# 阅读目录

**Paper1 实验导读：每组实验做了什么、说明了什么** **2**

先找到论文里的实验 . . . . . 2

1. 用了哪些数据 . . . . . 2

2. 先看懂分数 . . . . . 3

3. 受控主实验：完整流程能修已知错误吗 . . . . . 3

4. 实际抽取输出：不人为放错，还能改善吗 . . . . . 3

5. 诊断与过滤：究竟哪部分带来收益 . . . . . 4

6. 消融：把组件拿掉，结果变不变 . . . . . 4

7. 跨模型：换模型后如何 . . . . . 5

8. 首次收据测试：规则为什么可能误删 . . . . . 5

9. 新收据测试：证据位置提示有没有用 . . . . . 5

10. 修复与重新抽取：旧图到底有没有帮助 . . . . . 6

11. 完整组件与简单上下文对照 . . . . . 6

12. CUAD 合同：换文档类型能否推广 . . . . . 7

13. 真人审查：自动差异是否真的错，实际编辑是否可接受 . . . . . 7

14. 辅助实验、历史诊断与成本 . . . . . 7

15. 贡献与实验结论怎样对应 . . . . . 8

# Paper1 实验导读：每组实验做了什么、说明了什么

更新：2026-11-10。按当前合并版论文第 5 章及附录的顺序解释。本轮同步方法重组后的章节定位，实验内容与所有数值沿用已有结果。

先用一句话理解任务：**模型已经从文档里填出一张字段表，我们利用原文再检查、补充和修改它。** 实验既要看有没有修好，也要看有没有把原来正确的内容改坏。

## 先找到论文里的实验

编号按当前 main.tex 引用顺序整理。Overleaf 若改了顺序，用英文小节名定位。

| 本导读 | 论文对应位置 | 它想回答的问题 |
|---|---|---|
| 1—2 | 5.1 Test Setup | 用什么数据，怎么算好坏? |
| 3 | 5.2 Repair of Added Defects | 人为放入的错误能修好多少? |
| 4 | 5.3 Repair of Model-Built Graphs | 真实模型输出也能改善吗? |
| 5—6 | 5.4 Prompt, Filter, and Edit-Selector Tests；附录 A.1—A.2 | 生成、诊断、过滤及顺序选择各贡献多少? |
| 7 | 5.5 Tests with Two Models | 换模型后是否还有同样趋势? |
| 8 | 附录 A.3 First Receipt Test；正文 5.6 的动机 | 初次收据测试怎样暴露误删和格式问题? |
| 9 | 5.6 Source-Line Hints on New Receipts | 冻结的新收据测试是否改善? |
| 10 | 5.8 Repair versus Fresh Extraction；附录 A.4 Receipt Repair and Fresh-Extraction Details | 有旧图是否优于重新抽取？解析失败怎样限制结论? |
| 11 | 5.4 的 factorial 段；5.7 Comparing Source-Line Hints | 严格对照支持哪些组件归因? |
| 12 | 5.9 Contract Field Test | 换成合同能否复现收益? |
| 13 | 5.10 Human Review of Errors and Edits | 真人是否认可这些错误和编辑? |
| 14 | 附录 A Extra Tests；5.12 Code and Data | 完整回放、规模和成本怎么解释? |
| 15 | 5.11 Discussion；5.12 的研究问题汇总表 | 论文最终能得出什么结论? |

数学含义不清楚时查 数学导读，不必先读完所有公式。

## 1. 用了哪些数据

**对应论文：**5.1，experiments.tex，表 tab:repair_benchmark；各外部任务的小节另给细节。

| 数据 | 实际规模 | 用途 |
|---|---|---|
| 中文受控字段图 | 1,499 篇；训练 1,049、验证 225、测试 225 | 从已知答案出发，放入错误后测试恢复 |
| 中文实际抽取图 | 同一批 225 测试来源 | 直接检查模型真正生成的输出 |
| 中文机制对照 | 其中 60 篇，分别使用受控和实际抽取输入 | 固定其他条件，比较组件 |
| SROIE 收据 | 首次 60 篇；后续另有 20 开发＋60 测试篇 | 检验原始收据字段修复 |
| CUAD 合同 | 20 开发＋56 测试份 | 检验另一种文档类型 |
| 真人审查 | 200 项输入差异＋200 项实际编辑 | 检验自动差异是否真错、编辑是否可接受 |

**重要的数据特点：**中文原文是“字段名：值”形式，正确值已经直接写在来源里。因此简单程序按字段复制就能满分。收据和合同不是同样规整的格式。

后续多组收据实验重复使用同一批 60 篇，不能每跑一组就算又增加了 60 篇独立测试文档。

## 2. 先看懂分数

**对应论文：**5.1 的 Metrics and statistics，experiments.tex。

| 指标 | 用普通话解释 |
|---|---|
| 缺陷修复率 | 放进去的错误，有多少被修回去了 |
| 三元组 F1 | 整体上既少漏填，也少多填；不是只数修了几条 |
| 整图精确匹配 | 整篇文档的输出全部吻合参考，才算一次成功 |
| 正确事实保持率 | 原本与参考相符的内容，还保留了多少 |
| 参考差异减少率 | 修复后比修复前少了多少差异；若越修越多，可以为负 |

“参考”是评分答案，不是每一次实际编辑都经过真人确认。收据金额 1200.00 与 1,200.00 可能意思相同，却在严格字符串评分中不同。

文中“+4.76 个百分点”指从 78.75% 到 83.51% 这样的相减。95% 差值区间跨过 0，表示当前证据还不能可靠判断哪种更好，不表示两者已被证明完全一样。

F1 先在每篇文档内计算，再对文档取平均，每篇权重相同。收据的“恢复 26 个、丢失 14 个”是字段总数；表中的 F1 则是文档平均分。字段计数说明具体改了什么，F1 说明每篇输出与参考有多接近。

## 3. 受控主实验：完整流程能修已知错误吗

**对应论文：**5.2，experiments.tex，表 tab:repair_main、图 fig:repair_benchmark_results。

这里 Gate 指程序过滤器，Diagnosis 指额外诊断报告；Simple 是简单修复流程。SHACL 是描述和检查图约束的一种语言，本文使用其中适配本任务的检查。

**怎么做：**225 篇测试文档，每篇放入两个缺陷，共 450 个。缺陷包括缺失、重复、非法关系、反向边、无来源支持的值和层级冲突。比较不修复、规则、直接问模型、两次调用的 agent，以及组合流程。

| 方法 | 缺陷修复率 | F1 | 整图完全匹配 |
|---|---:|---:|---:|
| 不修复 | 0.00% | 76.15% | 0.00% |
| 仅规则 | 32.00% | 84.72% | 6.22% |
| SHACL-style Repair | 0.00% | 79.98% | 0.00% |
| 直接问模型 | 92.44% | 95.20% | 82.67% |
| 两次调用的 ReAct-style | 89.11% | 92.13% | 59.56% |
| Simple Pipeline | 95.11% | 96.34% | 84.00% |
| Diagnosis + Gate | 98.00% | 99.17% | 93.33% |
| 按原文字段直接复制 | 100.00% | 100.00% | 100.00% |

**结论：**组合流程比这里实现的几个模型流程好，但这个数据上最好的方法是无需模型的字段复制。98% 属于“一次生成＋过滤”，不是神经路由或多轮选择器的成绩。

完整流程比 Simple 的修复率高 2.89 点，配对区间为 [1.11, 4.89]。它比较两个完整流程；单组件贡献由匹配提示和同响应过滤测试衡量。

## 4. 实际抽取输出：不人为放错，还能改善吗

**对应论文：**5.3，experiments.tex，表 tab:natural_errors、图 fig:natural_stratified。

**怎么做：**让模型对同一批 225 来源实际建图，再修复输出。其中 10 次无法解析；77 个图与参考不一致，共 302 项差异。

| 方法 | F1 | 整图完全匹配 |
|---|---|---|
| 初始抽取 | 87.99% | 65.78% |
| Simple Pipeline | 88.07% | 67.11% |
| Diagnosis + Gate | 92.48% | 68.44% |
| 字段直接复制 | 100.00% | 100.00% |

**结论：**完整流程改善了参考匹配，三元组层面的改善比整图全部修好的改善更明显。这不是新领域测试；302 项自动差异也不能直接称为 302 个真人确认的错误。

论文另把解析失败与可解析但内容不符的输入分开检查，防止把“补回空图”的收益完全当成一般语义修复收益。

## 5. 诊断与过滤：究竟哪部分带来收益

**对应论文：**5.4，实验正文与匹配对照表。历史流程表在附录 A.1，见完整流程比较。

先看同一批候选过滤前后。这样模型没有重新生成，变化才能归到过滤上：

- 缺陷修复率都为 98.00%，整图匹配都为 93.33%。
- F1 从 98.95% 到 99.17%；过度修复从 2.27% 降到 1.67%。
- 过滤器拒绝了 8 个无来源支持、且不匹配参考的三元组。

**含义：**过滤主要拦下额外不合格内容，没有让这批候选修好更多目标缺陷。

再用 Gemma 比较 Base、Diagnosis、SHACL context，60 篇 × 两种输入 × 三组，共 360 个响应；每个响应都分别评分过滤前后。

| 统一过滤后的上下文 | 受控 F1 | 实际抽取输入 F1 |
|---|---|---|
| Base | 99.62% | 92.52% |
| Diagnosis | 98.61% | 91.47% |
| SHACL context | 99.12% | 93.64% |

**结论：**增加诊断没有稳定改善输出。这与上一节“完整流程胜过 Simple”不矛盾：旧完整流程同时改变了多件事，此处更接近只比较诊断内容。

这里的 SHACL context 是结合本任务改编的相关工作思路，不是官方代码原样复现。

## 6. 消融：把组件拿掉，结果变不变

**对应论文：**正文 5.4 的摘要、附录 A.2，appendix.tex。

### 6.1 五项过滤检查

540 个已存响应分别通过 8 种过滤设置，共 4,320 次评分，不增加模型请求。

检查包括重复、文档编号、字段名单、来源支持、字段最多一个值。完整过滤器拦下 28 个不匹配参考的候选：11 个文档编号错误、17 个缺来源支持；其他检查在这批输出中几乎没有改变结果。

**结论：**有可追溯的拦截作用，但 21 项比较经多重比较校正后，没有一项达到显著标准。当前没触发某检查，不等于该检查永远无用。

### 6.2 神经路由和顺序选择器

这里是另一条流程：先试做每个修改，再由效用和约束决定是否接受。新版统一训练/运行特征，使用 8 输入、884 参数的监督路由网络。

13 种配置各处理 450 个输入；另做一套先验敏感性分析，合计 11,700 次离线回放。主要结果如下：

| 设置 | 受控 F1 | 实际抽取输入 F1 |
|---|---|---|
| 始终开启＋均匀先验 | 84.72% | 88.33% |
| 始终开启＋学习先验 | 84.72% | 87.99% |
| 学习先验＋学习触发 | 84.72% | 87.99% |
| 去掉操作成本 | 89.30% | 88.13% |
| 仅规则候选 | 84.72% | 87.99% |

还检查了去先验惩罚、去密度上界、去质量下界、只做一轮、去规则候选，以及分别去局部/图/来源分数与对应边界。这些分数组件消融不等于把整个尺度的检测能力全部移除。

**结论：**这部分消融已经系统做过，但没有显示学习先验稳定提高最终修复质量。去成本有利于受控输入，对实际抽取输入却没有同样稳定的收益。11,700 是配置回放次数，不是新文档数。

## 7. 跨模型：换模型后如何

**对应论文：**5.5，experiments.tex，表 tab:cross_model。

在同一批 60 个受控文档上，历史 Claude 与 Gemma 都比较 Direct、Simple、Diagnosis + Gate。完整流程的缺陷修复率分别为 97.5%、98.3%，都高于对应的两个简单模型流程。

**结论：**这个小样本有跨模型一致趋势，但没有证明跨领域或真实语义错误上的普遍优势。这里提到 Claude 是历史档案，本次文档更新没有调用它。

## 8. 首次收据测试：规则为什么可能误删

**对应论文：**附录 A.3，appendix.tex。

60 张收据，评价公司、地址、日期、金额；一个地址没有标签，因此总计 239 个标注字段。

Base 和 Diagnosis 的原始 F1 都为 79.44%，加过滤后变成 79.15%。被过滤掉的三个候选恰好都匹配参考，问题来自来源与候选的空白形式不一致。按“字段名：值”直接复制在这种收据文本上也不适用。

**结论：**合法字段和来源出现检查不够；来源格式也会影响过滤。这个结果推动了后续的字段定义、空白处理与证据索引。

## 9. 新收据测试：证据位置提示有没有用

**对应论文：**5.6，experiments.tex，表 tab:receipt_followup。

先用另外 20 篇固定设计，再用新的 60 篇测试。所有组拿到同样的字段定义、编号原文行和初始图；索引组额外得到字段相关行的位置。

| 方法 | 严格 F1 | 规范化 F1 |
|---|---|---|
| 初始抽取 | 78.33% | 79.58% |
| Simple + Gate | 78.75% | 80.83% |
| Evidence Index + Gate | 83.51% | 86.43% |

| 方法 | 严格 F1 | 规范化 F1 |
|---|---|---|
| SHACL context + Gate | 78.33% | 80.42% |

预设比较 Index−Simple 为 **+4.76 点，95% 区间 [2.50, 7.26]**。规范化后仍有差异，不全是大小写或空格造成的。

**但不是只改对：**索引修好 26 个原不精确字段，也使 14 个原精确字段失去精确匹配；其中 10 个仍是同一金额，只改变格式。过滤本身对索引 F1 仅贡献约 0.18 点，主要差别来自生成时看到的上下文。

**结论：**这批新收据支持证据提示有效；还需要下一组更简单的上下文对照，才能说明专门的索引设计是否必要。

## 10. 修复与重新抽取：旧图到底有没有帮助

**对应论文：**5.8，experiments.tex。

复用上述 60 收据，比较“有/无旧图 × 有/无索引”，共 240 次请求。

所有响应都带 Markdown 代码围栏，与预先固定的严格解析器不兼容。因此**原定严格分析全部失败，无法判断语义优势**。

随后明确标注为事后分析，统一去外围围栏并处理已知文档编号：索引修复 F1 为 83.93%，索引重抽取为 74.86%。不统一编号时曾有更大的差距，其中一部分其实来自编号错误。

**结论：**不能把全部差距归给修复机制，也不能把事后处理写成预先设计成功的正式测试。这促成了合同实验在调用前固定解析和编号规则。

## 11. 完整组件与简单上下文对照

**对应论文：**5.4 的 factorial 段、5.7，experiments.tex，表 tab:recovery_factorial、tab:recovery_index。

本轮 840 个响应全部成功解析：480 个用于预处理×诊断开关，360 个用于收据上下文对照。过滤仍在同一响应上开关，不重新调用。

中文部分的六项预设组件主效应，经 Holm 校正后都未显著。诊断均值没有正向收益；来源和文档编号过滤拦下了 47 个不匹配参考的候选。这 47 个属于本轮，不能和第 6 节的 28 个混为一批。

收据部分如下，统一使用过滤：

| 上下文 | F1 |
|---|---|
| Simple | 79.17% |
| 完整索引 | 83.51% |
| 仅锚点 | 83.51% |
| 随机索引 | 81.67% |
| Simple，无字段定义 | 80.83% |
| 完整索引，无字段定义 | 74.70% |

**结论：**完整索引没有可靠优于随机索引，和仅锚点均值相同；去掉字段定义则明显伤害索引组。当前证据更支持“字段定义与上下文配合有用”，不能证明全部邻近行设计都必要。

本轮 Index−Simple 为 +4.35 点，五项校正后 p=0.0652。它和第 9 节 +4.76 来自不同响应批次与检验安排；边际区间不按多重比较调整，不能仅据区间不跨零宣称 Holm 校正后显著。完整与仅锚点均值相同，也不代表已证明两者等效。

## 12. CUAD 合同：换文档类型能否推广

**对应论文：**5.9，experiments.tex，表 tab:cuad。

使用 20 个开发合同，冻结字段、长度限制、解析和文档编号后，测试 56 个符合条件的官方测试合同。评价合同名、日期、期限、管辖法律等五字段，不是完整 CUAD 问答任务。

| 方法 | 测试 F1 |
|---|---|
| 初始抽取 | 46.76% |
| Simple repair | 43.35% |
| Indexed repair | 44.84% |
| Indexed re-extraction | 44.12% |

主要比较“索引修复−索引重抽取”为 **+0.72 点，95% 区间 [−4.80, 6.48]**，未显示可靠优势。测试 224 个计划输出实际用 270 次请求，运输失败按协议保留，没有挑结果重跑。

**结论：**索引修复比初始抽取低 **1.92 点**，丢失 5 个原参考正确事实，并引入 12 个新参考不匹配事实。这是本次迁移未复现修复收益的直接负结果。它与重新抽取的差异仍不确定；不显著不能写成等效，新参考不匹配也不自动等于真人确认语义错误。

## 13. 真人审查：自动差异是否真的错，实际编辑是否可接受

**对应论文：**5.10，experiments.tex，表 tab:human_review、tab:human_review_by_config。

两个人独立判断同一批 400 项：D 从 302 项参考差异中抽 200；E 从五种配置的 598 个实际编辑中抽 200。154 项分歧由第三人裁决；原始标签和一致性保留。

| 问题 | 裁决后结果 | 它的含义 |
|---|---|---|
| D：输入真的有错吗? | 95/200，47.5% | 参考不一致并不都是真错误 |
| D：建议操作可接受吗? | 86/200，43.0% | 有问题也不代表这个具体操作就合适 |
| E：实际操作可接受吗? | 134/199，67.3%，另 1 U | 抽样实际编辑中，确定判断的接受比例 |

U 表示证据不足，不是漏填。E 的原始操作接受一致率为 65%，κ 为 0.128；裁决后得到统一结果，不能掩盖最初分歧较大。

**结论：**中文人工任务已完成。67.3% 是五种配置合并的编辑接受率。收据和合同使用各自的数据集评分。历史 Diagnosis + Gate 的样本接受率为 **25/41（61.0%）**。各配置的抽样量较小且不同，分组结果按各自分母报告。完整统计见仓库中的 最终人工报告。

## 14. 辅助实验、历史诊断与成本

**对应论文：**附录 A，appendix.tex；正文 5.12。

| 检查 | 主要发现 | 怎样理解 |
|---|---|---|
| 旧选择器候选穷举 | 参考引导的最佳候选组合 F1 可到 99.64%，旧选择器只有 84.72% | 说明曾经有好候选但没选中；用了答案选组合，不能部署，也不是当前版本的新成绩 |
| 批量诊断规模 | 1,000 到 50,000 条记录，约 1.20 到 88.10 ms | 独立文档批处理，不含模型推理，不是大型连通图修复 |
| 来源评分检查 | 180 对的模型评分与参考有效性相关 | 模型检查的辅助证据，不是新的人类评价 |

| 检查 | 主要发现 | 怎样理解 |
|---|---|---|
| 45 个 TNEWS 标题抽取 | 类别准确率 0.556；Neo4j 对照 0.533，差异不显著 | 小型辅助抽取检查，不是有金标准三元组的 KG 修复比较 |

一次模型响应过滤前后只算一次调用；11,700 次缓存回放不是 11,700 次 API 请求。模型修复如果需要先建图，应把初始建图成本也算上。同样调用一次，也可能使用不同数量的输入 tokens。

## 15. 贡献与实验结论怎样对应

**对应论文：**5.11 Discussion、5.12 的 tab:research_answers，引言三项贡献及第 6 章 Conclusion。

| 合并版引言的贡献 | 对应方法与实验 | 当前结果 |
|---|---|---|
| 把局部、图和来源检查汇入 assessment profile，指导字段修复 | 3.2 的评估与 4.1 的设置；5.4 的匹配提示、单项检查和析因对照 | 错误报告列出失败位置，选择器用四项分数比较试改；匹配 Gemma 测试中诊断组均值下降，过滤记录了被拒绝的具体候选 |
| 输出过滤与单独测试的尺度路由选择器，比较试改收益、成本和图边界 | Algorithm 1、Algorithm 2；5.2—5.4；附录 A.2 | 生成加过滤在受控输入修复 98.00% 的缺陷；顺序选择器另有 11,700 次回放，默认配置在受控输入接受 0 次编辑，自然输入的均匀先验 F1 高于学习先验 |
| 跨任务的组件比较、人工评价，以及输出和决策日志 | 5.5—5.10；附录；5.12 的代码与数据入口 | 新收据 Index–Simple 为 +4.76 点；后续完整索引与仅锚点均值相同；合同索引修复比初始抽取低 1.92 点；五配置人工合并接受 134/199 项编辑 |

这三行对应引言中的方法贡献。RQ1—RQ3 则对应实验要回答的问题：什么时候修复有用，各组件改变了什么，已有图是否优于重新抽取。论文 5.12 的汇总表按这三个问题排列。

| 问题 | 目前的答案 |
|---|---|
| 完整流程能改善一些文档字段图吗? | 能，有受控与实际抽取的参考匹配结果 |
| 中文主任务必须用复杂模型吗? | 没有证明；字段复制已达 100% |
| 诊断或学习路由稳定带来额外增益吗? | 尚未证明；严格 Gemma 诊断组 F1 反而下降 |
| 过滤能拦截部分不合格候选吗? | 能，但收益较小，也出现过误删，不保证语义正确 |
| 证据索引在新收据上有帮助吗? | 相对 Simple 有正向结果，规范化后仍改善；未可靠胜过随机或仅锚点上下文 |
| 结果已推广到合同吗? | 未复现：索引修复 F1 低于初始抽取，且未可靠胜过重抽取 |
| 真人评价完成了吗? | 原定中文两项完成；合并 134/199 不能代表完整方法准确率，也未建立配置间优势 |

主文现在按任务与主结果、严格机制对照、外部文档、人工评价、综合讨论组织；完整回放和解析明细保留在附录。旧实验数值及冻结协议没有调整。

当前状态为**内容定稿待作者确认**。本轮英文采用简单词和短句，直接报告方法步骤及实验结果。下一步见 PROGRESS.md。