# 阅读目录

**Paper1 数学导读：对照论文一步步看** **2**

先找到你正在读的论文位置 . . . . . 2

1. 输入和输出：修一张文档信息表 . . . . . 2

2. 三个检查：主体对不对、字段对不对、值能否找到 . . . . . 3

3. 模型生成：根据原文提出一份完整答案 . . . . . 3

4. 候选筛选：一个字段最多留一个值 . . . . . 3

5. 证据索引：给模型标出值得再看的原文行 . . . . . 4

6. Algorithm 1：把前面五件事串起来 . . . . . 4

7. 顺序变体的 profile：用四个分数概括当前图 . . . . . 5

8. Scale-Aware Routing：建议要不要修、优先看哪类问题 . . . . . 5

9. 顺序选择：每次试改，再选择值得做的那一个 . . . . . 6

10. 自动评分：改对多少和整张图全对不同 . . . . . 7

11. 人工一致性与统计：判断这个提升是否可信 . . . . . 7

读完后应记住什么 . . . . . 7

# Paper1 数学导读：对照论文一步步看

更新：2026-11-10。本文对应 paper1merge/ 当前稿。第 3 章按任务、评估、约束修复、路由和试改循环展开，第 4 章集中说明实现设置。本轮同步章节定位，公式、阈值与实验数值沿用原稿。

如果只想先理解方法，可以先读每节的解释和例子，暂时跳过公式；需要核对时再看符号。

全文用一个例子：收据写着“公司：甲公司；小计：100；实付：120”。系统要得到“这张收据—实付金额—120”这样的记录。这里的知识图谱，可以先理解为**一张用三列存信息的表**。

## 先找到你正在读的论文位置

章节号按当前 main.tex 实际引用的源码排列；Overleaf 若调整了顺序，以英文小节名为准。下面的“本导读第几节”不是论文公式编号。

| 本导读 | 论文对应位置 | 你会弄懂什么 |
|---|---|---|
| 1 | 3.1 Task and Overall Design | 输入和输出是什么 |
| 2 | 3.2.1 Field Checks and Error Report | 程序先检查哪些问题 |
| 3 | 3.3.1 Generating a Graph from Source Text | 模型负责什么 |
| 4 | 3.3.3 Checking the Generated Triples | 哪些候选能留下，数量命题证明了什么 |
| 5 | 3.3.2 Field Meanings and Source Lines | 怎样提示模型去原文找字段 |
| 6 | 3.3.3 Checking the Generated Triples，Algorithm 1 | 主流程怎样连起来 |
| 7—9 | 3.2.2 Quality Scores for Trial Graphs；3.4 Scale-Aware Routing and Edit Actions；3.5 Trial Checks and Repair Loop | 单独评估的路由、候选编辑和试改循环怎样工作 |
| 10—11 | 5.1 Test Setup；5.10 Human Review of Errors and Edits | 怎样算分，怎样理解人工结果 |

**先分清两个流程**。主实验的“98% 修复率”来自“一次模型生成＋过滤”。路由和多轮选择按另一组独立配置评价，各自结果在第 5 章和附录中报告。

## 1. 输入和输出：修一张文档信息表

**对应论文：**3.1，methodology.tex，定位 sec:framework:problem。

| 符号 | 简单含义 | 例子 |
|---|---|---|
| $X$ | 原文 | 收据上的全部文字 |
| $G$ | 待修复的三列记录，可包含重复项 | “收据—实付—100” |
| $t = (h, r, o)$ | 一条记录：主体、字段、值 | (收据, 实付, 120) |
| $h_0$ | 这篇文档的固定编号 | 这张收据的编号 |
| $\mathcal{R}_X$ | 允许填写的字段 | 公司、地址、日期、实付 |
| $G^*$ | 评分时使用的参考答案 | 模型推理时不能读取 |
| $\widehat{G}$ | 修复后的输出 | 最终交出的信息表 |

这里每个字段最多保留一个值。“允许填写日期”不等于“每篇文档都必须有日期”。这个设置也不直接适用于“作者”这种可能有多个值的字段。

## 2. 三个检查：主体对不对、字段对不对、值能否找到

**对应论文：**3.2.1，methodology.tex，公式标签 eq:diagnostic_predicates、eq:diagnostic_context。

程序先去掉完全重复的记录，处理字段图中明确写反的边，去掉非法主体或字段。接着用三个开关检查候选：

$$H(t) = \mathbf{1}[h = h_0], \qquad R(t) = \mathbf{1}[r \in \mathcal{R}_X],$$
$$S(t; X) = \mathbf{1}[o \neq \emptyset \ \wedge \ o \text{ occurs in } X].$$

$\mathbf{1}[\cdots]$ 的意思是：方括号里的条件成立就记 1，否则记 0。$\wedge$ 表示“并且”。

- $H$：这条记录是否属于指定文档?
- $R$：字段是否在允许名单内?
- $S$：值是否非空，而且能在原文里找到?

例如“实付—100”可能三个检查都通过，因为 100 确实在收据里，但它是小计。因此，**通过这三个检查不等于字段语义正确**。

诊断报告只是把发现的问题列出来：

$$D = (n_{\text{dup}}, I_H, I_R, I_S, \mathcal{R}(G_s)).$$

$G_s$ 是预处理后的图；$n_{\text{dup}}$ 是重复数，$I_H, I_R, I_S$ 是检查失败的位置，最后一项是已经出现的字段。报告在预处理之后生成，有些问题已被删除，对应列表自然为空。

## 3. 模型生成：根据原文提出一份完整答案

**对应论文：**3.3.1，methodology.tex，eq:proposal_generation。

$$C = L_\theta(X, h_0, \mathcal{R}_X, G_s, D).$$

把它读成一句话：**将原文、文档编号、字段名单、现有图和可选诊断交给模型，得到候选记录列表** $C$。$L_\theta$ 表示现成语言模型，不表示本论文重新训练了该模型。

模型返回的完整图是最终过滤的输入。旧图中正确的记录也需要重新输出才能留下。无法解析的输出记为空图，纳入相应实验的评分和分母。

## 4. 候选筛选：一个字段最多留一个值

**对应论文：**3.3.3，methodology.tex，eq:eligible_candidates、eq:admissible_subsets、eq:selection_size。

先去重，再留下通过三个检查的候选：

$$C_X = \{t \in \text{uniq}(C) : H(t)R(t)S(t; X) = 1\}.$$

这里三个 0/1 值相乘，只有全部为 1 才通过。再要求每个字段最多出现一次：

$$\mathcal{F}(C_X) = \left\{ A \subseteq C_X : \sum_{t \in A} \mathbf{1}[r_t = r] \leq 1, \ \forall r \in \mathcal{R}_X \right\}.$$

读法是：“$\mathcal{F}$ 收集所有合法的候选子集；每个字段的计数不能超过 1。”实际算法按模型输出顺序扫描，保留每个字段的第一个合格候选。

**论文的数量命题：**

$$|\widehat{G}| = \max_{A \in \mathcal{F}(C_X)} |A| = |\{r : \exists t \in C_X,\ r_t = r\}|.$$

竖线 $|\cdot|$ 表示“有多少个”。假设合格候选涉及公司、日期、实付三个字段：每个字段最多取一个，所以最多保留三条；算法恰好各取一条，便达到三条。

这个式子说明过滤后保留的记录数。若实付的 100 和 120 都通过检查，算法按输出顺序选第一个；字段含义决定哪个值正确。若加入“总额等于各项金额之和”的规则，就需要同时检查几个字段。

## 5. 证据索引：给模型标出值得再看的原文行

**对应论文：**3.3.2，methodology.tex，sec:framework:field_evidence。下面的窗口式是对文字步骤的展开，不是新增论文定理。

先告诉模型“实付金额”指最终应付总额，再在原文中寻找 total 等位置。例如找到第 10 行，就同时提示它查看第 9—12 行。

$$A_r = \{i : \text{line } i \text{ matches field } r\}, \qquad E_r = \bigcup_{i \in A_r} \{i-1, i, i+1, i+2\}.$$

$A_r$ 是字段 $r$ 的锚点行，$E_r$ 是锚点和邻近行；超出文档范围的行号去掉。所有比较方法都能看到完整原文，索引额外给出按固定规则找到的行号。

收据后续实验还统一了空白处理。$N(s)$ 把连续空格、换行压成一个空格，并去掉首尾空白：

$$S_{\text{ws}}(t; X) = \mathbf{1}[|N(o)| > 0 \ \wedge \ N(o) \text{ occurs in } N(X)].$$

例如 `甲公司\n上海` 和 甲公司上海 可以匹配。空白处理解决排版差异；字段含义帮助模型判断公司角色。早期主过滤器和顺序选择器使用不同的空白规则，各版本按原规则评分。

## 6. Algorithm 1：把前面五件事串起来

**对应论文：**3.3.3，methodology.tex，alg:abstract。

1. 整理输入图，得到 $G_s$。
2. 生成诊断报告。
3. 调用一次模型，解析完整候选图。
4. 依次检查重复、主体、字段、原文和单值限制。
5. 返回保留的记录，并记下拒绝原因。

复杂度是在估计“数据变多后需要做多少检查”：

$$T_{\text{preprocess}} = O(n), \qquad T_{\text{gate}} = O(k(1 + c_X)).$$

$n$ 是输入记录数，$k$ 是候选数，$c_X$ 是一次原文查找的成本。$O(n)$ 可理解为“检查量大致随记录数增长”。文本长度影响查找成本，模型推理时间单独统计。

## 7. 顺序变体的 profile：用四个分数概括当前图

**对应论文：**3.2.2、3.4.1 与 4.1，methodology.tex，公式 eq:quality_state、eq:profile_rates、eq:routing_inputs，以及多尺度检查图和路由图。

| 分数 | 简单问题 | 计算方式（分母非空时） |
|---|---|---|
| $Q_{\text{inc}}$ | 有多少节点连着边? | $100(1 - I/n)$ |
| $Q_{\text{uniq}}$ | 记录是否重复或高度相似? | $100c/m$ |
| $Q_{\text{rule}}$ | 有多少记录未被规则标为违规? | $100(1 - B/m)$ |
| $Q_{\text{src}}$ | 有多少值能在原文找到? | $100(1 - V/m)$ |

$n$ 为节点数，$m$ 为记录数，$I$ 为孤立节点数，$B$ 为被规则标记的不同记录数，$V$ 为来源不匹配数。$c$ 是把相似记录连起来后得到的组数；实现用字符对计数的余弦相似度判断。

四项平均得到 $Q$。例如 5 个节点中 1 个孤立，第一项为 80 分。

节点连接和字段缺失分开检查。一张图只留下公司名，它的节点也可能都连接正常。来源字段检查会继续寻找原文中已有、图中缺失的字段。

图密度 $\rho$ 表示实际连接占可能连接的比例：

$$\rho = \frac{|E_{\text{pair}}|}{n(n-1)} \quad (n > 1).$$

$E_{\text{pair}}$ 只计不同的有向节点对，并去掉自己指向自己的连接。同一节点对上有多条记录时只计一次；$n \leq 1$ 时密度为零。

空图的节点连接分为 0，其余三项为 100。非空图没有来源文本时，来源分为 50。这些是计算约定；字段恢复效果另用参考 F1 衡量。

## 8. Scale-Aware Routing：建议要不要修、优先看哪类问题

**对应论文：**3.4.1 与 4.2，正文给出网络输入输出与训练损失，公式 eq:decision_net、eq:decision_loss。

输入是四个分数和四个图统计量：

$$x = [Q_{\text{inc}}, Q_{\text{uniq}}, Q_{\text{rule}}, Q_{\text{src}}, n, m, \rho, n_{\text{viol}}].$$

八个输入先按训练集均值和标准差缩放。网络经过 32、16 个中间单元，两层都用 ReLU。sigmoid 给出修复分数 $p_{\text{repair}}$，softmax 给出三类问题的权重 $\boldsymbol{\pi}$。网络共 884 个参数。$n_{\text{viol}}$ 是发现的违规数。

训练时，一方面要求“是否有缺陷”判断正确，另一方面要求“主要属于哪类问题”判断正确：

$$\mathcal{L} = \frac{1}{N}\sum_i \text{BCE}(p_i, y_i) + \frac{\sum_i m_i(-\log \pi_{i,c_i})}{\sum_i m_i + \epsilon}.$$

$y_i$ 是是否有缺陷的标签；$c_i$ 是问题类别；$m_i$ 表示是否有可用类别标签；$\epsilon$ 防止除零。两项损失都在做同一件事：预测越偏离训练标签，扣分越多。

这是用已知注入缺陷训练的**监督路由器**。干净图训练是否修复的输出；缺陷图还训练问题类别输出。类别取注入缺陷中占比最高的一类。文档的干净与缺陷版本放在同一数据分组中。

## 9. 顺序选择：每次试改，再选择值得做的那一个

**对应论文：**3.4.2 的候选与成本、3.5 的试改和循环、4.3 的固定设置，methodology.tex，公式 eq:cost_hierarchy、eq:action_utility、eq:constrained_opt，Algorithm 2。

对候选操作 $a$，先复制当前图，试做得到 $G_a$，再计算：

$$U(a) = \frac{Q(G_a) - Q(G)}{100} + 0.20\frac{\max(0, h(G) - h(G_a))}{\max(1, h(G))} - 0.35c(a) + 0.05\log(\max(\pi_{s(a)}, 0.05) + 10^{-6}) + 0.02z(a).$$

从左到右就是五笔账：质量提高多少、违规减少多少、操作多贵、路由器多偏好这类操作、候选有多可信。$h$ 是硬规则违规数，$c$ 是设定的操作成本，$s(a)$ 是类别，$z$ 是提议置信度。

添加、删除、改关系的成本分别为 0.06、0.30、0.16。多项编辑组成一个候选包时，成本相加，再乘公式中的 0.35。

每次试改先检查下面几条规则：

| 检查 | 当前设置 |
|---|---|
| 四项分数下界 | 节点连接 55、唯一性 55、规则 60、来源 45 |
| 已经达到下界的分数 | 修改后仍须达到下界 |
| 尚未达到下界的分数 | 保持原值或提高 |
| 单项分数回退 | 最多下降 2 分，同时满足前两条 |
| 图密度 | 修改后不超过 0.75 |
| 非空图 | 修改后仍为非空 |

例如，来源分从 80 降到 79，通过回退检查；从 46 降到 44，会低于 45 的下界；从 40 降到 39，则让原本不达标的分数进一步降低。后两种试改都会被挡下。

这些检查得到允许的候选集 $\mathcal{A}_t^{\text{ok}}$。Algorithm 2 从中选出 $U$ 最大且 $U > 0$ 的一项执行，然后重新计算整图分数，最多做 12 轮。

修复分数的触发阈值为 0.05。已有模型候选或硬规则错误时，低修复分数仍会进入试改。没有待查问题和候选，或没有正分的允许编辑时，循环结束。同一张图与同一候选的组合只试一次。

**一个容易理解的反例：**正确补上一个缺失字段，但四个分数几乎不变；再减去成本后，系统可能觉得“不值得做”。所以效用变好和参考 F1 变好不是同一回事。

论文另检查了把均匀先验的负常数去掉：

$$U_{\text{relative}}(a) = U(a) - 0.05\log(1/3 + 10^{-6}).$$

这像把所有候选同时加上相同分数：排名不变，但原来略低于零的候选可能变成可接受。默认评分和这个对照都在回放前固定。

当前正文 5.4 报告选择器摘要，完整 13 配置和先验敏感性回放移至附录 A.2。默认顺序选择在受控输入接受 0 次编辑；自然输入学习先验 F1 87.99%，低于均匀先验 88.33%。保留这条神经变体和三张方法图用于单独评价，主流程的 98% 修复率属于生成与过滤路径；选择器结果按其独立配置报告。

该流程需要对许多记录两两比较。$T$ 轮、每轮最多 $K$ 个候选、每图 $m$ 条记录时，主要检查量约 $O(TKm^2)$。Algorithm 1 的清理和过滤只需逐条扫描。

## 10. 自动评分：改对多少和整张图全对不同

**对应论文：**5.1 的 Metrics and statistics，以及各任务的评分说明，experiments.tex。

中文任务保留重复次数。设候选记录 $t$ 在输出、参考中分别出现 $y_t, g_t$ 次：

$$TP = \sum_t \min(y_t, g_t), \qquad F1 = \frac{2TP}{|\widehat{G}| + |G^*|}.$$

例如参考有 4 条，输出有 5 条，其中 4 条匹配，F1 为 $8/9$，约 88.9%。若只看命中参考的比例会得到 100%，却忽略多输出的一条。

表里的 F1 先按每篇文档计算，再对文档取平均。设共有 $N$ 篇：

$$\overline{F1} = \frac{1}{N}\sum_{i=1}^{N} F1_i.$$

这样每篇文档的权重相同。上式中的 $TP$ 和记录数也先在单篇文档内计算。合同测试先把字段和值按其空白规则整理成集合，再逐篇计分；重复次数的处理按各任务的评分程序执行。

- **缺陷修复率**：人工注入的缺陷有多少被恢复；主实验分母是 450 个缺陷。
- **整图精确匹配**：一篇文档的输出全部吻合参考才算通过。
- **参考差异减少率**：原差异数为 $d_0 > 0$，修复后为 $d_1$，计算 $1 - d_1/d_0$；差异增多时可以为负。

收据和合同另有规范化规则。忽略一些空白后更相似，不等于人工确认语义相同。

## 11. 人工一致性与统计：判断这个提升是否可信

**对应论文：**5.10 人工评价与 5.1 统计方法，experiments.tex。

两个人判断同一批项目，Cohen’s κ 用来衡量“超过偶然一致程度的一致性”：

$$\kappa = \frac{p_o - p_e}{1 - p_e}.$$

$p_o$ 是实际一致比例；$p_e$ 是按两人各类标签比例计算的偶然一致水平。E 任务操作可接受性的原始一致率为 65%，κ 为 0.128；第三人裁决不会把这项原始一致性变高。

E 任务合并接受 134/199 项编辑，约 67.3%，另有 1 项不确定。样本来自五种配置，历史 Diagnosis + Gate 为 25/41。论文按各配置的分母报告结果。

配对 bootstrap 反复抽取整篇文档，比较同一批文档上的两种方法。差值区间跨过 0 时，两者高低仍不确定。Holm 校正按同一组的多项比较调整 p 值。论文的 95% 区间对应单个比较；显著性按该组校正 p 值读取。

完整流程、固定响应过滤和匹配提示各有对应比较。收据冻结对照 Index–Simple 为 +4.76 点；后续 Full–Random 的区间跨零，Full 与 Anchors-only 均值相同。合同索引修复为 44.84%，低于初始抽取的 46.76%；与重抽取相差 +0.72 点，区间为 [−4.80, 6.48]。

## 读完后应记住什么

主算法用来源和字段规则过滤模型提出的值。证据索引帮助定位文本，顺序变体根据试改分数选操作。对照实验报告各步骤的得分变化，人工评价检查具体字段和编辑是否合理。

下一步按论文顺序读 实验导读。当前工作状态见 PROGRESS.md；需要追溯旧公式修复时再看仓库中的 历史数学审查。