利用源文本与字段检查修复文档知识图谱

Hua Peng[1†], Zifu Tao[2†], Yu Guo[1], Qiang Zhou[2],
Tian Zhou[3*], Bo Han[3]

[1]中移系统集成有限公司, 中国.
[2]同济大学, 中国.
[3]西安交通大学, 中国.

*通讯作者及邮箱： tianzhou@xjtu.edu.cn;
其他作者邮箱： penghua@cmict.chinamobile.com;
2253323@tongji.edu.cn; guoyu1@cmict.chinamobile.com;
zhouqiang@cmict.chinamobile.com; bohan@xjtu.edu.cn;
†以上作者对本文贡献相同。

摘要

从文本构建的知识图谱常有事实缺失、取值错误和三元组重复。修复需要找出这些错误，用约束引导修改，并选择有用的编辑。我们提出一个框架，将多尺度质量评估、约束驱动修复和尺度感知路由结合起来。局部、图和来源检查形成共享的评估概况。来源与字段约束引导图生成，并过滤候选三元组。神经路由器根据评估概况为候选编辑赋予权重。选择器在图的副本上检查每项编辑，在图约束下比较质量收益和成本，并在接受修改后更新评估概况。实验覆盖中文政务、金融和环境记录、收据及合同，并包含组件测试和人工评价。主流程修复了 98% 的注入缺陷。在收据任务中，来源行提示使 F1 比 简单流程 高 4.76 个百分点。评价同时记录恢复的事实和保留的原正确事实，展示各修复阶段如何影响输出图。

关键词: 知识图谱修复，源文本，字段检查，文档抽取

中文完整译本，对应英文合并版。参考文献保留原始出版信息；模型标识与程序名称保留原文。图内英文标注的中文对照见译文附页。

1 引言

知识图谱（KG）连接不同来源的事实，支持问答、推荐和数据分析(Ji et al. 2022; Pan et al. 2023)。这些应用依赖所存事实的质量。关系缺失会使有用的信息无法被发现，错误取值则可能导致错误答案或决策。随着更多图谱从文本构建，检查和提高

图谱质量已成为知识图谱构建的重要部分(Zaveri et al. 2016; Paulheim 2017)。其目标是恢复有用事实，并保留图中已有的正确信息。

从文本抽取事实后，同一张图中会留下多类错误。来源噪声和含义不清的表述可能造成字段缺失、事实重复、关系错误，以及取值被放入错误字段(Ji et al. 2022; Paulheim 2017)。这些错误将图结构与源文本的含义联系起来。例如，收据上可能同时出现小计和最终金额，但两者的作用不同。判断某个金额是否属于总额字段，需要检查它是否出现在原文中，也需要判断它的含义。因此，图修复需要同时检查结构和字段取值的来源证据。

现有方法从不同方面提高图谱质量。基于规则的检查发现违反图规则和字段要求的情况(Kontokostas et al. 2014; Knublauch and Kontokostas 2017)。嵌入模型根据图中的模式，为事实成立的可能性打分(Bordes et al. 2013; Nickel et al. 2016)。大语言模型（LLM）利用文本和图上下文提出修复建议(Pan et al. 2023; Lin et al. 2025)。每类方法都为修复决策提供有用信息。规则违规指出了未满足的要求，模型建议则给出可能的替换内容。将这些信号连接起来，需要统一描述错误、明确修改边界，并在修复动作之间作出选择。

质量错误出现在不同尺度。局部检查可以发现重复事实，图检查则检验关系和字段间的冲突。来源检查将保存的取值与文档证据联系起来(Zaveri et al. 2016; Wang et al. 2021)。一个值可能满足字段规则，却指向文档中的错误位置。因此，规划修复时需要汇总这些检查。我们提出覆盖实体、图和上下文尺度的*多尺度质量评估*。各项检查形成共享的评估概况，记录不同范围内的错误和质量分数。这一概况将发现的问题传入修复过程，并为评估修改建议提供统一依据。

修复还需要在恢复缺失事实与保留正确事实之间作出权衡。添加事实可能引入字段冲突，删除事实则可能损失有用信息。我们提出*约束驱动优化*，为这些修改设定清楚的边界。来源和字段约束决定哪些生成的三元组可以进入修复后的图。在编辑选择中，质量下界和密度上限限定允许的试改图，编辑成本则鼓励小幅修改。这些约束将修复目标与明确的输出要求联系起来，也使接受或拒绝修改建议的依据清晰可查。

修复动作的选择也需要反映错误类型。简单规则可以删除重复事实并修正明确的结构错误。缺失值或错误值则需要阅读源文本。多个编辑建议可能针对同一字段，也可能改变另一项编辑的效果。我们提出*尺度感知路由*，利用评估概况引导选择。小型神经模型为实体、图和上下文尺度的编辑赋予权重。选择器将这些权重与质量收益、编辑成本结合，在图边界内比较修改建议。每次接受编辑后，重新评估图谱，再引导下一次选择。这样，发现的问题范围与修复范围及成本建立了联系。

上述设计将评估、修复约束和动作选择连接为一个框架。本文研究文档图谱，其字段需要遵循给定模式，并从可用源文本中取值。主路径结合规则清理、大语言模型生成和输出过滤。错误报告或按字段提供的来源行提示引导生成。路由路径每次选择一项编辑，并在每次接受修改后检查图谱。我们为生成路径和路由路径中的组件分别设置对照。这一设计展示各项方法在修复不同阶段对图谱的影响。

实验覆盖三个中文记录集合、SROIE 收据和 CUAD 合同，并对图谱差异和系统编辑开展人工评价。在含有 450 个注入缺陷的 225 张图上，诊断+门控 修复了 98.00% 的缺陷。在模型构建的图上，它将三元组 F1 从 87.99% 提高到 92.48%。在新测试的 60 张收据上，来源行提示使 F1 比 简单流程 高 4.76 个百分点。共享提示对照和组件测试分析生成、过滤、证据上下文和编辑选择的作用。评价同时记录字段恢复、事实保留、请求成本和人工编辑接受度。

本文有三项贡献：

- **多尺度质量评估**。 我们将局部结构、图规则和来源检查汇入共享概况，将发现的缺陷与修复决策联系起来。
- **约束驱动修复与尺度感知路由**。 我们为生成的图定义来源和字段约束。神经路由路径为候选编辑赋予权重，并在图边界内比较其质量收益和成本。
- **文档图谱评价**。 我们在注入缺陷、模型输出、收据和合同上比较修复方法及其组件，并开展人工评价。保存的输出和决策日志支持检查各个修复阶段。

第 2 节回顾相关工作。第 3、4 节介绍方法与实现。第 5 节报告实验和结果。第 6 节总结全文。

2 相关工作

2.1 图构建与抽取事实检查

构建知识图谱包括抽取事实、链接实体、映射关系和合并结果(Ji et al. 2022)。DBpedia(Auer et al. 2007)、YAGO(Suchanek et al. 2007) 和 Freebase(Bollacker et al. 2008) 从具有明确或部分明确结构的数据中建立知识库。知识融合利用来源证据为事实打分(Dong et al. 2014)。这些检查帮助抽取过程选择事实。本文研究抽取后的图修复，并用原文检查取值。

嵌入模型用向量预测链接(Bordes et al. 2013; Wang et al. 2017)。图神经网络从邻近节点和关系中学习(Schlichtkrull et al. 2018)。相关综述介绍了利用大语言模型构建、补全和整合知识图谱的方法(Pan et al. 2023, 2024; Bian 2025)。提示方法包括思维链推理(Wei et al. 2022)和共享提示模式(White et al. 2023)。检索增强生成将来源证据加入模型输入(Lewis et al. 2020)。Neo4j Labs 的 LLM Knowledge Graph Builder 按用户设置的模式，将文档转换成图(Neo4j Labs 2024)。第 A.7 节将本文方法与其核心抽取器比较。

2.2 图质量与检查范围

知识图谱质量涉及事实正确、事实缺失、规则一致和信息时效(Zaveri et al. 2016; Paulheim 2017)。统计方法查找异常值(Wienand and Paulheim 2014; Paulheim and Bizer 2014)。嵌入模型为三元组的可信程度打分(Nickel et al. 2016)。基于测试的方法检查链接数据质量(Kontokostas et al. 2014)。SHACL 检查图约束(Knublauch and Kontokostas 2017)。这些方法各自检查图质量的一部分。局部检查查找重复事实和无连接节点。图规则检查类型与关系。来源检查将记录值与文档证据匹配。评估概况将这些结果汇总，供修复过程共同使用。

Lin 等人向图中加入规则错误，并比较大语言模型修复提示(Lin et al. 2025)。他们使用 SHACL 规则和邻近图上下文。人工评价有助于判断答案不明确的情况(Acosta et al. 2013)。其他综述讨论图构建与修复中的质量检查(Wang et al. 2021; Paulheim 2017)。本文错误报告列出重复三元组、模式错误，以及未在原文中出现的值。

2.3 图修复与动作选择

知识图谱补全预测缺失链接。相关方法使用路径(Lao et al. 2011)、嵌入(Bordes et al. 2013; Yang et al. 2015; Shi and Weninger 2017)和神经网络(Dettmers et al. 2018)。MINERVA 学习沿图路径回答查询(Das et al. 2018)。MetaR 根据少量样本

预测链接(Chen et al. 2019)。AMIE 学习正规则(Galárraga et al. 2013)，RuDiK 学习正规则和负规则(Ortona et al. 2018)。其他方法将规则加入嵌入训练(Guo et al. 2016; Ding et al. 2018)。

RNNLogic 联合训练规则生成器和答案预测器(Qu et al. 2021)。NBFNet 从图路径中学习以预测链接(Zhu et al. 2021)。pLogicNet 结合逻辑规则和嵌入(Qu and Tang 2019)。这些方法将规则与学习得到的预测结合。本文将源文本与字段检查结合。主路径过滤生成的图。尺度感知选择器根据评估概况为候选编辑赋予权重，并在图边界约束下比较试改分数。

Lin 等人比较了基于 SHACL 的修复提示(Lin et al. 2025)。ReAct 将模型推理与信息收集动作结合(Yao et al. 2023)。本文的 ReAct-style 基线使用这一模式。我们的 SHACL 上下文基线将 Lin 等人的五部分提示改编到相同字段任务和调用上限下。共享提示以及过滤前后的评分展示上下文与图检查的作用。

3 任务与方法

图修复需要两个相连的步骤：找到问题，再选择修改。我们连接图检查模块与修复模块。检查模块根据图和源文本构建评估概况。修复模块利用这一概况提出修改，并检查输出。

输入包括三元组列表 G、源文本 X、固定文档编号 h_0 和允许关系 $\mathcal{R}_X$。列表可以包含同一三元组的多个副本。每种关系最多对应一个非空值，例如文档字段和收据字段。评分器用参考图 G^* 检查输出。修复后的图记为 $\widehat{G}$。

主修复路径先清理输入，再让模型生成完整图，最后过滤三元组。错误报告或来源行提示可以引导生成。过滤器根据源文本和字段规则检查每个值。第二条路径利用尺度感知路由，每次选择一项编辑。它为试改后的图打分，并执行最佳允许编辑。第 4 节介绍两条路径及其测试设置。

3.1 输入清理与错误报告

不同错误需要不同检查。重复三元组属于局部错误。错误的文档编号或字段名违反图规则。未在来源中出现的值无法通过证据检查。我们按实体、图和上下文三个范围组织检查。这里的上下文指文档源文本。图 1 展示这三类检查。

清理首先用明确的规则修正错误。预处理器 P 删除重复三元组。若一条边的对象为 h_0，而主体是其他节点，则将该边反向。随后删除头节点或关系不合法的三元组。这里，头节点就是三元组的主体。清理后的图为 $G_s = P(G; h_0, \mathcal{R}_X)$。

对三元组 $t = (h, r, o)$，三项检查为

$$H(t) = \mathbf{1}[h = h_0], \quad R(t) = \mathbf{1}[r \in \mathcal{R}_X], \quad S(t; X) = \mathbf{1}[o \neq \emptyset \ \wedge \ o \text{ 出现在 } X]. \tag{1}$$

H 检查文档编号，R 检查关系，S 检查来源。分开执行这些检查，可以说明每条三元组被拒绝的原因。

主路径以错误报告的形式保存评估概况：

$$D(G_s, X) = \big(n_{\text{dup}}, I_H, I_R, I_S, \mathcal{R}(G_s)\big). \tag{2}$$

报告记录重复数、未通过检查的位置和已出现的关系。例如，$I_S = \{i : S(t_i; X) = 0\}$ 列出未通过来源检查的位置。报告基于清理后的输入构建。它为模型提出字段值时提

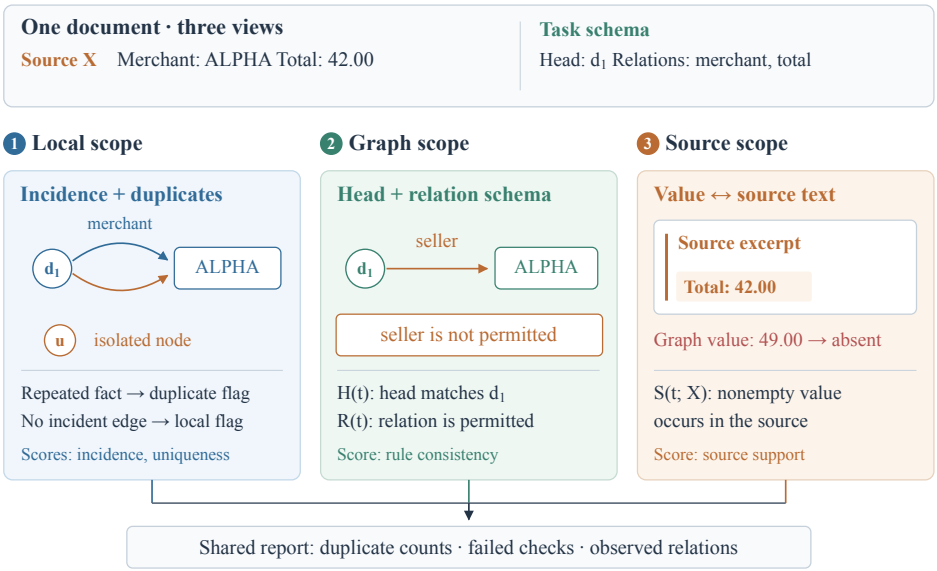


图 1 图检查的三个范围。局部检查查找重复事实和无连接节点，图检查测试文档编号和字段名，来源检查在文本中查找值。两条修复路径都用这些检查构建评估概况。

供查找位置。我们测试将报告加入提示的效果。字段为可选项，主路径对每篇文档调用模型一次。

3.2 根据源文本生成图

规则修正明确的结构错误；语言模型从文本中读取取值，并返回有序三元组列表：

$$C = L_\theta(X, h_0, \mathcal{R}_X, G_s, D(G_s, X)). \tag{3}$$

提示要求模型生成完整图，复制来源值，保留正确字段，并补充或修正缺失、错误的值。JSON 解析器将无效响应记为空图。这些空图也计入评分。基础提示使用相同输入和输出上限，但去掉错误报告。

3.3 检查生成的三元组

约束决定哪些候选三元组进入修复后的图。门控是一个过滤器，在允许字段下保留与来源匹配的值，并保证每种关系最多有一个值。令 $\mathrm{uniq}(C)$ 按输出顺序去重。通过检查的三元组为

$$C_X = \{t \in \mathrm{uniq}(C) : H(t)R(t)S(t; X) = 1\}. \tag{4}$$

允许的输出集合为

$$\mathcal{F}(C_X) = \left\{ A \subseteq C_X : \sum_{t \in A} \mathbf{1}[r_t = r] \le 1,\ \forall r \in \mathcal{R}_X \right\}. \tag{5}$$

式 4 规定证据和模式要求，式 5 规定字段数量上限。两者共同决定过滤器可以保留哪些输出。

过滤器按顺序扫描候选，保留每个字段的第一个有效值。输出 $\widehat{G}$ 的大小为

$$|\widehat{G}| = \max_{A \in \mathcal{F}(C_X)} |A| = |\{r : \exists t \in C_X,\ r_t = r\}|. \tag{6}$$

每个字段构成一组，每组最多放一条三元组。只要该组中有有效候选，过滤器就保留其中一条。因此，它保留了允许范围内数量最多的候选。同一字段有多个值通过检查时，按输出顺序取舍。

3.4 字段含义与来源行

来源证据还帮助模型在相邻取值中作出选择。收据可能同时列出品牌、公司、小计和最终金额。我们为每个字段提供简短含义，引导模型选择。所有收据修复方法都获得这些字段含义和带行号的原文。

来源行索引为各字段增加提示。固定模式查找公司词、地址词、邮政编码、日期和总额标签。每条匹配行都是锚点。索引包含锚点行、前一行及后两行。简单流程获得完整原文和字段含义。证据索引 还获得这些行提示。

收据过滤器与解析器使用相同空白规则。$N(s)$ 将连续空格或换行变成一个空格，并去掉首尾空白。来源检查为

$$S_{\mathrm{ws}}(t; X) = \mathbf{1}[|N(o)| > 0 \ \wedge \ N(o) \text{ 出现在 } N(X)]. \tag{7}$$

这一处理保留词边界、大小写和标点。收据后续测试使用该检查，早期测试使用原来的精确文本检查。

4 实现

实现部分将检查转成修复步骤。第 4.1 节介绍主生成与过滤路径。第 4.3、4.4 节介绍单独测试的编辑选择路径。

4.1 修复步骤

算法 1 给出 诊断＋门控。诊断 指错误报告，门控 指三元组过滤器。程序构建报告并执行检查，模型提出字段值，过滤器返回修复后的图和拒绝日志。

运行程序将原文、文档编号、允许关系和输入三元组传给模型。评分器加载参考值。测试通过改变参考值和缺陷标签，确认模型输入保持一致。旧加载器从参考记录中读取文档编号，作为任务信息。

采用哈希查找时，清理平均需要 $O(|G|)$ 次三元组操作。过滤 k 个候选的时间为 $O(k(1 + c_X))$，额外内存为 $O(k + |\mathcal{R}_X|)$。这里，c_X 表示在文本中查找一个值的成本，文本长度会影响这一成本。模型调用耗时与这些检查分别统计。

算法 1 利用源文本和字段检查进行修复

输入：　输入三元组 G、原文 X、文档编号 h_0、允许关系 $\mathcal{R}_X$
输出：　修复图 $\widehat{G}$ 和拒绝日志 J

$G_s \leftarrow P(G; h_0, \mathcal{R}_X)$
$D \leftarrow D(G_s, X)$
$C \leftarrow \mathrm{Parse}(L_\theta(X, h_0, \mathcal{R}_X, G_s, D))$
$\widehat{G} \leftarrow \emptyset$; $J \leftarrow \emptyset$; $B \leftarrow \emptyset$
对 按生成顺序遍历候选 $t = (h, r, o)$ 执行
    若 t 之前已在 C 中出现 则
        将 $(t,$ 重复$)$ 加入 J
    否则 若 $H(t)R(t)S(t; X) = 1$ 且 $r \notin B$ 则
        $\widehat{G} \leftarrow \widehat{G} \cup \{t\}$; $B \leftarrow B \cup \{r\}$
    否则
        将 $(t,$ 未通过检查$)$ 加入 J
    结束 若
结束 对
返回 $\widehat{G}, J$

4.2 提示与规则设置

4.2.1 共享提示与响应

同一个系统提示支持基础输入、错误报告和 SHACL 检查三种设置。每个输入调用三次，得到三个响应。每个响应在过滤前后分别计分，共得到六个分数。每个过滤前后对照使用相同三元组。这样，在衡量过滤器时，候选生成保持固定。

模型为 `google/gemma-4-26B-A4B-it`，温度为零。每种设置的输出上限均为 4,000 个 token。提示长度不同，因此我们报告输入 token 数。请求时间包含重试和请求间隔等待。所有响应均保存，无效响应也计分。较早的 Claude 测试为每种方法使用独立提示。

4.2.2 SHACL 提示基线

Lin 等人使用五部分提示：引言、检测到的错误、SHACL 规则、图上下文和指令 (Lin et al. 2025)。我们将其完整规则与完整图（$M + G$）设置用于字段任务。pySHACL 工具检查文档编号、允许关系、非空值和字段数量。SPARQL 规则根据原文检查取值。

提示包含完整原文，并返回完整 JSON 图。每篇文档的错误合并到一次调用中。我们将该基线称为*Lin 风格 SHACL 上下文（改编版）*。RDF 保存唯一三元组，共享 JSON 输入保留重复副本。每种提示设置的输出都在过滤前后计分。

4.3 尺度感知路由与编辑动作

编辑选择器必须决定下一步修改图中的哪一部分。多项编辑可能针对同一字段，也可能撤销另一项编辑。选择器利用评估概况权衡这些选择。尺度感知路由为局部、图和来源编辑赋予权重。试改检查再比较各项收益与成本。图 2 展示这条路径。

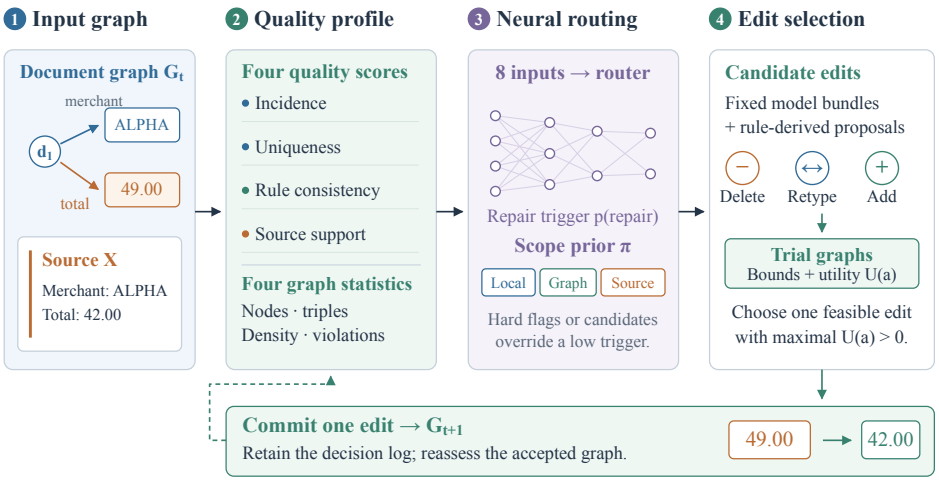


图 2 用于编辑选择的尺度感知路由。评估概况和图统计量输入路由器，得到修复分数和三个编辑范围的权重。选择器在图副本上尝试模型与规则编辑，执行最佳允许正分编辑，再次检查。

4.3.1 评估概况与共享输入

选择器的评估概况使用四个分数，分别衡量节点连接、三元组唯一性、规则一致和来源支持：

$$\begin{aligned} \mathbf{s} &= (Q_{\text{inc}}, Q_{\text{uniq}}, Q_{\text{rule}}, Q_{\text{src}}), \\ Q_i &= 100(1 - r_i), \quad Q = \tfrac{1}{4} \sum_i Q_i. \end{aligned} \tag{8}$$

每个 r_i 是对应检查的错误率。对于非空图，各错误率为

$$r_{\text{inc}} = \frac{I}{n}, \quad r_{\text{uniq}} = \frac{m - c}{m}, \quad r_{\text{rule}} = \frac{B}{m}, \quad r_{\text{src}} = \frac{V}{m}. \tag{9}$$

I 为无连接节点数，c 为三元组相似组数。B 为被图规则标记的不同三元组数。V 为去掉空白后仍未在文本中出现的值的数量。这里，n、m 分别为节点数和三元组数。这些分数为比较试改图提供统一尺度。空图的节点连接分为零，其余三项为 100。非空图没有源文本时，来源分为 50。

三元组相似度使用主体、关系和值的字符对计数。三部分余弦相似度的权重为 0.4、0.2、0.4。相似度达到 0.92 的三元组对组成相似组，用于唯一性评分。层级检查使用管理、监督和成员关系的方向，跳过含义不明确的关系。实体检查作用于标记为实体引用的端点，其他字段值按文本处理。

评估概况也报告来源字段缺失。来源字段检查读取文档、行或句子开头的允许标签之后的值。当原文给出一个字段而图中缺少它时，增加一个候选。重复标签给出冲突值时，跳过该字段。这些报告进入违规计数和候选列表。

路由器接收四项分数和四个图统计量：

$$\mathbf{g} = (n, m, \rho, n_{\text{viol}}), \qquad \rho = \frac{|E_{\text{pair}}|}{n(n-1)} \quad (n > 1). \tag{10}$$

这里，n、m 分别为节点数和三元组数。E_{pair} 包含不同的有向节点对，不含自连接。$n \le 1$ 时密度为零。n_{viol} 是报告的违规数。主报告 D 列出字段错误，$\mathbf{s}$ 为选择器的图打分。两者都是评估概况，分别用于各自的修复路径。

4.3.2 路由器与训练信号

路由器将这八个输入转成修复分数和范围权重：

$$(p_{\text{repair}}, \boldsymbol{\pi}) = f_\phi(\text{scale}([\mathbf{s}; \mathbf{g}])). \tag{11}$$

scale 使用训练集均值和标准差。$\boldsymbol{\pi}$ 有三个非负权重，合计为一，分别对应实体、图和上下文编辑。网络层大小为 $8 \to 32 \to 16$，具有一个修复输出和三个范围输出，共 884 个参数。两个隐藏层均使用 ReLU。sigmoid 给出修复分数，softmax 给出范围权重。训练和使用时共用特征代码。特征版本不匹配时，路由器改用等权重。

训练标签来自已知注入缺陷。损坏图的修复标签 y_j 为一，其干净配对图的标签为零。范围标签 c_j 取图中最常见的缺陷范围。干净图只训练修复输出。损失为

$$\begin{aligned} \mathcal{L}(\phi) = \frac{1}{N} \sum_j \text{BCE}(p_j, y_j) \\ + \frac{\sum_j b_j (-\log \pi_{j,c_j})}{\sum_j b_j + \epsilon}. \end{aligned} \tag{12}$$

有范围标签时，b_j 为一；ϵ 避免除零。第一项训练修复分数，第二项用损坏图训练范围权重。同一文档组只属于训练、验证或测试中的一个划分。选择器根据任务输入和源文本计算特征。

4.3.3 候选编辑与成本

规则和模型建议提供候选编辑。选择器可以删除三元组、改变关系或添加三元组。改变关系在代码中称为 retype。相关编辑可以组成一个包。在保存建议测试中，清理后输入与模型输出之间的差异按关系分组。每组是一个置信度为 0.7 的编辑包。

编辑成本鼓励小幅修改：

$$c(a) = \begin{cases} 0.30 & \text{删除}, \\ 0.16 & \text{改关系}, \\ 0.06 & \text{添加}. \end{cases} \tag{13}$$

编辑包的成本是其中各项编辑成本之和。这些固定成本与质量增益、范围权重一起进入试改分数。学习先验测试将路由器与始终开启的等权先验比较。

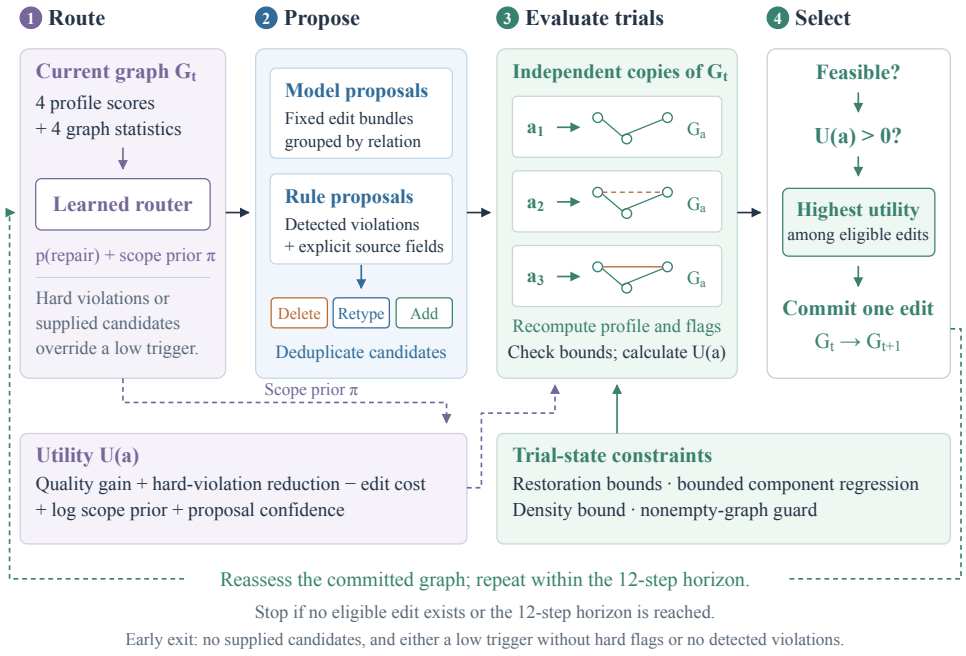


图 3 一轮试改检查。路由器为编辑范围赋权，选择器在图副本上为每项模型或规则编辑打分、检查边界，并执行最佳允许正分编辑。随后重新构建评估概况。保存建议测试最多允许十二轮。

4.4 试改检查与修复循环

执行编辑前，先在图副本上试做每个候选。令 G_a 为试改图，h 为硬规则错误数，$\sigma(a)$ 为编辑范围，$z(a)$ 为候选置信度。默认分数为

$$U(a) = \frac{Q(G_a) - Q(G)}{100} + 0.20\frac{\max(0, h(G) - h(G_a))}{\max(1, h(G))} - 0.35c(a) + 0.05\log\left(\max(\pi_{\sigma(a)}, 0.05) + 10^{-6}\right) + 0.02z(a). \tag{14}$$

各项分别衡量质量增益、规则错误减少、编辑成本、范围权重和候选置信度。试改重新计算完整图的评估概况，并检查分数边界、密度，以及编辑是否会把图删空。

四项分数的下界依次为 55、55、60、45。已经满足的下界必须继续满足。低于下界的分数必须保持或提高。在这些条件下，每项检查分数最多下降两分。试改后密度最多为 0.75，非空图必须保持非空。这些要求确定允许的试改集合 $\mathcal{A}_t^{\mathrm{ok}}$。选择步骤为

$$a_t^* = \arg\max_{a \in \mathcal{A}_t^{\mathrm{ok}}} U(a), \qquad U(a_t^*) > 0. \tag{15}$$

式 15 在当前试改编辑中作出选择。边界决定哪些编辑允许执行，分数为允许编辑排序。没有允许编辑获得正分时，图保持原样。

算法 2 连接评估、路由和执行。即使修复分数较低，只要存在已提供的候选或硬规则错误，也会开始试改检查。当没有有用的允许编辑、不再需要试改，或达到步数上限时，循环结束。日志保存试改图、分数、决策和停止原因。

算法 2 带试改检查的尺度感知编辑选择

输入：　输入图 G、原文 X、已提供候选 A_0、任务输入、步数上限 T
输出：　修复图 $\widehat{G}$ 和决策日志 J

$\widehat{G} \leftarrow G$; $J \leftarrow \emptyset$; $E \leftarrow \emptyset$
将缺失来源字段的候选加入 A_0
对 $t = 1$ 到 T 执行
    为 $\widehat{G}$ 计算评估概况和 $(p_{\text{repair}}, \boldsymbol{\pi})$
    若 $A_0 = \emptyset$、$h(\widehat{G}) = 0$ 且 $p_{\text{repair}} < \tau_{\text{repair}}$ 则
        退出循环
    结束 若
    若 没有报告的违规且 $A_0 = \emptyset$ 则
        退出循环
    结束 若
    $A \leftarrow \text{Unique}(A_0 \cup \text{RuleEdits}(\widehat{G}))$
    跳过已在 E 中的图与候选组合
    对其余每个 $a \in A$ 在副本上试改，并将组合记入 E
    为每次试改检查图边界并计算 $U(a)$
    将试改分数和决策加入 J
    若 没有允许候选满足 $U(a) > 0$ 则
        退出循环
    结束 若
    对 $\widehat{G}$ 执行 $U(a)$ 最高的允许编辑
结束 对
返回 $\widehat{G}, J$

保存建议测试使用 $T = 12$ 和 $\tau_{\text{repair}} = 0.05$。第二种评分从默认分数中减去 $0.05 \log(1/3 + 10^{-6})$。这样，等权重的先验项为零。对于固定路由器，它保留编辑排序，但改变正分接受门槛。两种评分均在保存建议测试前固定。该选择器的来源匹配去掉两个字符串中的空白。档案也保留使用其他空白规则的早期日志。算法 1 和选择器分别测试。

对于 m 条三元组，两两检查的成本为 $O(m^2)$。T 轮、每轮最多 K 次试改的成本为 $O(TKm^2)$，另加文本检查成本。主过滤器只扫描候选列表一次。

5 实验评价

我们在注入缺陷、模型构建图、收据文本和合同字段上测试修复。共享提示用于测试上下文，过滤前后的评分用于测试门控，人工评审检查参考差异和实际编辑。本文提出三个问题：**RQ1**：修复何时能改善图？**RQ2**：上下文、过滤和编辑选择各改变了什么？**RQ3**：已有图何时比重新抽取更有用？表 12 汇总结果。

表 1 注入缺陷测试数据。最后三列为文档数。

领域	文档数	缺陷数	训练	验证	测试
政务	499	998	349	75	75
金融	500	1,000	350	75	75
环境	500	1,000	350	75	75
总计	1,499	2,998	1,049	225	225

5.1 测试设置

来源记录与注入缺陷。

来源数据包含陕西省人民政府的 4,728 条政务记录、国家金融监督管理总局的 1,000 条金融记录，以及生态环境部的 500 条环境记录。我们从每个来源最多抽取 500 篇文档，为每篇构建字段图。

源文本以“字段名：值”列出非空字段，用中文句号连接。每个值最多 320 个字符，服务标签最多 100 个字符。相同的清理后取值构成参考三元组。我们用随机种子 42，按 70/15/15 将文档划分为训练、验证和测试集。在加入缺陷前按来源编号划分，同一原始文档及其修改副本属于同一组。

每张测试图恰好加入两个缺陷。六种缺陷为三元组缺失、三元组重复、非法关系、反向边、无来源支持的值和层级冲突。保存的数据列出每条干净和修改后的三元组。测试集有 225 篇文档，每个来源 75 篇，共 450 个缺陷（表 1）。

模型构建的图。

Claude Haiku 为相同的 225 篇测试文档分别构建新图。输入为源文本、文档编号和允许关系。评分器将结构化字段作为参考值。十个响应的 JSON 无效，按空图计分，解析成功率为 95.56%。共有 77 张图与参考不同，包含 302 项三元组差异。两名评审检查其中固定抽样的 200 项差异，第三名评审解决分歧（第 5.10 节）。

修复方法。

所有方法获得相同输入图、源文本、文档编号和允许关系。

- **来源字段复制**：读取字段标签，直接从文本复制值。
- **不修复**：返回输入。
- **仅规则**：去重，将指向文档节点的边反向，删除非法头节点和关系。
- **SHACL 风格修复**：使用 SHACL 形状约束检查文档头节点和允许关系(Knublauch and Kontokostas 2017)。
- **直接调用模型**：调用一次模型，根据原文返回完整图。
- **ReAct 风格智能体**：一次调用查找错误，另一次调用执行修复(Yao et al. 2023)。
- **简单流程**：清理输入，调用一次模型，并对响应去重。
- **诊断+门控**：在提示中增加错误报告，按文档编号、关系、来源匹配、重复数量和每字段值数量过滤输出。

除另行指定模型外，模型方法均在同一端点使用 `claude-haiku-4-5-20251001`(Anthropic 2025)，温度为零。所有分数均包含失败调用。注入

表 2 225 篇测试文档、450 个注入缺陷上的修复结果。过度修复、调用数和请求时间越低越好。

方法	缺陷修复	事实保留	过度修复	三元组 F1	整图匹配	调用／篇	耗时／篇
来源字段复制	**1.0000**	**1.0000**	**0.0000**	**1.0000**	**1.0000**	0.00	< 0.001 s
不修复	0.0000	**1.0000**	**0.0000**	0.7615	0.0000	0.00	< 0.001 s
仅规则	0.3200	**1.0000**	**0.0000**	0.8472	0.0622	0.00	< 0.001 s
SHACL 风格修复	0.0000	**1.0000**	**0.0000**	0.7998	0.0000	0.00	< 0.001 s
直接调用模型	0.9244	0.9687	0.0758	0.9520	0.8267	1.00	7.25 s
ReAct 风格智能体	0.8911	0.9324	0.1667	0.9213	0.5956	2.00	20.50 s
简单流程	0.9511	0.9723	0.0705	0.9634	0.8400	1.00	9.27 s
诊断＋门控	0.9800	0.9932	0.0167	0.9917	0.9333	1.00	11.44 s

缺陷测试中，直接调用模型 和 简单流程 各有一个无效 JSON 响应，诊断＋门控 和 ReAct 均为零。

评分与统计检验。

当输出恢复各条干净三元组的数量，并去掉其修改形式时，该缺陷视为修复。我们还衡量正确事实保留、过度修复、三元组 F1、整图精确匹配、调用次数和请求时间。整图精确匹配同时检查三元组与重复数量。

令 G_0 为模型构建的输入图，G_1 为修复图，G^* 为参考图。令 d 统计多余和缺失的三元组，包括重复副本。参考差异减少率为

$$1 - \frac{d(G_1, G^*)}{d(G_0, G^*)},$$

该指标在 77 个与参考不同的输入上取平均。负值表示输出差异变多。事实保留和过度修复也按参考三元组计算。人工分数衡量评审是否发现错误、是否接受编辑。

置信区间（CI）使用 10,000 次配对 bootstrap 抽样。匹配测试每次抽取完整文档，使同一文档的两个注入缺陷保持在一起。配对符号随机化检验使用 10,000 次抽样和种子 42。较早的缺陷与整图匹配比较使用精确 McNemar 检验。模型输出差异数还使用单侧配对 Wilcoxon 检验。

首次匹配上下文测试使用未校正的 p 值。后续组件、收据上下文和保存响应测试按各表所列分组进行 Holm 校正。每个 95% 置信区间对应一个比较，Holm 校正作用于同一检验组的 p 值。

5.2 注入缺陷修复

诊断＋门控 修复 98.00% 的缺陷，保留 99.32% 的干净事实，F1 达 99.17%（表 2）。简单流程 使用相同的一次调用上限，修复率为 95.11%，F1 为 96.34%。诊断＋门控 修复了 简单流程 漏掉的 15 个缺陷；简单流程 修复了 诊断＋门控 漏掉的两个缺陷（McNemar $p = 0.00235$）。配对修复率增益为 2.89 个百分点（95% 置信区间：1.11–4.89；$p = 0.0067$），F1 增益为 2.84 个百分点（95% 置信区间：1.65–4.25）。直接调用模型 的修复率为 92.44%。来源字段复制 直接读取记录中的字段名和值，不调用模型，修复率和整图匹配均为 100%。

诊断＋门控 修复了 直接调用模型 漏掉的 28 个缺陷；直接调用模型 修复了 诊断＋门控 漏掉的三个缺陷（$p = 4.65 \times 10^{-6}$）。与 ReAct 比较时，两项计数分别为 42 和二（$p = 1.13 \times 10^{-10}$）。这些检验比较完整修复方法，第 5.4 节再测试其中步骤。

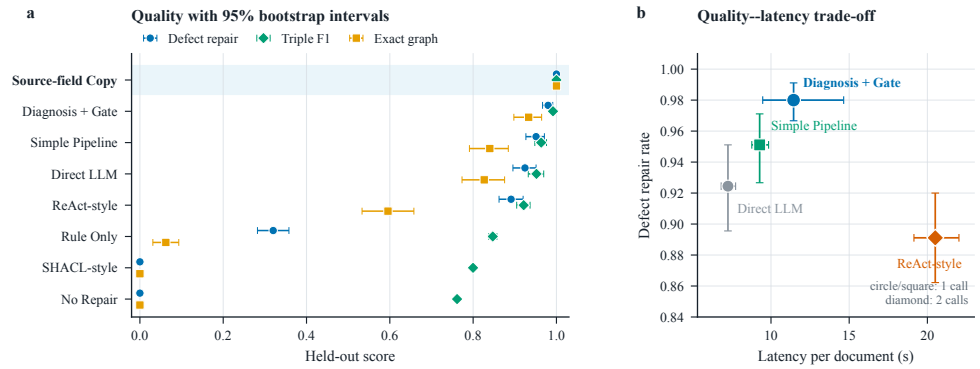


图 4 注入缺陷修复。**a**：修复率、三元组 F1 和整图匹配，带基于文档抽样的 95% 置信区间。**b**：一次或两次调用方法的分数与请求时间。

表 3 模型构建图的修复。差异减少率使用 77 个与参考不同的输入，其余分数使用全部 225 篇文档。

方法	解析率	非精确输入	差异减少率	事实保留	过度修复	三元组 F1	整图匹配
来源字段复制	1.0000	77	1.0000	1.0000	0.0000	1.0000	1.0000
抽取图，不修复	0.9556	77	0.0000	1.0000	0.0000	0.8799	0.6578
简单流程	1.0000	77	−0.5915	0.9971	0.2389	0.8807	0.6711
诊断＋门控	0.9956	77	0.2775	1.0000	0.0292	0.9248	0.6844

5.3 模型构建图的修复

输入图的 F1 为 87.99%，整图匹配为 65.78%（表 3）。诊断＋门控 将 F1 提高到 92.48%，参考差异减少 27.75%，并保留全部原本匹配参考的输入三元组。简单流程 在 77 个有差异输入上的平均差异减少率为 −59.15%，增加的差异多于去掉的差异。

诊断＋门控 的 F1 比 简单流程 高 4.40 个百分点（95% 置信区间：3.07–5.77），平均每篇少 1.03 项差异（95% 置信区间：0.77–1.32；Wilcoxon $p = 3.18 \times 10^{-12}$）。三个图在 诊断＋门控 下完全匹配参考，在 简单流程 下不匹配；反向情况为零（$p = 0.25$）。来源字段复制 匹配全部参考。

有效与无效 JSON 输入。

215 个有效 JSON 输入的 F1 为 92.09%。诊断＋门控 达到 93.53%，简单流程 为 88.85%。67 个有效但有参考差异的输入中，诊断＋门控 使差异减少 24.00%，F1 从 74.61% 提高到 79.22%。148 个原本精确匹配的图全部保持精确匹配。十个无效输入修复后的 F1 为 69.91%，没有一个整图精确匹配。

5.4 提示、过滤与编辑选择器测试

我们依次测试提示文本、过滤和编辑选择。在保存的 Claude 响应上，过滤将 F1 从 98.95% 提高到 99.17%，过度修复降低 0.60 个百分点。修复率保持 98.00%，整图匹配保持 93.33%。过滤器去掉八条三元组，均未通过来源检查且与参考不同。附录 A.1 给出完整方法表。

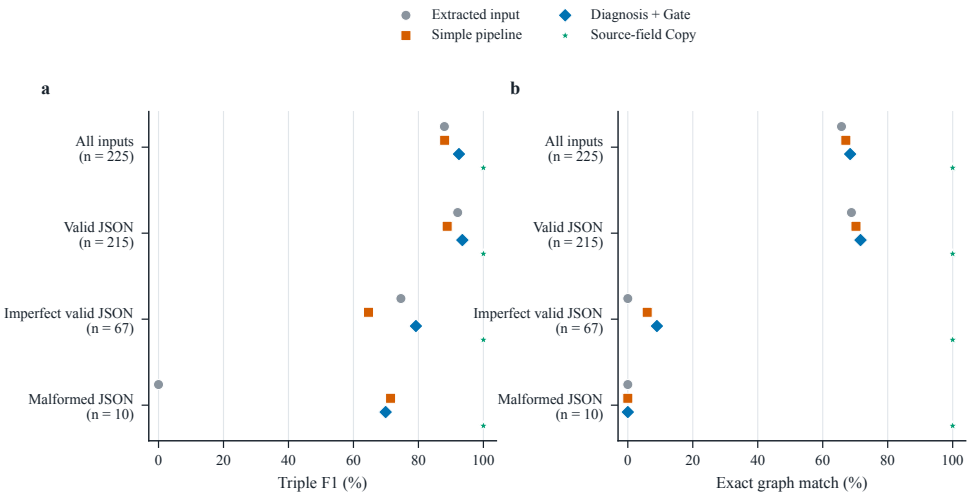


图 5 按输入类型划分的修复分数。有效 JSON 组展示可解析图的修复，无效 JSON 组展示空输入的恢复。

表 4 Gemma 提示测试，每组输入 60 篇文档。每个原始／过滤对照使用同一响应。

上下文	输出	受控修复	受控 F1	模型构建 F1	模型构建整图匹配
基础提示	未过滤	0.9750	0.9951	0.9185	0.6667
基础提示	门控	0.9750	0.9962	0.9252	0.6667
诊断提示	未过滤	0.9250	0.9850	0.9079	0.6667
诊断提示	门控	0.9250	0.9861	0.9147	0.6667
SHACL 上下文	未过滤	0.9500	0.9912	0.9322	0.7000
SHACL 上下文	门控	0.9500	0.9912	0.9364	0.7000

Gemma 测试使用 60 篇文档，每个来源 20 篇，分别测试注入缺陷输入和模型构建输入。三个提示共享指令、清理步骤、温度和输出上限。每个响应在同一门控过滤前后计分。表 4 给出六种设置，表 20 给出输入 token 数和请求时间。第 4.2.2 节给出 SHACL 提示。

经过过滤，基础提示在注入缺陷输入上达到 99.62% F1 和 97.50% 修复率。错误报告提示为 98.61% F1 和 92.50% 修复率。配对 F1 变化为 -1.01 个百分点（95% 置信区间：$[-1.67, -0.38]$；$p = 0.0082$）。模型构建输入上，基础提示 + 门控 的 F1 为 92.52%，诊断＋门控 为 91.47%，SHACL 上下文＋门控 为 93.64%。诊断 与 SHACL 的 F1 差为 -2.16 个百分点（95% 置信区间：$[-5.26, 0.02]$；$p = 0.105$）。

在使用错误报告提示的模型构建输入上，过滤将 F1 从 90.79% 提高到 91.47%，增益为 0.69 个百分点（95% 置信区间：0.20–1.29；$p = 0.0335$），整图匹配保持相同。360 个响应共拒绝 27 条三元组，均与参考不同。

联合测试清理、错误报告与过滤。

我们分别开启或关闭输入清理（P）与错误报告（D）。四种提示设置使用 60 个注入缺陷输入和 60 个模型构建输入，得到 480 个 Gemma 响应。每个响应分别在启用和关闭门控（G）时计分。每项主效应都对另外两个开关取平均。

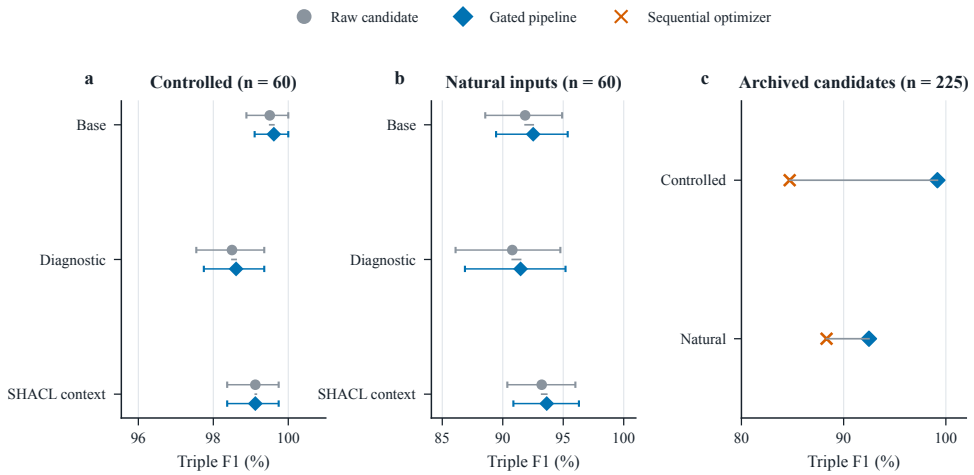


图 6 提示、过滤和选择器测试。a–b 使用 60 篇文档的 Gemma 输出；每个原始／过滤对照使用同一响应，误差线表示 95% 文档 bootstrap 置信区间。c 使用 225 篇文档保存的 Claude 建议。

表 5 平均 F1 变化，单位为百分点。每组输入有 60 篇配对文档，各效应对另外两个开关取平均。区间为 95% 文档 bootstrap 置信区间。p_H 对六项主效应检验进行 Holm 校正。

输入	组件	变化	95% 区间	p_H
受控输入	预处理	-0.028	[-0.797, 0.778]	1.000
受控输入	诊断	-0.651	[-1.348, -0.056]	0.164
受控输入	门控	+0.164	[0.054, 0.301]	0.156
模型构建输入	预处理	+0.697	[0.000, 1.905]	1.000
模型构建输入	诊断	-0.535	[-2.376, 0.842]	1.000
模型构建输入	门控	+0.707	[0.225, 1.316]	0.086

六项 Holm 校正后的 p 值均大于 0.05（表 5）。错误报告在两组输入中都降低平均 F1。门控在注入缺陷输入上提高 0.164 个百分点，在模型构建输入上提高 0.707 个百分点。所有输入组共拒绝 47 条三元组，其中 17 条文档编号错误，30 条未通过来源匹配，均与参考不同。公开分数还列出开关联合效应和每项检查去掉的候选。

各项过滤检查。

我们将 540 个已保存响应经过八种过滤设置，得到 4,320 个输出。完整过滤器拒绝 28 条三元组，其中 11 条文档编号错误，17 条来源匹配失败，均与参考不同。其他检查在该样本中未额外去掉候选。21 项检查比较的校正后 p 值均大于 0.05。附录 A.2 给出结果表。

编辑选择。

在保存的 Claude 建议上，默认选择器无论使用学习权重还是等权重，在注入缺陷输入上都接受零项编辑。修复率保持 32.00%，F1 保持 84.72%，与清理后输入相同。

表 6 两个模型在相同 60 个注入缺陷输入上的结果。

模型	方法	修复率	F1	精确匹配
Claude	直接	0.958	0.970	0.867
Claude	简单流程	0.958	0.966	0.833
Claude	**诊断+门控**	**0.975**	**0.991**	**0.917**
Gemma	直接	0.958	0.988	0.883
Gemma	简单流程	0.967	0.984	0.867
Gemma	**诊断+门控**	**0.983**	**0.990**	**0.917**

v2 运行中，模型构建输入的等权重 F1 为 88.33%，学习权重为 87.99%，学习触发器也为 87.99%。去掉编辑成本将注入缺陷 F1 提高到 89.30%，该设置的模型构建 F1 为 88.13%。日志显示，一些评估分数较高的图仍缺少字段。某些有用的添加得到不大于零的分数，因而被拒绝。附录 A.2 给出全部 13 种设置、两种先验评分形式和 11,700 个结果。附录 A 还给出早期选择器结果和调用策略测试。

5.5 两个模型的测试

我们在 60 个注入缺陷输入上比较 直接调用模型、简单流程 和 诊断+门控，每个来源 20 个。模型为 Claude Haiku 和 `google/gemma-4-26B-A4B-it`(Gemma Team 2026)。每种方法跨模型使用相同输入、提示形式、温度和一次调用上限。诊断+门控 在两个模型上的修复率均最高（表 6）。它相对 简单流程 的 F1 优势在 Claude 上更大。Gemma 直接输出的 F1 高于 Claude。

5.6 新收据上的来源行提示

我们使用 SROIE 收据(Huang et al. 2019)。首次 60 张收据测试中，基础提示和错误报告提示都保留全部输入图不变。过滤将 F1 从 79.44% 降到 79.15%。一个地址因空白与来源不同而被拒绝。49 项参考差异中，有 27 项涉及大小写、空白、标点或金额格式（附录 A.3）。据此，我们加入字段含义、来源行提示和共享空白规则。

我们用 20 张新收据设置索引设计，然后固定设计，在另外 60 张收据上测试（第 3.4 节）。首次 60 张、开发 20 张和新测试 60 张收据的编号不同，空白清理后的文本也不同。抽样种子为 20260923。所有预测保存后才下载测试标签。每种方法得到相同字段含义、带行号原文、输入图和指令。简单流程 直接使用这些输入；证据索引 增加字段行提示；SHACL 增加规则检查上下文。三种方法的过滤器使用相同空白规则。

开发集 F1 为：输入 80.00%，简单流程 82.50%，证据索引 85.00%，SHACL 80.00%。测试保留一个索引设计和全部三种方法。主要比较为 证据索引 减 简单流程 的文档平均 F1。代码和评分规则在测试前固定。

新测试集的输入 F1 为 78.33%。过滤后 简单流程、证据索引、SHACL 分别为 78.75%、83.51%、78.33%。简单流程 比输入高 0.42 个百分点（95% 置信区间：$[-4.17, 5.00]$）。证据索引 比 简单流程 高 4.76 个百分点（95% 置信区间：$[2.50, 7.26]$；配对随机化 $p = 0.0004$）。三种方法的整图匹配分别为 28.33%、40.00%、28.33%。

表 7 60 张新收据的修复。各方法共享字段含义、来源行和空白检查。精确匹配使用有标签字段。

方法	三元组 F1	整图匹配	规范化 F1	事实保留
抽取输入	0.7833	0.3500	0.7958	1.0000
简单流程, 未过滤	0.7875	0.2833	0.8083	0.9250
简单流程, 过滤后	0.7875	0.2833	0.8083	0.9250
证据索引, 未过滤	0.8333	0.4000	0.8625	0.9306
证据索引, 过滤后	0.8351	0.4000	0.8643	0.9306
SHACL 上下文，未过滤	0.7833	0.2833	0.8042	0.9347
SHACL 上下文，过滤后	0.7833	0.2833	0.8042	0.9347

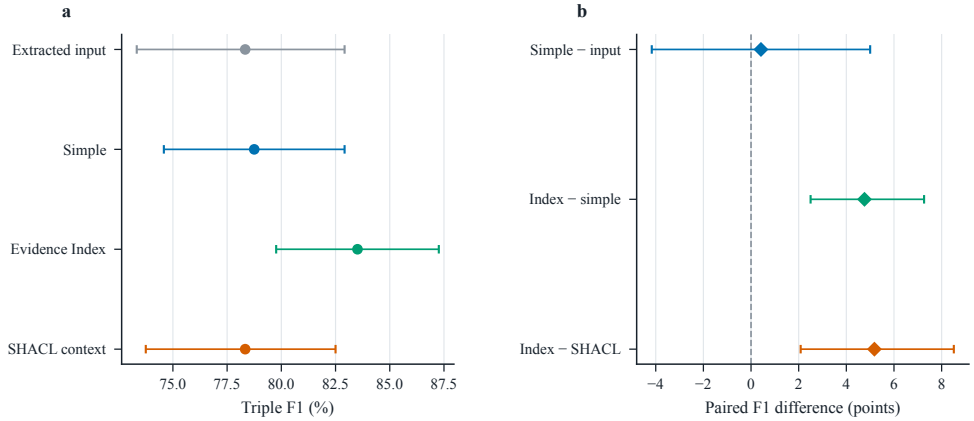


图 7 新收据测试。左：平均 F1 及 95% 文档 bootstrap 置信区间。右：配对 F1 变化。所有方法共享字段含义和来源行。

输入有 52 个字段与参考不同。简单流程 恢复其中 16 个，并丢失 15 个原本精确匹配的字段。证据索引 恢复 26 个、丢失 14 个；SHACL 恢复 13 个、丢失 13 个。索引修正了 11 项标点差异和 6 项文本边界差异。它丢失的 14 个精确匹配中，有 10 个数值金额相同，只改变显示格式。

金额检查去掉总额字段中的货币前缀和千位分隔符。正确金额数为：输入 58/60，简单流程 59/60，证据索引 59/60，SHACL 58/60。清理大小写和空白后，证据索引 的 F1 为 86.43%，简单流程 为 80.83%。索引同时提高精确和清理后文本分数。

过滤器拒绝 1 个候选。它与参考不同，并将地址片段拼成原文中没有的文本。被拒绝的参考匹配候选数为 0。过滤使索引 F1 提高 0.18 个百分点，另外两种方法的 F1 保持不变。

简单流程、证据索引、SHACL 分别修改 31、39、28 个输入图。平均修复请求时间为 7.91、7.88、8.11 秒，平均输入长度为 1784、2153、3404 个 token。240 次请求产生 60 个抽取输出和 180 个修复输出。请求时间包含间隔等待和重试。每个原始与过滤后评分对只使用一个响应。

表 8 60 张收据上的来源行测试。各行使用相同模型、原文、输出上限和过滤器。随机提示与索引的字符长度大致相同。

上下文	精确 F1	规范化 F1
简单流程	0.7917	0.8125
完整索引	0.8351	0.8643
仅锚点	0.8351	0.8643
随机索引	0.8167	0.8458
简单流程，无字段定义	0.8083	0.8292
完整索引，无字段定义	0.7470	0.7762

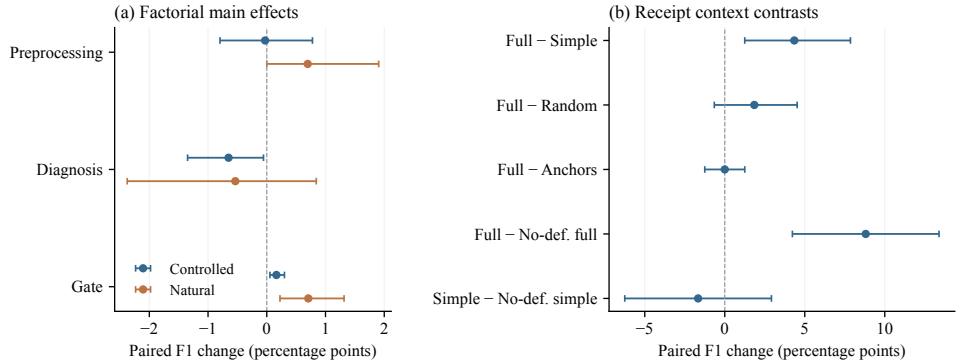


图 8 组件与来源行测试。点表示平均配对 F1 变化，误差线为各项变化的 95% 置信区间。组件测试与收据测试分别进行 Holm 校正。

5.7 来源行提示对照

我们在相同 60 张新测试收据上比较六种提示设置。测试使用与组件测试同批的 360 个新 Gemma 响应，全部解析成功。各设置都保留完整原文，并共享模型、输出上限和过滤器。随机索引的字符长度与完整索引大致相同。

完整索引的 F1 比 简单流程 高 4.35 个百分点（95% 置信区间：1.25 至 7.86）。五项预设比较的 Holm 校正值为 $p_H = 0.065$。完整索引与仅锚点行的平均 F1 相同。完整索引与随机索引相差 1.85 个百分点（置信区间：$[-0.65, 4.52]$；$p_H = 0.696$）。去掉字段含义使完整索引 F1 下降 8.81 个百分点（置信区间：$[4.23, 13.39]$；$p_H = 0.006$）。本批次 简单流程 去掉字段含义后得分更高。这些结果说明字段含义有助于索引提示选择取值。

5.8 修复与重新抽取

我们复用 60 张新测试收据，比较有无索引下的修复与重新抽取，共四种设置。各设置共享来源行、字段含义、文档编号和输出上限；修复额外获得已有图。全部 240 个响应都将 JSON 放在 Markdown 代码围栏中，固定的严格解析器将其计为失败。

表 9 56 份文档的合同结果。F1 检查空白清理后的精确文本。“丢失”统计被删除的正确输入事实。输入行给出初始图成本，修复行给出修复调用成本。

输出	F1 (%)	丢失	新增不匹配	请求数
初始抽取	46.76	0	0	59
简单流程修复	43.35	7	2	71
索引修复	44.84	5	12	69
索引重新抽取	44.12	8	32	71

随后，我们去掉代码围栏，并为每个输出指定已知文档编号，对相同响应重新计分。这项补充分析得到索引修复 F1 为 83.93%，索引重新抽取为 74.86%，配对差为 9.07 个百分点（95% 置信区间：5.22 至 13.10）。修复调用使用已有图，其构建成本另计。附录 A.4 给出严格评分、围栏清理评分、编号错误和来源行覆盖。合同测试在采集前固定围栏处理和编号分配。

5.9 合同字段测试

我们用 CUAD(Hendrycks et al. 2021) 测试五个字段：文档名称、签约日期、生效日期、到期日期或初始期限，以及适用法律。选择空白清理后每字段最多一个不同参考值、原文不超过 40,000 字符的合同。保留完整原文，并检查标注值的位置。20 份官方训练合同构成开发集；全部 56 份满足规则的官方测试合同构成测试集。

比较初始抽取、简单流程 修复、索引修复和索引重新抽取。两种修复方法得到相同初始图，索引方法在完整原文之外增加字段行窗口。各设置共享 Gemma 模型、字段含义和 4,000 token 输出上限。采集前，程序已设置 JSON 围栏处理和文档编号分配。一轮开发之后，提示与选择规则保持固定。

索引修复 F1 为 44.84%，输入为 46.76%，下降 1.92 个百分点。它删除五条正确输入事实，并增加十二条与参考不同的事实。简单流程 修复也低于输入。

索引修复的 F1 比索引重新抽取高 0.72 个百分点（95% 配对置信区间：[-4.80,6.48]；符号翻转检验 $p = 0.810$）。测试共用 270 次请求得到 224 个输出，包括重试。失败输出计为空图。评分在空白清理后，将复制文本与 CUAD 标签比较。

5.10 错误与编辑的人工评价

任务 D 从模型构建输入的 302 项三元组差异中抽取 200 项参考差异。任务 E 从五种设置的 598 项编辑中抽取 200 项实际编辑。两者都用种子 42 随机抽样。每项是一项差异或编辑，同一文档可提供多项。评审看到原文、模式、输入图和指定操作。任务 E 还展示完整输出图。方法名称与参考质量提示隐藏。

两名具有计算机背景和中文阅读能力的评审先阅读规则和练习样例，再各自独立标注相同的 400 项。每项回答两个问题：输入在该位置是否有错（`is_error`），以及添加或删除操作是否可接受（`repair_acceptable`）。标签为 0、1 或 U，并说明理由。U 表示所示证据不足以作出判断。第三名评审检查原文和图，在两人的答案中选择，解决 154 项分歧。其余 246 项保留一致标签。一项编辑接受判断仍为 U。原始标签和一致性分数均保留。

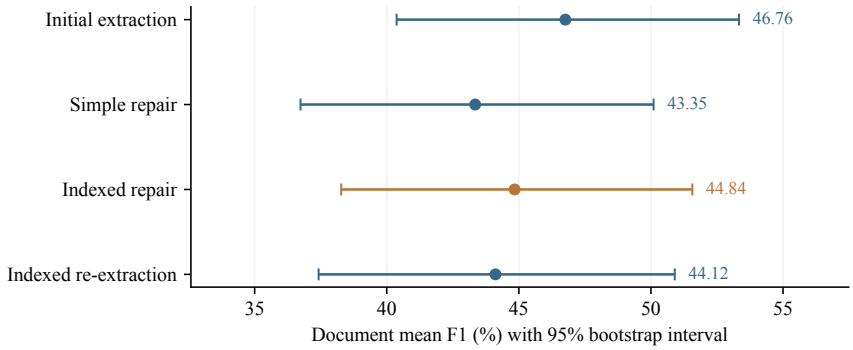


图 9 合同分数。点表示文档平均 F1，误差线为各方法的 95% 置信区间。正文给出修复与抽取的配对差值区间。

表 10 人工评分。一致率和 κ 使用两位评审原始的 0/1/U 答案。正例数使用最终标签，接受率使用答案为 0 或 1 的项目。

任务	判断	一致率	κ	正例／确定项	U
D	输入错误	80.0%	0.600	95/200 (47.5%)	0
D	建议编辑可接受	62.0%	0.334	86/200 (43.0%)	0
E	输入错误	86.0%	0.677	134/200 (67.0%)	0
E	实际编辑可接受	65.0%	0.128	134/199 (67.3%)	1

表 11 按设置划分的实际编辑接受率。随机样本的各组大小不同，比例使用有明确判断的编辑。

配置	抽样数	可接受	U
历史简单流程	105	63/104 (60.6%)	1
历史诊断＋门控	41	25/41 (61.0%)	0
Gemma 基础提示＋门控	16	13/16 (81.3%)	0
Gemma 诊断＋门控	16	13/16 (81.3%)	0
Gemma SHACL 上下文＋门控	22	20/22 (90.9%)	0

评审在 95/200 项参考差异中发现输入错误，接受 86/200 项建议编辑，以及 134/199 项实际编辑，另有一项不确定。一个缺失值本身可以是正确的，但添加后可能使仅允许一个值的字段出现两个值。输入错误与编辑接受问题分别覆盖这两个判断。任务 E 的原始编辑一致率为 65.0%，$\kappa = 0.128$。

样本包含 105 项 历史简单流程 编辑、41 项 历史诊断＋门控 编辑、16 项 Gemma 基础提示＋门控 编辑、16 项 Gemma 诊断＋门控 编辑，以及 22 项 Gemma SHACL 上下文＋门控 编辑。表中按各组报告被接受编辑的比例。

表 12 研究问题与测试结果。

问题	比较	结果
RQ1	注入缺陷与模型构建图	诊断＋门控改善修复率和 F1。直接复制匹配全部中文记录参考。
RQ2	共享提示与响应；来源行提示；编辑选择器	来源和编号检查去掉多余三元组。收据索引提高 F1。匹配测试中，错误报告降低平均 F1。模型构建输入上，等权选择器得分高于学习权重。
RQ3	收据、合同修复与重新抽取	收据测试在围栏和编号清理后倾向已有图。合同索引修复得分低于初始图。

5.11 讨论

来源格式影响修复方法的选择。对于列出字段名和值的记录，解析器可以直接复制字段；收据则需要从全文中选择取值。新收据测试中，来源行提示提高 F1。后续索引测试展示字段含义的作用：去掉后，索引 F1 下降 8.81 个百分点。合同索引修复 F1 为 44.84%，输入为 46.76%。保留正确输入字段是清楚的改进目标。

实验还展示过滤器改变了什么。来源和文档编号检查去掉多余三元组。字段选择发生在模型生成和首值规则中。例如，来源可能同时包含小计和最终金额，修复方法必须为“total”选出正确的一个。因此，检查需要同时考虑关系含义和取值是否出现在原文中。

人工评审接受五种设置合并样本中 67.3% 的编辑，并在 47.5% 的参考差异样本中发现输入错误。历史诊断＋门控 样本中，接受的编辑为 25/41。结合原始标签和理由，这些分数帮助定位字段选择与单项编辑决策中的错误。

5.12 代码与数据

代码、提示、数据名单、模型输出和评分脚本位于 https://github.com/turambar928/MCP_based_KG_construction。每次运行保存模型设置、解析状态、请求和 token 用量，全部响应均保留。各实验 README 给出数据来源、样本、校验值和运行命令。

人工评价文件包含固定任务规则、评分器、汇总结果、原始一致性分数和样本名单。个人答案与理由不公开。收据评分使用 SROIE 的人工字段标签。

6 结论

我们将图检查与利用源文本和字段约束的修复结合。评估概况记录局部、图和来源错误。主路径先清理输入，再请求模型生成完整图，最后过滤三元组。尺度感知选择器还在图副本上比较编辑，考虑质量增益、成本和图边界。共享提示以及过滤前后的评分展示各步骤带来的变化。

诊断＋门控 修复了 98.00% 的注入缺陷，并将模型构建图的 F1 从 87.99% 提高到 92.48%。直接字段复制恢复了中文记录中的全部参考。来源行提示使收据 F1 比简单流程 高 4.76 个百分点。后续测试中，完整索引与仅锚点的平均 F1 相同。合同索引修复的 F1 为 44.84%，输入为 46.76%；与重新抽取相差 0.72 个百分点（95%

置信区间：$[-4.80, 6.48]$）。来源和文档编号检查去掉了不需要的三元组。匹配测试中，错误报告降低了平均 F1；模型构建输入上，默认学习选择器的分数低于等权重设置。

人工评价在 95/200 项参考差异中发现输入错误。评审接受五种设置中的 134/199 项编辑，另有一项不确定。这些结果给出清楚的改进目标：为每个字段选择正确取值，保留正确的输入事实，并检查最终图。

声明

数据可用性

数据名单、固定样本编号、模型输出和评分脚本位于 https://github.com/turambar928/MCP_based_KG_construction。各实验 README 给出来源数据集、访问链接和数据修改。我们公开人工评价总数和固定抽样规则。个人答案、书面理由和来源上下文不公开。

代码可用性

同一仓库包含代码、完整提示、模型设置，以及复现论文分析的运行命令。

参考文献

Acosta M, Zaveri A, Simperl E, et al (2013) Crowdsourcing linked data quality assessment. In: International Semantic Web Conference, pp 260–276, https://doi.org/10.1007/978-3-642-41338-4_17

Anthropic (2025) Introducing Claude Haiku 4.5. Anthropic model release announcement, URL https://www.anthropic.com/news/claude-haiku-4-5, published 15 October 2025; accessed 17 September 2026

Auer S, Bizer C, Kobilarov G, et al (2007) DBpedia: A nucleus for a web of open data. In: The Semantic Web: 6th International Semantic Web Conference and 2nd Asian Semantic Web Conference (ISWC/ASWC 2007). Springer, pp 722–735, https://doi.org/10.1007/978-3-540-76298-0_52

Bian H (2025) LLM-empowered knowledge graph construction: A survey. arXiv preprint, https://doi.org/10.48550/arXiv.2510.20345, arXiv:2510.20345

Bollacker K, Evans C, Paritosh P, et al (2008) Freebase: A collaboratively created graph database for structuring human knowledge. In: Proceedings of the 2008 ACM SIGMOD International Conference on Management of Data, pp 1247–1250, https://doi.org/10.1145/1376616.1376746

Bordes A, Usunier N, Garcia-Duran A, et al (2013) Translating embeddings for modeling multi-relational data. In: Advances in Neural Information Processing Systems, URL https://papers.nips.cc/paper_files/paper/2013/hash/1cecc7a77928ca8133fa24680a88d2f9-Abstract.html

Chen M, Zhang W, Zhang W, et al (2019) Meta relational learning for few-shot link prediction in knowledge graphs. In: Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP), pp 4217–4226, https://doi.org/10.18653/v1/D19-1431

Das R, Dhuliawala S, Zaheer M, et al (2018) Go for a walk and arrive at the answer: Reasoning over paths in knowledge bases using reinforcement learning. In: International Conference on Learning Representations, URL https://arxiv.org/abs/1711.05851

Dettmers T, Minervini P, Stenetorp P, et al (2018) Convolutional 2D knowledge graph embeddings. In: Proceedings of the AAAI Conference on Artificial Intelligence, https://doi.org/10.1609/aaai.v32i1.11573

Ding B, Wang Q, Wang B, et al (2018) Improving knowledge graph embedding using simple constraints. In: Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics, pp 110–121, https://doi.org/10.18653/v1/p18-1011

Dong X, Gabrilovich E, Heitz G, et al (2014) Knowledge vault: A web-scale approach to probabilistic knowledge fusion. In: Proceedings of the 20th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, pp 601–610, https://doi.org/10.1145/2623330.2623623

Galárraga LA, Teflioudi C, Hose K, et al (2013) AMIE: Association rule mining under incomplete evidence in ontological knowledge bases. In: Proceedings of the 22nd International Conference on World Wide Web, pp 413–422, https://doi.org/10.1145/2488388.2488425

Gemma Team (2026) Gemma 4 technical report. arXiv preprint, https://doi.org/10.48550/arXiv.2607.02770, arXiv:2607.02770

Guo S, Wang Q, Wang L, et al (2016) Jointly embedding knowledge graphs and logical rules. In: Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing, pp 192–202, https://doi.org/10.18653/v1/d16-1019

Hendrycks D, Burns C, Chen A, et al (2021) CUAD: An expert-annotated NLP dataset for legal contract review. In: Proceedings of the Neural Information Processing Systems Track on Datasets and Benchmarks, URL https://datasets-benchmarks-proceedings.neurips.cc/paper_files/paper/2021/hash/6ea9ab1baa0efb9e19094440c317e21b-Abstract-round1.html

Huang Z, Chen K, He J, et al (2019) ICDAR2019 competition on scanned receipt OCR and information extraction. In: 2019 International Conference on Document Analysis and Recognition (ICDAR). IEEE, pp 1516–1520, https://doi.org/10.1109/ICDAR.2019.00244

Ji S, Pan S, Cambria E, et al (2022) A survey on knowledge graphs: Representation, acquisition, and applications. IEEE Transactions on Neural Networks and Learning Systems 33(2):494–514. https://doi.org/10.1109/tnnls.2021.3070843

Knublauch H, Kontokostas D (2017) Shapes constraint language (SHACL). W3C Recommendation, URL https://www.w3.org/TR/2017/REC-shacl-20170720/

Kontokostas D, Westphal P, Auer S, et al (2014) Test-driven evaluation of linked data quality. In: Proceedings of the 23rd International Conference on World Wide Web, pp 747–758, https://doi.org/10.1145/2566486.2568002

Lao N, Mitchell T, Cohen WW (2011) Random walk inference and learning in a large scale knowledge base. In: Proceedings of the 2011 Conference on Empirical Methods in Natural Language Processing, pp 529–539, URL https://aclanthology.org/D11-1049/

Lewis P, Perez E, Piktus A, et al (2020) Retrieval-augmented generation for knowledge-intensive NLP tasks. In: Advances in Neural Information Processing Systems, pp 9459–9474, URL https://papers.nips.cc/paper_files/paper/2020/hash/6b493230205f780e1bc26945df7481e5-Abstract.html

Lin TW, Fierro G, Li H, et al (2025) Systematic evaluation of knowledge graph repair with large language models. arXiv preprint, https://doi.org/10.48550/arXiv.2507.22419, arXiv:2507.22419

Neo4j Labs (2024) LLM Knowledge Graph Builder. Open-source software repository, URL https://github.com/neo4j-labs/llm-graph-builder, version inspected at commit 5ff7af3e9bb9226e1bbecd02f70f8d98697727a7; accessed 16 September 2026

Nickel M, Murphy K, Tresp V, et al (2016) A review of relational machine learning for knowledge graphs. Proceedings of the IEEE 104(1):11–33. https://doi.org/10.1109/jproc.2015.2483592

Ortona S, Meduri VV, Papotti P (2018) Robust discovery of positive and negative rules in knowledge bases. In: Proceedings of the 34th IEEE International Conference on Data Engineering, pp 1168–1179, https://doi.org/10.1109/icde.2018.00108

Pan JZ, Razniewski S, Kalo JC, et al (2023) Large language models and knowledge graphs: Opportunities and challenges. arXiv preprint, https://doi.org/10.48550/arXiv.2308.06374, arXiv:2308.06374

Pan S, Luo L, Wang Y, et al (2024) Unifying large language models and knowledge graphs: A roadmap. IEEE Transactions on Knowledge and Data Engineering 36(7):3580–3599. https://doi.org/10.1109/tkde.2024.3352100

Paulheim H (2017) Knowledge graph refinement: A survey of approaches and evaluation methods. Semantic Web 8(3):489–508. https://doi.org/10.3233/sw-160218

Paulheim H, Bizer C (2014) Improving the quality of linked data using statistical distributions. International Journal on Semantic Web and Information Systems 10(2):63–86. https://doi.org/10.4018/ijswis.2014040104

Qu M, Tang J (2019) Probabilistic logic neural networks for reasoning. In: Advances in Neural Information Processing Systems, URL https://papers.nips.cc/paper_files/paper/2019/hash/13e5ebb0fa112fe1b31a1067962d74a7-Abstract.html

Qu M, Chen J, Xhonneux LP, et al (2021) RNNLogic: Learning logic rules for reasoning on knowledge graphs. In: International Conference on Learning Representations, URL https://arxiv.org/abs/2010.04029

Schlichtkrull M, Kipf TN, Bloem P, et al (2018) Modeling relational data with graph convolutional networks. In: European Semantic Web Conference, pp 593–607, https://doi.org/10.1007/978-3-319-93417-4_38

Shi B, Weninger T (2017) ProjE: Embedding projection for knowledge graph completion. In: Proceedings of the AAAI Conference on Artificial Intelligence, https://doi.org/10.1609/aaai.v31i1.10677

Suchanek FM, Kasneci G, Weikum G (2007) YAGO: A core of semantic knowledge. In: Proceedings of the 16th International Conference on World Wide Web, pp 697–706, https://doi.org/10.1145/1242572.1242667

Wang Q, Mao Z, Wang B, et al (2017) Knowledge graph embedding: A survey of approaches and applications. IEEE Transactions on Knowledge and Data Engineering 29(12):2724–2743. https://doi.org/10.1109/tkde.2017.2754499

Wang X, Chen L, Ban T, et al (2021) Knowledge graph quality control: A survey. Fundamental Research 1(5):607–626. https://doi.org/10.1016/j.fmre.2021.09.003

Wei J, Wang X, Schuurmans D, et al (2022) Chain-of-thought prompting elicits reasoning in large language models. In: Advances in Neural Information Processing Systems, pp 24824–24837, https://doi.org/10.52202/068431-1800

White J, Fu Q, Hays S, et al (2023) A prompt pattern catalog to enhance prompt engineering with ChatGPT. In: Proceedings of the 30th Conference on Pattern Languages of Programs. ACM, https://doi.org/10.64346/PLoP2023p05

Wienand D, Paulheim H (2014) Detecting incorrect numerical data in DBpedia. In: European Semantic Web Conference, pp 504–518, https://doi.org/10.1007/978-3-319-07443-6_34

Xu L, Hu H, Zhang X, et al (2020) CLUE: A Chinese language understanding evaluation benchmark. In: Proceedings of the 28th International Conference on Computational Linguistics. International Committee on Computational Linguistics, pp 4762–4772, https://doi.org/10.18653/v1/2020.coling-main.419, URL https://aclanthology.org/2020.coling-main.419/

Yang B, Yih Wt, He X, et al (2015) Embedding entities and relations for learning and inference in knowledge bases. In: International Conference on Learning Representations, URL https://arxiv.org/abs/1412.6575

Yao S, Zhao J, Yu D, et al (2023) ReAct: Synergizing reasoning and acting in language models. In: International Conference on Learning Representations, URL https://arxiv.org/abs/2210.03629

Zaveri A, Rula A, Maurino A, et al (2016) Quality assessment for linked data: A survey. Semantic Web 7(1):63–93. https://doi.org/10.3233/sw-150175

Zhu Z, Zhang Z, Xhonneux LP, et al (2021) Neural Bellman-Ford networks: A general graph neural network framework for link prediction. In: Advances in Neural Information Processing Systems, pp 29476–29490, URL https://papers.nips.cc/paper_files/paper/2021/hash/f6a673f09493afcd8b129a0bcf1cd5bc-Abstract.html

表 13 注入缺陷输入上的四种设置。直接调用模型使用不同提示。

变体	修复率	过度修复	F1	精确匹配
无模型补全	0.3200	0.0000	0.8472	0.0622
直接调用模型（独立提示）	0.9244	0.0758	0.9520	0.8267
无约束门控	0.9800	0.0227	0.9895	0.9333
诊断＋门控	**0.9800**	**0.0167**	**0.9917**	**0.9333**

A 补充实验

本节给出早期方法结果、过滤器和选择器的完整测试、首次收据测试、解析细节与补充检查。主要结果见第 5 节。

A.1 早期方法与过滤测试

表 13 比较四种已保存设置。不使用模型补全时返回清理后的图。直接调用模型 使用自己的提示，并跳过清理。过滤测试对同一建议在检查前后计分。第 5.4 节测试提示文本，第 A.2 节测试过滤器和选择器的各个步骤。

模型补全恢复大多数缺失字段。诊断＋门控 的 F1 为 99.17%，直接调用模型 为 95.20%。过滤保持相同修复率，并使过度修复降低 0.60 个百分点。它去掉八条未通过来源匹配的三元组，均与参考不同。

A.2 过滤器与选择器步骤测试

我们使用共享提示测试中的 360 个 Gemma 响应，以及新收据测试中的 180 个响应。每个响应经过八种过滤设置：全部检查、分别去掉五项检查中的一项、同时去掉重复与字段数量检查，以及去掉全部检查。540 个响应得到 4,320 个评分输出，候选顺序保持固定。同时去掉两项检查，用于测试两者如何相互影响。

表 14 给出完整过滤器的 F1 减去改变后过滤器的 F1。先对同一文档的三个提示取平均，再对文档取平均。完整过滤器拒绝 28 条三元组，其中 11 条文档编号错误，17 条来源匹配失败，均与参考不同。其他检查未额外去掉候选。模型构建输入中，来源匹配增加 0.505 个 F1 百分点，编号检查增加 0.085 个百分点。21 项校正后的检验 p 值均大于 0.05。日志也列出移除某项检查后丢失的正确事实。

当前编辑选择器测试。

我们在 225 个注入缺陷输入和 225 个模型构建输入的保存建议上运行 v2 选择器。13 种设置在默认绝对先验评分下产生 5,850 个结果，再用相对等权重评分重复测试，得到另外 5,850 个结果。两次均使用 `public-profile-v2` 特征和重新训练的路由器。档案保留较早的 v1 运行。

基础设置使用等权重，并让选择器始终开启。每个测试改变一个指定步骤。触发器测试从始终开启的学习权重设置开始。去掉某项分数时，将该项置零，并去掉对应边界，其他权重不变。规则检测器和违规减少奖励继续使用。去掉规则候选时，移除检测器动作和直接来源字段添加；图评估概况与保存的模型建议继续使用。

默认等权重选择器在注入缺陷输入上的 F1 为 84.72%，接受零项编辑。去掉编辑成本后，F1 提高到 89.30%，接受 68 个动作。模型构建输入上，等权重达到

表 14 各项过滤检查带来的 F1 变化，单位为百分点。每组输入有 60 篇文档和三种提示。正值表示完整过滤器更好。

移除的检查	受控输入	模型构建输入	收据
重复	+0.000	+0.000	+0.000
文档头节点	+0.037	+0.085	+0.000
关系类型	+0.000	+0.000	+0.000
来源支持	+0.037	+0.505	+0.060
字段数量	+0.000	+0.000	+0.000
重复＋字段数量	+0.000	+0.000	+0.000
全部检查	+0.073	+0.590	+0.060

表 15 默认绝对先验评分下的 v2 选择器。接受数统计动作或编辑包，按注入缺陷／模型构建输入排列。每项 F1 使用 225 篇文档。

设置	受控 F1	模型构建 F1	接受数
始终开启、均匀先验	0.8472	0.8833	0 / 10
学习先验、始终开启	0.8472	0.8799	0 / 10
学习先验与触发器	0.8472	0.8799	0 / 10
无先验惩罚	0.8472	0.8833	0 / 10
无动作成本	0.8930	0.8813	68 / 13
无密度上界	0.8472	0.8833	0 / 10
无质量下界	0.8472	0.8833	0 / 10
仅一轮	0.8472	0.8833	0 / 10
无规则候选	0.8472	0.8833	0 / 9
仅规则候选	0.8472	0.8799	0 / 10
无局部分数及边界	0.8472	0.8799	0 / 0
无图分数及边界	0.8472	0.8833	0 / 10
无来源分数及边界	0.8472	0.8799	0 / 10

88.33% F1，学习权重和学习触发器为 87.99%。两组中，各设置均保留全部原本正确的参考事实。公开文件包含文档分数、试改编辑、拒绝原因和停止原因。每种先验评分形式将 24 项组件检验作为一组进行 Holm 校正。

路由器训练与先验评分。

v2 路由器采用 $8 \to 32 \to 16$ 网络，有一个修复输出和三个编辑类型输出，共 884 个参数。特征缩放器使用 2,098 条训练记录。验证集与测试集各有 450 条记录，按文档分组。注入缺陷输入上的修复分类和编辑类型分类均达到 100%。训练标签来自已知注入缺陷。

表 16 给出较早 v2 测试中的四种权重与评分设置，上面的完整运行已包含它们。学习权重下，相对评分将注入缺陷 F1 从 84.72% 提高到 89.29%，模型构建 F1 从 87.99% 降到 87.64%。两个等权重设置返回相同的图，绝对评分继续作为默认设置。

表 16 保存建议上的 v2 选择器。相对评分以等权重为零点。接受数按注入缺陷／模型构建输入排列。

先验／偏移	受控 F1	模型构建 F1	接受数
均匀／绝对	0.8472	0.8833	0 / 10
均匀／相对	0.8472	0.8833	0 / 10
学习／绝对	0.8472	0.8799	0 / 10
学习／相对	0.8929	0.8764	156 / 51

表 17 首次 SROIE 测试，共 60 张收据。精确匹配使用有标签字段。规范化 F1 忽略取值中的大小写和空白。

方法	三元组 F1	整图匹配	规范化 F1	事实保留
抽取输入	0.7944	0.3333	0.8153	1.0000
仅规则	0.7944	0.3333	0.8153	1.0000
来源字段复制	0.0000	0.0000	0.0000	0.0000
基础，未过滤	0.7944	0.3333	0.8153	1.0000
基础，过滤后	0.7915	0.3333	0.8123	0.9944
诊断，未过滤	0.7944	0.3333	0.8153	1.0000
诊断，过滤后	0.7915	0.3333	0.8123	0.9944
SHACL 上下文，未过滤	0.7986	0.3333	0.8194	1.0000
SHACL 上下文，过滤后	0.7956	0.3333	0.8165	0.9944

A.3 首次收据测试

我们使用 SROIE 收据文本和人工字段标签(Huang et al. 2019)。从修正版 trainval 镜像的 626 篇文档中随机抽取 60 篇，种子为 20260922。文本行按保存顺序连接。模型获得该文本和 company、date、address、total 四个字段名，评分器读取字段标签。一张收据没有地址标签，因此共评分 239 个字段。每种方法都在这些字段上计分；模型仍获得全部四个字段名。

Gemma 首先抽取图。三个修复提示获得同一张图，设置见第 4.2 节。样本和设置在模型调用前固定。测试包含 60 次抽取调用和 180 个修复输出，每个修复响应在过滤前后计分。我们也按原设置运行来源复制和规则修复。主分数使用精确三元组，第二种分数忽略值中的大小写和空白。

输入 F1 为 79.44%。过滤后，基础和错误报告提示均为 79.15%，SHACL 上下文为 79.56%。错误报告减基础提示的差为 0.00 个百分点（95% 置信区间：$[0.00, 0.00]$；配对随机化 $p = 1.0000$）。字段复制在收据上的 F1 为 0.00%，在明确命名字段的中文记录上为 100%。

239 个参考值中，220 个在源文本中精确出现，其余 19 个与来源字符串不同。过滤拒绝 3 个候选，全部匹配参考值。它们是在三种设置中出现的同一地址：来源有双空格，解析器却将候选中的空格压成一个。运行后，我们对来源应用相同空白规则，三种设置都保留该地址。基础与错误报告提示的 F1 变为 79.44%，SHACL 为 79.86%，整图匹配均保持 33.33%。表 17 给出原规则评分。

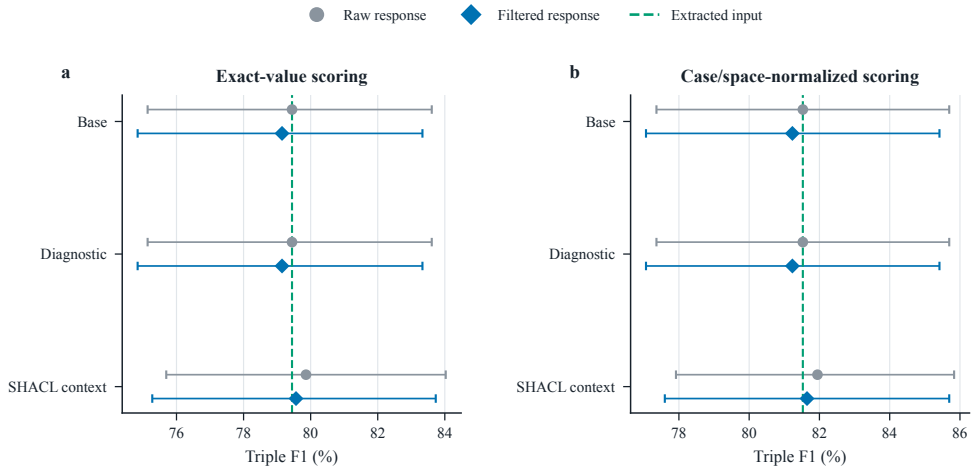


图 10 首次收据评分。点表示平均 F1，误差线为 95% 文档 bootstrap 置信区间。每个原始／过滤对照使用一个响应。虚线表示输入 F1。

表 18 60 张收据在采集后的补充评分。围栏兼容处理去掉外层 Markdown 围栏。编号规范化还在过滤前分配已知文档编号。两者均使用保存的响应。

方法	围栏兼容 F1	编号规范化 F1	错误编号图数
重新抽取	0.6333	0.7256	18/60
索引抽取	0.6105	0.7486	28/60
修复率	0.7917	0.7917	0/60
索引修复	0.8393	0.8393	0/60

本次记录 240 次请求，包括重试，得到 240 个可解析输出。基础、错误报告和 SHACL 提示的平均修复请求时间为 7.87、7.92、8.05 秒，平均输入长度为 661、715、2276 个 token。请求时间包含间隔等待。抽取和上下文设置另计。

A.4 收据修复与重新抽取细节

我们在相同的 60 张新测试收据上再收集 240 个 Gemma 响应，比较有无索引下的修复与重新抽取。各设置共享来源行、字段含义、文档编号和输出上限；修复额外获得已有图。主分数差为过滤后的索引修复减索引重新抽取。全部 240 个响应的 JSON 都包含 Markdown 代码围栏。固定的严格解析器将其记为失败，各设置 F1 均为零。

采集后，我们去掉外层围栏，并执行相同模式检查。全部 240 个响应随即可解析。表 18 给出这些补充评分。索引修复 F1 为 83.93%，索引重新抽取为 61.05%，配对差为 22.88 个百分点（95% 置信区间：14.84 至 31.35）。

索引重新抽取在 28 张图中给出错误文档编号；索引修复在全部 60 张图中使用正确编号。为四种设置统一分配已知编号后，索引重新抽取 F1 提高到 74.86%，索引修复领先 9.07 个百分点（95% 置信区间：5.22 至 13.10）。编号修正保持字段值不

表 19 早期选择器结果，每组 225 个输入。oracle 利用参考答案寻找最佳保存子集。一篇文档可以有多次试改。

诊断项	受控输入	模型构建输入
预处理图 F1	0.8472	0.8799
均匀选择器 F1	0.8472	0.8833
固定建议 oracle F1	0.9964	0.9173
初始未检出违规	86	198
其中与参考不同的图	72	50
其中存在可改善结果的图	70	8
提高参考分数但效用非正的试改	212	1

变。原来的 22.88 个百分点差距同时包含编号和字段值的影响。初始图构建成本与这些修复调用分别计算。

行索引覆盖的字段。

我们在来源行中定位最初后续测试的 240 个参考字段。匹配保留大小写和标点，并清理空白。一个值跨越多行时，索引必须包含某次出现的全部行。240 个值中，188 个出现在索引行或邻近行，36 个出现在范围外，16 个与来源文本不同。对于覆盖的 188 个值，简单流程 精确返回 163 个，证据索引 返回 174 个。对于范围外的 36 个值，两者都返回 26 个；与来源不同的 16 个值，两者都未返回。索引净增加的十一项精确匹配来自覆盖组。

A.5 按可见错误调用修复

我们测试基于可见编号、关系、重复、字段数量和来源匹配错误的调用规则。它为每篇文档选择返回输入，或返回保存的修复输出。在 450 项模型构建与干净图混合流上，仅对 6.22% 的输入调用修复，却漏掉 63.64% 有参考差异的图。其 F1 为 94.46%，始终调用修复为 95.82%。可见检查漏掉许多缺失或字段分配错误的值。主方法对每篇文档都调用修复。

早期选择器中的有用编辑。

我们使用早期选择器保存的建议与试改图。这些运行早于表 16 中的共享特征和候选启动修改。对每篇文档，尝试模型编辑包的所有子集，并根据参考图为结果计分。执行保存编辑时关闭停止、成本和图边界检查。参考得分最高的子集称为 oracle。这项分析使用模型编辑包和参考值。

我们在 450 个输入上尝试 2,144 个子集，结果见表 19。注入缺陷输入中，86 张图未检测到违规，其中 72 张缺少参考字段，70 张存在能提高 F1 的建议子集。检查的试改中，212 项提高参考 F1，但效用分数不大于零。模型构建输入的对应数量为 8 张图和 1 项试改。

去掉编辑成本使 67 篇注入缺陷文档的 F1 提高，158 篇不变，0 篇降低。模型构建输入中，0 篇提高，222 篇不变，3 篇降低。这三张图在清理后已经与参考不同。全部 148 个原本精确匹配的模型构建输入保留其 F1。注入缺陷输入的配对增益为 4.58 个百分点（95% 文档 bootstrap 置信区间：3.69–5.54）。同一成本修改在两组输入上作用不同。

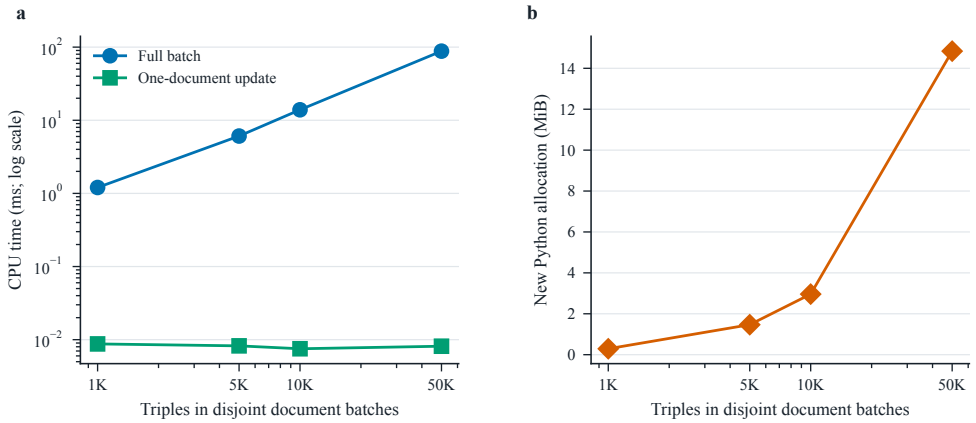


图 11 独立文档批次的报告时间和内存。局部更新只检查一篇修改后的文档。内存统计共享源文本时新增的批次存储。

A.6 图检查的时间与内存

我们在包含 1K–50K 条三元组的独立文档批次上，测量式 (2) 中报告的耗时。完整扫描检查所有文档，局部更新只检查一篇已修改文档。完整扫描时间取七次运行的中位数，局部更新时间取 200 次运行的中位数，数值见表 21。内存统计构建批次时新增 Python 内存的峰值。源文本和模式对象共享，模型调用时间另计。

A.7 补充质量与抽取检查

Gemma 评判器在方法名称隐藏的条件下，为 180 个来源与三元组对打分。来源分数与精确参考有效性的 Pearson 相关系数为 $r = 0.794$，Spearman 相关系数为 $\rho = 0.807$（两者均有 $p < 2.4 \times 10^{-40}$）。另外五次运行中，固定 50 项样本的均值都为 0.96。

我们将本文抽取器与 Neo4j Labs 的 Graph Builder 使用的 `LLMGraphTransformer` 核心(Neo4j Labs 2024)比较，测试使用 CLUE 中的 45 篇均衡 TNEWS 文档(Xu et al. 2020)。字段抽取器的类别准确率为 0.556，Graph Builder 为 0.533，配对检验为 $p = 1.00$。

A.8 请求成本与检查时间

表 20 请求成本。平均时间包含重试和请求间隔等待。来源设置与排队时间另计。

输入	上下文	调用数	输入 token	输出 token	总耗时（秒）
受控输入	基础提示	1.00	947	517	8.58
受控输入	诊断提示	1.00	1017	512	8.61
受控输入	SHACL	1.00	3080	513	8.45
模型构建输入	基础提示	1.00	832	458	7.51
模型构建输入	诊断提示	1.00	901	462	7.90
模型构建输入	SHACL	1.00	2822	455	8.16

表 21 图报告的时间和内存。内存统计新增批次存储峰值，单位为 MiB，源文本共享。

三元组	文档数	完整（毫秒）	局部（毫秒）	内存（MiB）
1,000	143	1.20	0.009	0.29
5,000	716	6.08	0.008	1.47
10,000	1,434	13.90	0.008	2.96
50,000	7,173	88.10	0.008	14.84

译文附页：图中文字对照

本页对照原图中的英文标注。图形、数据点、颜色和数值沿用英文论文。方法名称在正文和表格中采用以下中文写法。

原图方法名	中文名称
Source-field Copy	来源字段复制
No Repair	不修复
Rule Only	仅规则
SHACL-style	SHACL 风格修复
Direct LLM	直接调用模型
ReAct-style	ReAct 风格智能体
Simple Pipeline / Simple	简单流程
Diagnosis + Gate	诊断＋门控
Evidence Index / Index	证据索引
Base	基础提示
Diagnostic	诊断提示
SHACL context	SHACL 上下文

图 1：三个检查范围。

- 输入：One document · three views 为“一篇文档、三个视角”；Source X 为“原文 X”；Task schema 为“任务模式”；Head 为“头节点”；Relations 为“关系”。示例 Merchant: ALPHA、Total: 42.00 表示“商户：ALPHA、总额：42.00”。
- Local scope 为“局部范围”；Incidence + duplicates 为“节点连接与重复”；merchant 为“商户”；isolated node 为“孤立节点”；Repeated fact → duplicate flag 为“事实重复，标记为重复”；No incident edge → local flag 为“没有关联边，标记为局部问题”；Scores: incidence, uniqueness 为“分数：节点连接、唯一性”。
- Graph scope 为“图范围”；Head + relation schema 为“头节点与关系模式”；seller 为“卖方”；seller is not permitted 为“seller 关系不在允许名单内”；$H(t)$ 的说明为“头节点匹配 d1”；$R(t)$ 的说明为“关系被允许”；Score: rule consistency 为“分数：规则一致性”。
- Source scope 为“来源范围”；Value ↔ source text 为“值与源文本对应”；Source excerpt 为“来源片段”；Graph value: 49.00 → absent 为“图中取值 49.00 在原文中不存在”；$S(t; X)$ 的说明为“非空值出现在原文中”；Score: source support 为“分数：来源支持”。底部 Shared report 表示“共享报告：重复计数、失败检查、已出现的关系”。

图 2：路由与编辑选择。

- Input graph 为“输入图”；Document graph G_t 为“文档图 G_t”；Source X 为“原文 X”。示例 merchant、total 分别为“商户、总额”，图中的 49.00 对应来源中的 42.00。
- Quality profile 为“质量评估概况”；Four quality scores 为“四项质量分数”：Incidence、Uniqueness、Rule consistency、Source support，分别为

“节点连接、唯一性、规则一致性、来源支持”。Four graph statistics 为“四项图统计量”：Nodes、triples、Density、violations，即“节点数、三元组数、密度、违规数”。

- Neural routing 为“神经路由”；8 inputs → router 为“八个输入进入路由器”；Repair trigger 为“修复触发分数”；Scope prior π 为“范围先验 π”；Local、Graph、Source 为“局部、图、来源”。Hard flags or candidates override a low trigger 表示“存在硬规则标记或候选时，较低触发分数仍会启动试改”。
- Edit selection 为“编辑选择”；Candidate edits 为“候选编辑”；Fixed model bundles + rule-derived proposals 为“固定模型编辑包加规则建议”；Delete、Retype、Add 分别为“删除、改关系、添加”。Trial graphs 为“试改图”；Bounds + utility $U(a)$ 为“边界与效用 $U(a)$”。选择步骤为“选择可执行且 $U(a) > 0$ 最高的一项编辑”。
- Commit one edit → G_{t+1} 为“执行一项编辑，得到 G_{t+1}”；随后“保留决策日志，重新评估接受后的图”。底部说明：顺序变体在每次接受编辑后重新评估；没有可执行的正效用编辑时停止。

图 3：一次试改循环。

- Route 为“路由”：当前图 G_t 输入四项评估分数和四项图统计量。Learned router 为“学习得到的路由器”；输出修复分数 p(repair) 和范围先验 π。存在硬规则违规或已提供候选时，低触发分数仍继续试改。
- Propose 为“提出候选”：Model proposals 为“模型建议”；Fixed edit bundles grouped by relation 为“按关系分组的固定编辑包”；Rule proposals 为“规则建议”；Detected violations + explicit source fields 为“检测到的违规与明确来源字段”。动作是删除、改关系和添加；Deduplicate candidates 为“对候选去重”。
- Evaluate trials 为“评估试改”：在 G_t 的独立副本上分别尝试 a_1, a_2, a_3，得到试改图。Recompute profile and flags 为“重新计算评估概况与标记”；Check bounds; calculate $U(a)$ 为“检查边界，计算 $U(a)$”。
- Select 为“选择”：先判断是否允许执行、是否满足 $U(a) > 0$，再在合格编辑中选择最高效用，执行一项编辑，使 G_t 变为 G_{t+1}。
- Utility $U(a)$ 的文字说明为“质量增益＋硬规则违规减少－编辑成本＋对数范围先验＋建议置信度”。Trial-state constraints 为“试改状态约束”，包括“恢复边界、单项分数有限回退、密度上界、非空图保护”。
- 底部说明：重新评估执行后的图，并在 12 步范围内重复；没有合格编辑或达到 12 步时停止。提前退出条件为“没有已提供候选，且低触发分数下没有硬规则标记，或没有检测到违规”。

图 4：受控修复。

a 中 Quality with 95% bootstrap intervals 为“质量分数及 95% bootstrap 区间”；Defect repair、Triple F1、Exact graph 为“缺陷修复、三元组 F1、整图匹配”；Held-out score 为“预留测试得分”。b 中 Quality–latency trade-off 为“质量与耗时的权衡”；纵轴为“缺陷修复率”，横轴为“每篇文档耗时（秒）”。圆形和方形表示一次调用，菱形表示两次调用。方法名见本附页开头。

图 5：按输入类型分组。

Extracted input 为“抽取输入”；Simple pipeline 为“简单流程”；All inputs 为“全部输入”；Valid JSON 为“有效 JSON”；Imperfect valid JSON 为“有效但与参考不同的 JSON”；Malformed JSON 为“无效 JSON”。n 表示该组样本数。a 的横轴为“三元组 F1（%）”，b 为“整图精确匹配（%）”。其他方法名见本附页开头。

图 6：机制对照。

Raw candidate 为“原始候选”；Gated pipeline 为“门控过滤流程”；Sequential optimizer 为“顺序选择器”。a 为“受控输入”，b 为“模型构建输入”，c 为“保存的候选”；Archived candidates 表示“历史保存候选”。三幅图横轴均为“三元组 F1（%）”。Base、Diagnostic、SHACL context 的对应中文见开头。

图 7：新收据。

Extracted input 为“抽取输入”，a 的横轴为“三元组 F1（%）”。b 的三项为“简单流程减输入”“索引减简单流程”“索引减 SHACL”，横轴 Paired F1 difference (points) 为“配对 F1 差（百分点）”。方法名见开头。

图 8：析因与来源行。

a 的 Factorial main effects 为“析因主效应”；Preprocessing、Diagnosis、Gate 分别为“预处理、诊断、门控”；Controlled、Natural 分别为“受控输入、模型构建输入”。b 的 Receipt context contrasts 为“收据上下文对照”；Full、Random、Anchors 分别为“完整索引、随机索引、仅锚点”；No-def. full 为“无字段定义的完整索引”，No-def. simple 为“无字段定义的简单流程”。各项依次比较“完整减简单”“完整减随机”“完整减锚点”“完整减无定义完整”“简单减无定义简单”。横轴均为“配对 F1 变化（百分点）”。

图 9：合同。

Initial extraction、Simple repair、Indexed repair、Indexed re-extraction 分别为“初始抽取、简单流程修复、索引修复、索引重新抽取”。横轴 Document mean F1 (%) with 95% bootstrap interval 为“文档平均 F1（%）及 95% bootstrap 区间”。

图 10：首次收据。

Raw response、Filtered response、Extracted input 分别为“原始响应、过滤后响应、抽取输入”。a 的 Exact-value scoring 为“精确值评分”，b 的 Case/space-normalized scoring 为“大小写与空白规范化评分”。横轴为“三元组 F1（%）”。提示名称见本附页开头。

图 11：检查规模。

Full batch 为“完整批次”；One-document update 为“单文档更新”。a 的纵轴 CPU time (ms; log scale) 为“CPU 时间（毫秒，对数坐标）”。b 的纵轴 New Python allocation (MiB) 为“新增 Python 内存分配（MiB）”。两幅图横轴 Triples in disjoint document batches 为“互相独立的文档批次中的三元组数”，1K、5K、10K、50K 分别表示一千、五千、一万和五万条。