阅读目录

Paper1 数学导读：对照论文一步步看 **2**

先找到你正在读的论文位置 2

1. 输入和输出：修一张文档信息表 2

2. 三个检查：主体对不对、字段对不对、值能否找到 3

3. 模型生成：根据原文提出一份完整答案 3

4. 候选筛选：一个字段最多留一个值 3

5. 证据索引：给模型标出值得再看的原文行 4

6. Algorithm 1：把前面五件事串起来 4

7. 顺序变体的 profile：用四个分数概括当前图 5

8. Scale-Aware Routing：建议要不要修、优先看哪类问题 5

9. 顺序选择：每次试改，再选择值得做的那一个 5

10. 自动评分：改对多少和整张图全对不同 6

11. 人工一致性与统计：判断这个提升是否可信 6

读完后应记住什么 7

Paper1 数学导读：对照论文一步步看

更新：2026-10-12。本文对应老师意见合并版，按第 3、4 两章解释检查、约束、路由和执行。方法按当前代码写，实验数值和冻结协议保留。

如果只想先理解方法，可以先读每节的解释和例子，暂时跳过公式；需要核对时再看符号。

全文用一个例子：收据写着“公司：甲公司；小计：100；实付：120”。系统要得到“这张收据—实付金额—120”这样的记录。这里的知识图谱，可以先理解为**一张用三列存信息的表**。

先找到你正在读的论文位置

章节号按当前 main.tex 实际引用的源码排列；Overleaf 若调整了顺序，以英文小节名为准。下面的“本导读第几节”不是论文公式编号。

本导读	论文对应位置	你会弄懂什么
1	第 3 章开头，Task and Method	输入和输出是什么
2	3.1 Input Cleanup and Error Report	程序先检查哪些问题
3	3.2 Generating a Graph from Source Text	模型负责什么
4	3.3 Checking the Generated Triples	哪些候选能留下，数量命题证明了什么
5	3.4 Field Meanings and Source Lines	怎样提示模型去原文找字段
6	4.1 Repair Steps，Algorithm 1	主流程怎样连起来
7—9	4.3 Scale-Aware Routing and Edit Actions；4.4 Trial Checks and Repair Loop	单独评估的路由、候选编辑和试改循环怎样工作
10—11	5.1 Test Setup；5.10 Human Review of Errors and Edits	怎样算分，怎样理解人工结果

先分清两个流程。主实验的“98% 修复率”来自“一次模型生成＋过滤”。路由和多轮选择按另一组独立配置评价，各自结果在第 5 章和附录中报告。

1. 输入和输出：修一张文档信息表

对应论文：第 3 章开头，methodology.tex，定位 sec:framework。

符号	简单含义	例子
X	原文	收据上的全部文字
G	待修复的三列记录，可包含重复项	“收据—实付—100”
$t = (h, r, o)$	一条记录：主体、字段、值	(收据, 实付, 120)
h_0	这篇文档的固定编号	这张收据的编号
$\mathcal{R}_X$	允许填写的字段	公司、地址、日期、实付
G^*	评分时使用的参考答案	模型推理时不能读取
$\widehat{G}$	修复后的输出	最终交出的信息表

这里每个字段最多保留一个值。“允许填写日期”不等于“每篇文档都必须有日期”。这个设置也不直接适用于“作者”这种可能有多个值的字段。

2. 三个检查：主体对不对、字段对不对、值能否找到

对应论文：3.1，methodology.tex，公式标签 eq:diagnostic_predicates、eq:diagnostic_context。

程序先去掉完全重复的记录，处理字段图中明确写反的边，去掉非法主体或字段。接着用三个开关检查候选：

$$H(t) = \mathbf{1}[h = h_0], \qquad R(t) = \mathbf{1}[r \in \mathcal{R}_X],$$
$$S(t; X) = \mathbf{1}[o \neq \emptyset \ \wedge \ o \text{ occurs in } X].$$

$\mathbf{1}[\cdots]$ 的意思是：方括号里的条件成立就记 1，否则记 0。$\wedge$ 表示“并且”。

- H：这条记录是否属于指定文档?
- R：字段是否在允许名单内?
- S：值是否非空，而且能在原文里找到?

例如“实付—100”可能三个检查都通过，因为 100 确实在收据里，但它是小计。因此，**通过这三个检查不等于字段语义正确**。

诊断报告只是把发现的问题列出来：

$$D = (n_{\text{dup}}, I_H, I_R, I_S, \mathcal{R}(G_s)).$$

G_s 是预处理后的图；n_{dup} 是重复数，I_H, I_R, I_S 是检查失败的位置，最后一项是已经出现的字段。报告在预处理之后生成，有些问题已被删除，对应列表自然为空。

3. 模型生成：根据原文提出一份完整答案

对应论文：3.2，methodology.tex，eq:proposal_generation。

$$C = L_\theta(X, h_0, \mathcal{R}_X, G_s, D).$$

把它读成一句话：**将原文、文档编号、字段名单、现有图和可选诊断交给模型，得到候选记录列表** C。L_θ 表示现成语言模型，不表示本论文重新训练了该模型。

模型返回的完整图是最终过滤的输入。旧图中正确的记录也需要重新输出才能留下。无法解析的输出记为空图，纳入相应实验的评分和分母。

4. 候选筛选：一个字段最多留一个值

对应论文：3.3，methodology.tex，eq:eligible_candidates、eq:admissible_subsets、eq:selection_size。

先去重，再留下通过三个检查的候选：

$$C_X = \{t \in \text{uniq}(C) : H(t)R(t)S(t; X) = 1\}.$$

这里三个 0/1 值相乘，只有全部为 1 才通过。再要求每个字段最多出现一次：

$$\mathcal{F}(C_X) = \left\{ A \subseteq C_X : \sum_{t \in A} \mathbf{1}[r_t = r] \leq 1, \ \forall r \in \mathcal{R}_X \right\}.$$

读法是：“$\mathcal{F}$ 收集所有合法的候选子集；每个字段的计数不能超过 1。”实际算法按模型输出顺序扫描，保留每个字段的第一个合格候选。

论文的数量命题：

$$|\widehat{G}| = \max_{A \in \mathcal{F}(C_X)} |A| = |\{r : \exists t \in C_X,\ r_t = r\}|.$$

竖线 $|\cdot|$ 表示“有多少个”。假设合格候选涉及公司、日期、实付三个字段：每个字段最多取一个，所以最多保留三条；算法恰好各取一条，便达到三条。

这个式子说明过滤后保留的记录数。若实付的 100 和 120 都通过检查，算法按输出顺序选第一个；字段含义决定哪个值正确。若加入“总额等于各项金额之和”的规则，就需要同时检查几个字段。

5. 证据索引：给模型标出值得再看的原文行

对应论文：3.4，methodology.tex，sec:framework:field_evidence。下面的窗口式是对文字步骤的展开，不是新增论文定理。

先告诉模型“实付金额”指最终应付总额，再在原文中寻找 total 等位置。例如找到第 10 行，就同时提示它查看第 9—12 行。

$$A_r = \{i : \text{line } i \text{ matches field } r\}, \qquad E_r = \bigcup_{i \in A_r} \{i-1, i, i+1, i+2\}.$$

A_r 是字段 r 的锚点行，E_r 是锚点和邻近行；超出文档范围的行号去掉。所有比较方法都能看到完整原文，索引额外给出按固定规则找到的行号。

收据后续实验还统一了空白处理。$N(s)$ 把连续空格、换行压成一个空格，并去掉首尾空白：

$$S_{\text{ws}}(t; X) = \mathbf{1}[|N(o)| > 0 \ \wedge \ N(o) \text{ occurs in } N(X)].$$

例如 `甲公司\n上海` 和 甲公司上海 可以匹配。空白处理解决排版差异；字段含义帮助模型判断公司角色。早期主过滤器和顺序选择器使用不同的空白规则，各版本按原规则评分。

6. Algorithm 1：把前面五件事串起来

对应论文：4.1，methodology.tex，alg:abstract。

1. 整理输入图，得到 G_s。
2. 生成诊断报告。
3. 调用一次模型，解析完整候选图。
4. 依次检查重复、主体、字段、原文和单值限制。
5. 返回保留的记录，并记下拒绝原因。

复杂度是在估计“数据变多后需要做多少检查”：

$$T_{\text{preprocess}} = O(n), \qquad T_{\text{gate}} = O(k(1 + c_X)).$$

n 是输入记录数，k 是候选数，c_X 是一次原文查找的成本。$O(n)$ 可理解为“检查量大致随记录数增长”。文本长度影响查找成本，模型推理时间单独统计。

7. 顺序变体的 profile：用四个分数概括当前图

对应论文：4.3.1，methodology.tex，公式 eq:quality_state、eq:profile_rates、eq:routing_inputs，以及 Figures 2、3。

分数	简单问题	计算方式（分母非空时）
Q_{inc}	有多少节点连着边?	$100(1 - I/n)$
Q_{uniq}	记录是否重复或高度相似?	$100c/m$
Q_{rule}	有多少记录未被规则标为违规?	$100(1 - B/m)$
Q_{src}	有多少值能在原文找到?	$100(1 - V/m)$

n 为节点数，m 为记录数，I 为孤立节点数，B 为被规则标记的不同记录数，V 为来源不匹配数。c 是把相似记录连起来后得到的组数；实现用字符对计数的余弦相似度判断。

四项平均得到 Q。例如 5 个节点中 1 个孤立，第一项为 80 分。

节点连接和字段缺失分开检查。一张图只留下公司名，它的节点也可能都连接正常。来源字段检查会继续寻找原文中已有、图中缺失的字段。

图密度 ρ 表示实际连接占可能连接的比例；实现只计算不同节点对的连接，避免重复记录把密度推到 1 以上。空图和缺来源等边界采用明确的程序约定，分数不是“事实正确概率”。

8. Scale-Aware Routing：建议要不要修、优先看哪类问题

对应论文：4.3.2，正文给出网络输入输出与训练损失，公式 eq:decision_net、eq:decision_loss。

输入是四个分数和四个图统计量：

$$x = [Q_{\text{inc}}, Q_{\text{uniq}}, Q_{\text{rule}}, Q_{\text{src}}, n, m, \rho, n_{\text{viol}}].$$

八个输入先按训练集均值和标准差缩放。网络经过 32、16 个中间单元，两层都用 ReLU。sigmoid 给出修复分数 p_{repair}，softmax 给出三类问题的权重 $\boldsymbol{\pi}$。网络共 884 个参数。n_{viol} 是发现的违规数。

训练时，一方面要求“是否有缺陷”判断正确，另一方面要求“主要属于哪类问题”判断正确：

$$\mathcal{L} = \frac{1}{N}\sum_i \text{BCE}(p_i, y_i) + \frac{\sum_i m_i(-\log \pi_{i,c_i})}{\sum_i m_i + \epsilon}.$$

y_i 是是否有缺陷的标签；c_i 是问题类别；m_i 表示是否有可用类别标签；ϵ 防止除零。两项损失都在做同一件事：预测越偏离训练标签，扣分越多。

这是用已知注入缺陷训练的**监督路由器**。干净图训练是否修复的输出；缺陷图还训练问题类别输出。类别取注入缺陷中占比最高的一类。文档的干净与缺陷版本放在同一数据分组中。

9. 顺序选择：每次试改，再选择值得做的那一个

对应论文：4.3.3 的候选与成本、4.4 的试改和循环，methodology.tex，公式 eq:cost_hierarchy、eq:action_utility、eq:constrained_opt，Algorithm 2。

对候选操作 a，先复制当前图，试做得到 G_a，再计算：

$$U(a) = \frac{Q(G_a) - Q(G)}{100} + 0.20\frac{\max(0, h(G) - h(G_a))}{\max(1, h(G))} - 0.35c(a) + 0.05\log(\max(\pi_{s(a)}, 0.05) + 10^{-6}) + 0.02z(a).$$

从左到右就是五笔账：质量提高多少、违规减少多少、操作多贵、路由器多偏好这类操作、候选有多可信。h 是硬规则违规数，c 是设定的操作成本，$s(a)$ 是类别，z 是提议置信度。

添加、删除、改关系的成本分别为 0.06、0.30、0.16，是公式中的固定罚分。候选还要通过各分数下界、允许回退幅度、密度和不删空检查。然后选 U 最大且 $U > 0$ 的一项执行，重新评分，最多 12 轮。

一个容易理解的反例：正确补上一个缺失字段，但四个分数几乎不变；再减去成本后，系统可能觉得“不值得做”。所以效用变好和参考 F1 变好不是同一回事。

论文另检查了把均匀先验的负常数去掉:

$$U_{\text{relative}}(a) = U(a) - 0.05 \log(1/3 + 10^{-6}).$$

这像把所有候选同时加上相同分数：排名不变，但原来略低于零的候选可能变成可接受。默认评分和这个对照都在回放前固定。

当前正文 5.4 报告选择器摘要，完整 13 配置和先验敏感性回放移至附录 A.2。默认顺序选择在受控输入接受 0 次编辑；自然输入学习先验 F1 87.99%，低于均匀先验 88.33%。保留这条神经变体和三张方法图用于单独评价，主流程的 98% 修复率属于生成与过滤路径；选择器结果按其独立配置报告。

该流程需要对许多记录两两比较。T 轮、每轮最多 K 个候选、每图 m 条记录时，主要检查量约 $O(TKm^2)$。Algorithm 1 的清理和过滤只需逐条扫描。

10. 自动评分：改对多少和整张图全对不同

对应论文：5.1 的 Metrics and statistics，以及各任务的评分说明，experiments.tex。

中文任务保留重复次数。设候选记录 t 在输出、参考中分别出现 y_t, g_t 次:

$$TP = \sum_t \min(y_t, g_t), \qquad F1 = \frac{2TP}{|\widehat{G}| + |G^*|}.$$

例如参考有 4 条，输出有 5 条，其中 4 条匹配，F1 为 $8/9$，约 88.9%。若只看命中参考的比例会得到 100%，却忽略多输出的一条。

- **缺陷修复率**：人工注入的缺陷有多少被恢复；主实验分母是 450 个缺陷。
- **整图精确匹配**：一篇文档的输出全部吻合参考才算通过。
- **参考差异减少率**：原差异数为 $d_0 > 0$，修复后为 d_1，计算 $1 - d_1/d_0$；差异增多时可以为负。

收据和合同另有规范化规则。忽略一些空白后更相似，不等于人工确认语义相同。

11. 人工一致性与统计：判断这个提升是否可信

对应论文：5.10 人工评价与 5.1 统计方法，experiments.tex。

两个人判断同一批项目，Cohen’s κ 用来衡量“超过偶然一致程度的一致性”：

$$\kappa = \frac{p_o - p_e}{1 - p_e}.$$

p_o 是实际一致比例；p_e 是按两人各类标签比例计算的偶然一致水平。E 任务操作可接受性的原始一致率为 65%，κ 为 0.128；第三人裁决不会把这项原始一致性变高。

最终 E 接受率是 $134/199$，约 67.3%，另有 1 项不确定。它来自五种配置的合并操作样本，不能写成完整方法的人工准确率。历史 Diagnosis + Gate 的样本是 25/41；这些不平衡配置样本未建立人工方法优势。

配对 bootstrap 可以理解为：反复抽取整篇文档，比较同一批文档上的两种方法。如果差值区间跨过 0，就暂时不能判断哪种更好。Holm 校正是在同时比较很多项时提高判定要求，防止碰巧挑出“显著”结果。论文给出的边际 95% 区间不作多重比较调整；应按相应检验族的校正 p 值判断显著性。不显著不能证明等效，均值相同也不能证明等效。

收益归因必须遵循实际对照：整体 pipeline 对比同时改变提示和过滤，不能用它独立证明诊断有效；同一个响应过滤前后才能直接观察过滤的贡献。收据冻结对照 Index−Simple 为 +4.76 点，但后续 Full−Random 不显著、Full 与 Anchors-only 均值相同，所以不能将全部收益归于完整索引或精准检索。合同索引修复从 46.76% 降至 44.84%，与重抽取差值 +0.72 点的区间 [−4.80, 6.48] 又跨零：这项合同测试中，修复分数低于初始抽取，修复与重抽取的差值区间跨零。

读完后应记住什么

主算法用来源和字段规则过滤模型提出的值。证据索引帮助定位文本，顺序变体根据试改分数选操作。对照实验报告各步骤的得分变化，人工评价检查具体字段和编辑是否合理。

下一步按论文顺序读 实验导读。当前工作状态见 PROGRESS.md；需要追溯旧公式修复时再看仓库中的 历史数学审查。