

阅读目录

Paper1 实验导读：每组实验做了什么、说明了什么	2
先找到论文里的实验	2
1. 用了哪些数据	2
2. 先看懂分数	3
3. 受控主实验：完整流程能修已知错误吗	3
4. 实际抽取输出：不人为放错，还能改善吗	3
5. 诊断与过滤：究竟哪部分带来收益	4
6. 消融：把组件拿掉，结果变不变	4
7. 跨模型：换模型后如何	5
8. 首次收据测试：规则为什么可能误删	5
9. 新收据测试：证据位置提示有没有用	5
10. 修复与重新抽取：旧图到底有没有帮助	6
11. 完整组件与简单上下文对照	6
12. CUAD 合同：换文档类型能否推广	7
13. 真人审查：自动差异是否真的错，实际编辑是否可接受	7
14. 辅助实验、历史诊断与成本	7
15. 贡献与实验结论怎样对应	8

Paper1 实验导读：每组实验做了什么、说明了什么

更新：2026-10-10。按当前论文第 5 章及附录的顺序解释。所有数值来自已有结果；本次没有重跑实验、调用模型或改人工标签。

先用一句话理解任务：**模型已经从文档里填出一张字段表，我们利用原文再检查、补充和修改它。**实验既要看有没有修好，也要看有没有把原来正确的内容改坏。

先找到论文里的实验

编号按当前 main.tex 引用顺序整理。Overleaf 若改了顺序，用英文小节名定位。

本导读	论文对应位置	它想回答的问题
1—2	5.1 Test Setup	用什么数据，怎么算好坏？
3	5.2 Repair of Added Defects	人为放入的错误能修好多少？
4	5.3 Repair of Model-Built Graphs	真实模型输出也能改善吗？
5—6	5.4 Prompt, Filter, and Edit-Selector Tests; 附录 A.1—A.2	生成、诊断、过滤及顺序选择各贡献多少？
7	5.5 Tests with Two Models	换模型后是否还有同样趋势？
8	附录 A.3 First Receipt Test; 正文 5.6 的动机	初次收据测试怎样暴露误删和格式问题？
9	5.6 Source-Line Hints on New Receipts	冻结的新收据测试是否改善？
10	5.8 Receipt Repair and Fresh-Extraction Details; 附录 A.4	有旧图是否优于重新抽取？解析失败怎样限制结论？
11	5.4 的 factorial 段; 5.7 Comparing Source-Line Hints	严格对照支持哪些组件归因？
12	5.9 Contract Field Test	换成合同能否复现收益？
13	5.10 Human Review of Errors and Edits	真人是否认可这些错误和编辑？
14	附录 A Extra Tests; 5.12 Code and Data	完整回放、规模和成本怎么解释？
15	5.11 Discussion; 5.12 的研究问题汇总表	论文最终能得出什么结论？

数学含义不清楚时查 数学导读，不必先读完所有公式。

1. 用了哪些数据

对应论文：5.1, [experiments.tex](#), 表 tab:repair_benchmark; 各外部任务的小节另给细节。

数据	实际规模	用途
中文受控字段图	1,499 篇; 训练 1,049、验证 225、测试 225	从已知答案出发，放入错误后测试恢复
中文实际抽取图	同一批 225 测试来源	直接检查模型真正生成的输出
中文机制对照	其中 60 篇，分别使用受控和实际抽取输入	固定其他条件，比较组件
SROIE 收据	首次 60 篇; 后续另有 20 开发+60 测试篇	检验原始收据字段修复
CUAD 合同	20 开发+56 测试份	检验另一种文档类型
真人审查	200 项输入差异+200 项实际编辑	检验自动差异是否真错、编辑是否可接受

重要的数据特点：中文原文是“字段名：值”形式，正确值已经直接写在来源里。因此简单程序按字段复制就能满分。收据和合同不是同样规整的格式。

后续多组收据实验重复使用同一批 60 篇，不能每跑一组就算又增加了 60 篇独立测试文档。

2. 先看懂分数

对应论文：5.1 的 Metrics and statistics, [experiments.tex](#)。

指标	用普通话解释
缺陷修复率	放进去的错误，有多少被修回去了
三元组 F1	整体上既少漏填，也少多填；不是只数修了几条
整图精确匹配	整篇文档的输出全部吻合参考，才算一次成功
正确事实保持率	原本与参考相符的内容，还保留了多少
参考差异减少率	修复后比修复前少了多少差异；若越修越多，可以为负

“参考”是评分答案，不是每一次实际编辑都经过真人确认。收据金额 1200.00 与 1,200.00 可能意思相同，却在严格字符串评分中不同。

文中“+4.76 个百分点”指从 78.75% 到 83.51% 这样的相减。95% 差值区间跨过 0，表示当前证据还不能可靠判断哪种更好，不表示两者已被证明完全一样。

3. 受控主实验：完整流程能修已知错误吗

对应论文：5.2, [experiments.tex](#), 表 tab:repair_main、图 fig:repair_benchmark_results。

这里 Gate 指程序过滤器，Diagnosis 指额外诊断报告；Simple 是简单修复流程。SHACL 是描述和检查图约束的一种语言，本文使用其中适配本任务的检查。

怎么做：225 篇测试文档，每篇放入两个缺陷，共 450 个。缺陷包括缺失、重复、非法关系、反向边、无来源支持的值和层级冲突。比较不修复、规则、直接问模型、两次调用的 agent，以及组合流程。

方法	缺陷修复率	F1	整图完全匹配
不修复	0.00%	76.15%	0.00%
仅规则	32.00%	84.72%	6.22%
SHACL-style Repair	0.00%	79.98%	0.00%
直接问模型	92.44%	95.20%	82.67%
两次调用的 ReAct-style	89.11%	92.13%	59.56%
Simple Pipeline	95.11%	96.34%	84.00%
Diagnosis + Gate	98.00%	99.17%	93.33%
按原文字段直接复制	100.00%	100.00%	100.00%

结论：组合流程比这里实现的几个模型流程好，但这个数据上最好的方法是无需模型的字段复制。98% 属于“一次生成+过滤”，不是神经路由或多轮选择器的成绩。

完整流程比 Simple 的修复率高 2.89 点，配对区间为 [1.11, 4.89]。它比较两个完整流程；单组件贡献由匹配提示和同响应过滤测试衡量。

4. 实际抽取输出：不人为放错，还能改善吗

对应论文：5.3, [experiments.tex](#), 表 tab:natural_errors、图 fig:natural_stratified。

怎么做：让模型对同一批 225 来源实际建图，再修复输出。其中 10 次无法解析；77 个图与参考不一致，共 302 项差异。

方法	F1	整图完全匹配
初始抽取	87.99%	65.78%
Simple Pipeline	88.07%	67.11%
Diagnosis + Gate	92.48%	68.44%
字段直接复制	100.00%	100.00%

结论：完整流程改善了参考匹配，三元组层面的改善比整图全部修好的改善更明显。这不是新领域测试；302 项自动差异也不能直接称为 302 个真人确认的错误。

论文另把解析失败与可解析但内容不符的输入分开检查，防止把“补回空图”的收益完全当成一般语义修复收益。

5. 诊断与过滤：究竟哪部分带来收益

对应论文：5.4, 实验正文与匹配对照表。历史流程表在附录 A.1, 见完整流程比较。

先看同一批候选过滤前后。这样模型没有重新生成，变化才能归到过滤上：

- 缺陷修复率都为 98.00%，整图匹配都为 93.33%。
- F1 从 98.95% 到 99.17%；过度修复从 2.27% 降到 1.67%。
- 过滤器拒绝了 8 个无来源支持、且不匹配参考的三元组。

含义：过滤主要拦下额外不合格内容，没有让这批候选修好更多目标缺陷。

再用 Gemma 比较 Base、Diagnosis、SHACL context, 60 篇 × 两种输入 × 三组，共 360 个响应；每个响应都分别评分过滤前后。

统一过滤后的上下文	受控 F1	实际抽取输入 F1
Base	99.62%	92.52%
Diagnosis	98.61%	91.47%
SHACL context	99.12%	93.64%

结论：增加诊断没有稳定改善输出。这与上一节“完整流程胜过 Simple”不矛盾：旧完整流程同时改变了多件事，此处更接近只比较诊断内容。

这里的 SHACL context 是结合本任务改编的相关工作思路，不是官方代码原样复现。

6. 消融：把组件拿掉，结果变不变

对应论文：正文 5.4 的摘要、附录 A.2, [appendix.tex](#)。

6.1 五项过滤检查

540 个已存响应分别通过 8 种过滤设置，共 4,320 次评分，不增加模型请求。

检查包括重复、文档编号、字段名单、来源支持、字段最多一个值。完整过滤器拦下 28 个不匹配参考的候选：11 个文档编号错误、17 个缺来源支持；其他检查在这批输出中几乎没有改变结果。

结论：有可追溯的拦截作用，但 21 项比较经多重比较校正后，没有一项达到显著标准。当前没触发某检查，不等于该检查永远无用。

6.2 神经路由和顺序选择器

这里是另一条流程：先试做每个修改，再由效用和约束决定是否接受。新版统一训练/运行特征，使用 8 输入、884 参数的监督路由网络。

13 种配置各处理 450 个输入；另做一套先验敏感性分析，合计 11,700 次离线回放。主要结果如下：

设置	受控 F1	实际抽取输入 F1
始终开启+均匀先验	84.72%	88.33%
始终开启+学习先验	84.72%	87.99%
学习先验+学习触发	84.72%	87.99%
去掉操作成本	89.30%	88.13%
仅规则候选	84.72%	87.99%

还检查了去先验惩罚、去密度上界、去质量下界、只做一轮、去规则候选，以及分别去局部/图/来源分数与对应边界。这些分数组件消融不等于把整个尺度的检测能力全部移除。

结论：这部分消融已经系统做过，但没有显示学习先验稳定提高最终修复质量。去成本有利于受控输入，对实际抽取输入却没有同样稳定的收益。11,700 是配置回放次数，不是新文档数。

7. 跨模型：换模型后如何

对应论文：5.5, [experiments.tex](#), 表 tab:cross_model。

在同一批 60 个受控文档上，历史 Claude 与 Gemma 都比较 Direct、Simple、Diagnosis + Gate。完整流程的缺陷修复率分别为 97.5%、98.3%，都高于对应的两个简单模型流程。

结论：这个小样本有跨模型一致趋势，但没有证明跨领域或真实语义错误上的普遍优势。这里提到 Claude 是历史档案，本次文档更新没有调用它。

8. 首次收据测试：规则为什么可能误删

对应论文：附录 A.3, [appendix.tex](#)。

60 张收据，评价公司、地址、日期、金额；一个地址没有标签，因此总计 239 个标注字段。

Base 和 Diagnosis 的原始 F1 都为 79.44%，加过滤后变成 79.15%。被过滤掉的三个候选恰好都匹配参考，问题来自来源与候选的空白形式不一致。按“字段名：值”直接复制在这种收据文本上也不适用。

结论：合法字段和来源出现检查不够；来源格式也会影响过滤。这个结果推动了后续的字段的定义、空白处理与证据索引。

9. 新收据测试：证据位置提示有没有用

对应论文：5.6, [experiments.tex](#), 表 tab:receipt_followup。

先用另外 20 篇固定设计，再用新的 60 篇测试。所有组拿到同样的字段定义、编号原文行和初始图；索引组额外得到字段相关行的位置。

方法	严格 F1	规范化 F1
初始抽取	78.33%	79.58%
Simple + Gate	78.75%	80.83%
Evidence Index + Gate	83.51%	86.43%

方法	严格 F1	规范化 F1
SHACL context + Gate	78.33%	80.42%

预设比较 Index-Simple 为 +4.76 点，95% 区间 [2.50, 7.26]。规范化后仍有差异，不全是大小写或空格造成的。

但不是只改对：索引修好 26 个原不精确字段，也使 14 个原精确字段失去精确匹配；其中 10 个仍是同一金额，只改变格式。过滤本身对索引 F1 仅贡献约 0.18 点，主要差别来自生成时看到的上下文。

结论：这批新收据支持证据提示有效；还需要下一组更简单的上下文对照，才能说明专门的索引设计是否必要。

10. 修复与重新抽取：旧图到底有没有帮助

对应论文：5.8, experiments.tex。

复用上述 60 收据，比较“有/无旧图 × 有/无索引”，共 240 次请求。

所有响应都带 Markdown 代码围栏，与预先固定的严格解析器不兼容。因此原定严格分析全部失败，无法判断语义优势。

随后明确标注为事后分析，统一去外围围栏并处理已知文档编号：索引修复 F1 为 83.93%，索引重抽取为 74.86%。不统一编号时曾有更大的差距，其中一部分其实来自编号错误。

结论：不能把全部差距归给修复机制，也不能把事后处理写成预先设计成功的正式测试。这促成了合同实验在调用前固定解析和编号规则。

11. 完整组件与简单上下文对照

对应论文：5.4 的 factorial 段、5.7, experiments.tex，表 tab:recovery_factorial、tab:recovery_index。

本轮 840 个响应全部成功解析：480 个用于预处理 × 诊断开关，360 个用于收据上下文对照。过滤仍在同一响应上开关，不重新调用。

中文部分的六项预设组件主效应，经 Holm 校正后都未显著。诊断均值没有正向收益；来源和文档编号过滤拦下了 47 个不匹配参考的候选。这 47 个属于本轮，不能和第 6 节的 28 个混为一批。

收据部分如下，统一使用过滤：

上下文	F1
Simple	79.17%
完整索引	83.51%
仅锚点	83.51%
随机索引	81.67%
Simple, 无字段定义	80.83%
完整索引, 无字段定义	74.70%

结论：完整索引没有可靠优于随机索引，和仅锚点均值相同；去掉字段定义则明显伤害索引组。当前证据更支持“字段定义与上下文配合有用”，不能证明全部邻近行设计都必要。

本轮 Index-Simple 为 +4.35 点，五项校正后 $p=0.0652$ 。它和第 9 节 +4.76 来自不同响应批次与检验安排；边际区间不按多重比较调整，不能仅据区间不跨零宣称 Holm 校正后显著。完整与仅锚点均值相同，也不代表已证明两者等效。

12. CUAD 合同：换文档类型能否推广

对应论文：5.9, [experiments.tex](#), 表 tab:cuad。

使用 20 个开发合同，冻结字段、长度限制、解析和文档编号后，测试 56 个符合条件的官方测试合同。评价合同名、日期、期限、管辖法律等五字段，不是完整 CUAD 问答任务。

方法	测试 F1
初始抽取	46.76%
Simple repair	43.35%
Indexed repair	44.84%
Indexed re-extraction	44.12%

主要比较“索引修复-索引重抽取”为 +0.72 点，95% 区间 [-4.80, 6.48]，未显示可靠优势。测试 224 个计划输出实际用 270 次请求，运输失败按协议保留，没有挑结果重跑。

结论：索引修复比初始抽取低 1.92 点，丢失 5 个原参考正确事实，并引入 12 个新参考不匹配事实。这是本次迁移未复现修复收益的直接负结果。它与重新抽取的差异仍不确定；不显著不能写成等效，新参考不匹配也不自动等于真人确认语义错误。

13. 真人审查：自动差异是否真的错，实际编辑是否可接受

对应论文：5.10, [experiments.tex](#), 表 tab:human_review、tab:human_review_by_config。

两个人独立判断同一批 400 项：D 从 302 项参考差异中抽 200；E 从五种配置的 598 个实际编辑中抽 200。154 项分歧由第三人裁决；原始标签和一致性保留。

问题	裁决后结果	它的含义
D: 输入真的有错吗?	95/200, 47.5%	参考不一致并不都是真错误
D: 建议操作可接受吗?	86/200, 43.0%	有问题也不代表这个具体操作就合适
E: 实际操作可接受吗?	134/199, 67.3%, 另 1 U	抽样实际编辑中，确定判断的接受比例

U 表示证据不足，不是漏填。E 的原始操作接受一致率为 65%， κ 为 0.128；裁决后得到统一结果，不能掩盖最初分歧较大。

结论：中文人工任务已完成，但 67.3% 是五种配置合并结果，不是完整方法自己的准确率。该指标衡量中文抽样编辑的接受率；收据和合同使用各自的数据集评分。历史 Diagnosis + Gate 自己的样本为 25/41 (61.0%)；配置抽样不平衡且较小，未建立方法之间的人工优势。完整分配统计见 [最终人工报告](#)。

14. 辅助实验、历史诊断与成本

对应论文：附录 A, [appendix.tex](#)；正文 5.12。

检查	主要发现	怎样理解
旧选择器候选穷举	参考引导的最佳候选组合 F1 可到 99.64%，旧选择器只有 84.72%	说明曾经有好候选但没选中；用了答案选组合，不能部署，也不是当前版本的新成绩
批量诊断规模	1,000 到 50,000 条记录，约 1.20 到 88.10 ms	独立文档批处理，不含模型推理，不是大型连通图修复
来源评分检查	180 对的模型评分与参考有效性相关	模型检查的辅助证据，不是新的人类评价

检查	主要发现	怎样理解
45 个 TNEWS 标题抽取	类别准确率 0.556; Neo4j 对照 0.533, 差异不显著	小型辅助抽取检查, 不是有金标准三元组的 KG 修复比较

一次模型响应过滤前后只算一次调用; 11,700 次缓存回放不是 11,700 次 API 请求。模型修复如果需要先建图, 应把初始建图成本也算上。同样调用一次, 也可能使用不同数量的输入 tokens。

15. 贡献与实验结论怎样对应

对应论文: 5.11 Discussion、5.12 的 tab:research_answers, 引言三项贡献及第 6 章 Conclusion。

贡献	验证路径	当前可支持的结论
来源约束候选验证流程	Algorithm 1; 固定响应过滤前后; 单项过滤与析因对照	可记录并拦截部分不合格候选, F1 收益较小; 数量命题保证约束下保留数量, 不保证语义正确
覆盖恢复与保持的修复评价	中文受控/实际抽取、独立收据、合同、D/E 人工任务	任务收益有差异, 参考匹配与人工语义质量有距离; 中文字段复制满分、合同修复下降均保留
组件归因与公开可复核证据	匹配提示、同响应过滤、收据上下文对照、单独神经选择器回放	冻结收据 Index-Simple 的 +4.76 点有正向配对区间, 但不能归因于完整索引或精准检索; 诊断与学习选择没有独立稳定收益

问题	目前的答案
完整流程能改善一些文档字段图吗?	能, 有受控与实际抽取的参考匹配结果
中文主任务必须用复杂模型吗?	没有证明; 字段复制已达 100%
诊断或学习路由稳定带来额外增益吗?	尚未证明; 严格 Gemma 诊断组 F1 反而下降
过滤能拦截部分不合格候选吗?	能, 但收益较小, 也出现过误删, 不保证语义正确
证据索引在新收据上有帮助吗?	相对 Simple 有正向结果, 规范化后仍改善; 未可靠胜过随机或仅锚点上下文
结果已推广到合同吗?	未复现: 索引修复 F1 低于初始抽取, 且未可靠胜过重抽取
真人评价完成了吗?	原定中文两项完成; 合并 134/199 不能代表完整方法准确率, 也未建立配置间优势

主文现在按任务与主结果、严格机制对照、外部文档、人工评价、综合讨论组织; 完整回放和解析明细保留在附录。旧实验数值及冻结协议没有调整。

当前状态为**内容定稿待作者确认**。本轮英文采用简单词和短句, 直接报告方法步骤及实验结果。下一步见 [PROGRESS.md](#)。