

阅读目录

Paper1 实验导读：每组实验做了什么、说明了什么	2
先找到论文里的实验	2
1. 用了哪些数据	2
2. 先看懂分数	3
3. 受控主实验：完整流程能修已知错误吗	3
4. 实际抽取输出：不人为放错，还能改善吗	3
5. 诊断与过滤：究竟哪部分带来收益	4
6. 消融：把组件拿掉，结果变不变	4
7. 跨模型：换模型后如何	5
8. 首次收据测试：规则为什么可能误删	5
9. 新收据测试：证据位置提示有没有用	5
10. 修复与重新抽取：旧图到底有没有帮助	6
11. 完整组件与简单上下文对照	6
12. CUAD 合同：换文档类型能否推广	7
13. 真人审查：自动差异是否真的错，实际编辑是否可接受	7
14. 辅助实验、历史诊断与成本	7
15. 用这张表记住论文结论	8

Paper1 实验导读：每组实验做了什么、说明了什么

更新：2026-10-08。按当前论文第 5 章及附录的顺序解释。所有数值来自已有结果；本次没有重跑实验、调用模型或改人工标签。

先用一句话理解任务：**模型已经从文档里填出一张字段表，我们利用原文再检查、补充和修改它。**实验既要看有没有修好，也要看有没有把原来正确的内容改坏。

先找到论文里的实验

编号按当前 main.tex 引用顺序整理。Overleaf 若改了顺序，用英文小节名定位。

本导读	论文对应小节	它想回答的问题
1—2	5.1 Experimental Protocol	用什么数据，怎么算好坏？
3	5.2 Controlled Repair Results	人为放入的错误能修好多少？
4	5.3 Repair of Actual Extraction Outputs	真实模型输出也能改善吗？
5	5.4 Component and Constraint-Gate Analysis; 5.5 Matched Comparisons and Sequential Selection	效果究竟来自过滤还是诊断？
6	5.6 Individual Filter and Optimizer Ablations	每项检查和顺序选择器有没有用？
7	5.7 Cross-Model Robustness	换模型后是否还有同样趋势？
8	5.8 External Receipt Text	换成原始收据文字会怎样？
9	5.9 Field-Evidence Follow-up on New Documents	提示证据位置是否有帮助？
10	5.10 Repair and Fresh Extraction with Shared Evidence	有旧图的修复是否优于重新抽取？
11	5.11 Contemporaneous Factorial and Evidence Controls	简单上下文能否解释索引增益？
12	5.12 Transfer to Contract Fields	换成合同能否复现收益？
13	5.13 Blinded Human Review of Discrepancies and Edits	真人是否认可这些错误和编辑？
14	附录 A Supporting Diagnostics; 5.15 Reproducibility and Availability	规模、成本和历史诊断怎么解释？
15	5.14 Discussion; 5.15 的研究问题汇总表	论文最终能得出什么结论？

数学含义不清楚时查 数学导读，不必先读完所有公式。

1. 用了哪些数据

对应论文：5.1, [experiments.tex](#), 表 tab:repair_benchmark; 各外部任务的小节另给细节。

数据	实际规模	用途
中文受控字段图	1,499 篇；训练 1,049、验证 225、测试 225	从已知答案出发，放入错误后测试恢复
中文实际抽取图	同一批 225 测试来源	直接检查模型真正生成的输出
中文机制对照	其中 60 篇，分别使用受控和实际抽取输入	固定其他条件，比较组件
SROIE 收据	首次 60 篇；后续另有 20 开发+60 测试篇	检验原始收据字段修复
CUAD 合同	20 开发+56 测试份	检验另一种文档类型
真人审查	200 项输入差异+200 项实际编辑	检验自动差异是否真错、编辑是否可接受

重要的数据特点：中文原文是“字段名：值”形式，正确值已经直接写在来源里。因此简单程序按字段复制就能满分。收据和合同不是同样规整的格式。

后续多组收据实验重复使用同一批 60 篇，不能每跑一组就算又增加了 60 篇独立测试文档。

2. 先看懂分数

对应论文：5.1 的 Metrics and statistics, [experiments.tex](#)。

指标	用普通话解释
缺陷修复率	放进去的错误，有多少被修回去了
三元组 F1	整体上既少漏填，也少多填；不是只数修了几条
整图精确匹配	整篇文档的输出全部吻合参考，才算一次成功
正确事实保持率	原本与参考相符的内容，还保留了多少
参考差异减少率	修复后比修复前少了多少差异；若越修越多，可以为负

“参考”是评分答案，不是每一次实际编辑都经过真人确认。收据金额 1200.00 与 1,200.00 可能意思相同，却在严格字符串评分中不同。

文中“+4.76 个百分点”指从 78.75% 到 83.51% 这样的相减。95% 差值区间跨过 0，表示当前证据还不能可靠判断哪种更好，不表示两者已被证明完全一样。

3. 受控主实验：完整流程能修已知错误吗

对应论文：5.2, [experiments.tex](#), 表 tab:repair_main、图 fig:repair_benchmark_results。

这里 Gate 指程序过滤器，Diagnosis 指额外诊断报告；Simple 是简单修复流程。SHACL 是描述和检查图约束的一种语言，本文使用其中适配本任务的检查。

怎么做：225 篇测试文档，每篇放入两个缺陷，共 450 个。缺陷包括缺失、重复、非法关系、反向边、无来源支持的值和层级冲突。比较不修复、规则、直接问模型、两次调用的 agent，以及组合流程。

方法	缺陷修复率	F1	整图完全匹配
不修复	0.00%	76.15%	0.00%
仅规则	32.00%	84.72%	6.22%
SHACL-style Repair	0.00%	79.98%	0.00%
直接问模型	92.44%	95.20%	82.67%
两次调用的 ReAct-style	89.11%	92.13%	59.56%
Simple Pipeline	95.11%	96.34%	84.00%
Diagnosis + Gate	98.00%	99.17%	93.33%
按原文字段直接复制	100.00%	100.00%	100.00%

结论：组合流程比这里实现的几个模型流程好，但这个数据上最好的方法是无需模型的字段复制。98% 属于“一次生成+过滤”，不是神经路由或多轮选择器的成绩。

完整流程比 Simple 的修复率高 2.89 点，配对区间为 [1.11, 4.89]。它证明这两个完整流程有差别，还不能说明差别具体来自哪一个组件。

4. 实际抽取输出：不人为放错，还能改善吗

对应论文：5.3, [experiments.tex](#), 表 tab:natural_errors、图 fig:natural_stratified。

怎么做：让模型对同一批 225 来源实际建图，再修复输出。其中 10 次无法解析；77 个图与参考不一致，共 302 项差异。

方法	F1	整图完全匹配
初始抽取	87.99%	65.78%
Simple Pipeline	88.07%	67.11%
Diagnosis + Gate	92.48%	68.44%
字段直接复制	100.00%	100.00%

结论：完整流程改善了参考匹配，三元组层面的改善比整图全部修好的改善更明显。这不是新领域测试；302 项自动差异也不能直接称为 302 个真人确认的错误。

论文另把解析失败与可解析但内容不符的输入分开检查，防止把“补回空图”的收益完全当成一般语义修复收益。

5. 诊断与过滤：究竟哪部分带来收益

对应论文：5.4—5.5, [experiments.tex](#)、[audit_primary.tex](#)。

先看同一批候选过滤前后。这样模型没有重新生成，变化才能归到过滤上：

- 缺陷修复率都为 98.00%，整图匹配都为 93.33%。
- F1 从 98.95% 到 99.17%；过度修复从 2.27% 降到 1.67%。
- 过滤器拒绝了 8 个无来源支持、且不匹配参考的三元组。

含义：过滤主要拦下额外不合格内容，没有让这批候选修好更多目标缺陷。

再用 Gemma 比较 Base、Diagnosis、SHACL context，60 篇 × 两种输入 × 三组，共 360 个响应；每个响应都分别评分过滤前后。

统一过滤后的上下文	受控 F1	实际抽取输入 F1
Base	99.62%	92.52%
Diagnosis	98.61%	91.47%
SHACL context	99.12%	93.64%

结论：增加诊断没有稳定改善输出。这与上一节“完整流程胜过 Simple”不矛盾：旧完整流程同时改变了多件事，此处更接近只比较诊断内容。

这里的 SHACL context 是结合本任务改编的相关工作思路，不是官方代码原样复现。

6. 消融：把组件拿掉，结果变不变

对应论文：5.6, [ablation_offline.tex](#)、[v2_ablation.tex](#)。

6.1 五项过滤检查

540 个已存响应分别通过 8 种过滤设置，共 4,320 次评分，不增加模型请求。

检查包括重复、文档编号、字段名单、来源支持、字段最多一个值。完整过滤器拦下 28 个不匹配参考的候选：11 个文档编号错误、17 个缺来源支持；其他检查在这批输出中几乎没有改变结果。

结论：有可追溯的拦截作用，但 21 项比较经多重比较校正后，没有一项达到显著标准。当前没触发某检查，不等于该检查永远无用。

6.2 神经路由和顺序选择器

这里是另一条流程：先试做每个修改，再由效用和约束决定是否接受。新版统一训练/运行特征，使用 8 输入、884 参数的监督路由网络。

13 种配置各处理 450 个输入；另做一套先验敏感性分析，合计 11,700 次离线回放。主要结果如下：

设置	受控 F1	实际抽取输入 F1
始终开启+均匀先验	84.72%	88.33%
始终开启+学习先验	84.72%	87.99%
学习先验+学习触发	84.72%	87.99%
去掉操作成本	89.30%	88.13%
仅规则候选	84.72%	87.99%

还检查了去先验惩罚、去密度上界、去质量下界、只做一轮、去规则候选，以及分别去局部/图/来源分数与对应边界。这些分数组件消融不等于把整个尺度的检测能力全部移除。

结论：这部分消融已经系统做过，但没有显示学习先验稳定提高最终修复质量。去成本有利于受控输入，对实际抽取输入却没有同样稳定的收益。11,700 是配置回放次数，不是新文档数。

7. 跨模型：换模型后如何

对应论文：5.7, [experiments.tex](#), 表 tab:cross_model。

在同一批 60 个受控文档上，历史 Claude 与 Gemma 都比较 Direct、Simple、Diagnosis + Gate。完整流程的缺陷修复率分别为 97.5%、98.3%，都高于对应的两个简单模型流程。

结论：这个小样本有跨模型一致趋势，但没有证明跨领域或真实语义错误上的普遍优势。这里提到 Claude 是历史档案，本次文档更新没有调用它。

8. 首次收据测试：规则为什么可能误删

对应论文：5.8, [external_receipts.tex](#)。

60 张收据，评价公司、地址、日期、金额；一个地址没有标签，因此总计 239 个标注字段。

Base 和 Diagnosis 的原始 F1 都为 79.44%，加过滤后变成 79.15%。被过滤掉的三个候选恰好都匹配参考，问题来自来源与候选的空白形式不一致。按“字段名：值”直接复制在这种收据文本上也不适用。

结论：合法字段和来源出现检查不够；来源格式也会影响过滤。这个结果推动了后续的字段的定义、空白处理与证据索引。

9. 新收据测试：证据位置提示有没有用

对应论文：5.9, [receipt_followup.tex](#), 表 tab:receipt_followup。

先用另外 20 篇固定设计，再用新的 60 篇测试。所有组拿到同样的字段定义、编号原文行和初始图；索引组额外得到字段相关行的位置。

方法	严格 F1	规范化 F1
初始抽取	78.33%	79.58%
Simple + Gate	78.75%	80.83%
Evidence Index + Gate	83.51%	86.43%

方法	严格 F1	规范化 F1
SHACL context + Gate	78.33%	80.42%

预设比较 Index-Simple 为 +4.76 点，95% 区间 [2.50, 7.26]。规范化后仍有差异，不全是大小写或空格造成的。

但不是只改对：索引修好 26 个原不精确字段，也使 14 个原精确字段失去精确匹配；其中 10 个仍是同一金额，只改变格式。过滤本身对索引 F1 仅贡献约 0.18 点，主要差别来自生成时看到的上下文。

结论：这批新收据支持证据提示有效；还需要下一组更简单的上下文对照，才能说明专门的索引设计是否必要。

10. 修复与重新抽取：旧图到底有没有帮助

对应论文：5.10, [reextraction_recovery.tex](#)。

复用上述 60 收据，比较“有/无旧图 × 有/无索引”，共 240 次请求。

所有响应都带 Markdown 代码围栏，与预先固定的严格解析器不兼容。因此原定严格分析全部失败，无法判断语义优势。

随后明确标注为事后分析，统一去外围围栏并处理已知文档编号：索引修复 F1 为 83.93%，索引重抽取为 74.86%。不统一编号时曾有更大的差距，其中一部分其实来自编号错误。

结论：不能把全部差距归给修复机制，也不能把事后处理写成预先设计成功的正式测试。这促成了合同实验在调用前固定解析和编号规则。

11. 完整组件与简单上下文对照

对应论文：5.11, [recovery_ablation.tex](#)，表 tab:recovery_factorial、tab:recovery_index。

本轮 840 个响应全部成功解析：480 个用于预处理 × 诊断开关，360 个用于收据上下文对照。过滤仍在同一响应上开关，不重新调用。

中文部分的六项预设组件主效应，经 Holm 校正后都未显著。诊断均值没有正向收益；来源和文档编号过滤拦下了 47 个不匹配参考的候选。这 47 个属于本轮，不能和第 6 节的 28 个混为一批。

收据部分如下，统一使用过滤：

上下文	F1
Simple	79.17%
完整索引	83.51%
仅锚点	83.51%
随机索引	81.67%
Simple, 无字段定义	80.83%
完整索引, 无字段定义	74.70%

结论：完整索引没有可靠优于随机索引，和仅锚点均值相同；去掉字段定义则明显伤害索引组。当前证据更支持“字段定义与上下文配合有用”，不能证明全部邻近行设计都必要。

本轮 Index-Simple 为 +4.35 点，五项校正后 $p=0.0652$ 。它和第 9 节 +4.76 来自不同响应批次与检验安排，不是同一数字算错。

12. CUAD 合同：换文档类型能否推广

对应论文：5.12, [cuad_contracts.tex](#), 表 tab:cuad。

使用 20 个开发合同，冻结字段、长度限制、解析和文档编号后，测试 56 个符合条件的官方测试合同。评价合同名、日期、期限、管辖法律等五字段，不是完整 CUAD 问答任务。

方法	测试 F1
初始抽取	46.76%
Simple repair	43.35%
Indexed repair	44.84%
Indexed re-extraction	44.12%

主要比较“索引修复-索引重抽取”为 +0.72 点，95% 区间 [-4.80, 6.48]，未显示可靠优势。测试 224 个计划输出实际用 270 次请求，运输失败按协议保留，没有挑结果重跑。

结论：没有证据说明旧图修复在这项新任务上稳定优于重新抽取；也不能因为不显著就说两者已经等效。

13. 真人审查：自动差异是否真的错，实际编辑是否可接受

对应论文：5.13, [experiments.tex](#), 表 tab:human_review、tab:human_review_by_config。

两个人独立判断同一批 400 项：D 从 302 项参考差异中抽 200；E 从五种配置的 598 个实际编辑中抽 200。154 项分歧由第三人裁决；原始标签和一致性保留。

问题	裁决后结果	它的含义
D: 输入真的有错吗?	95/200, 47.5%	参考不一致并不都是真错误
D: 建议操作可接受吗?	86/200, 43.0%	有问题也不代表这个具体操作就合适
E: 实际操作可接受吗?	134/199, 67.3%, 另 1 U	抽样实际编辑中，确定判断的接受比例

U 表示证据不足，不是漏填。E 的原始操作接受一致率为 65%， κ 为 0.128；裁决后得到统一结果，不能掩盖最初分歧较大。

结论：中文人工任务已完成，但 67.3% 是五种配置合并结果，不是完整方法自己的准确率。它不是整图人工 F1，也没有自动覆盖收据或合同的编辑语义审核。完整分配统计见 [最终人工报告](#)。

14. 辅助实验、历史诊断与成本

对应论文：附录 A, [supplementary_diagnostics.tex](#)；正文 5.15。

检查	主要发现	怎样理解
旧选择器候选穷举	参考引导的最佳候选组合 F1 可到 99.64%，旧选择器只有 84.72%	说明曾经有好候选但没选中；用了答案选组合，不能部署，也不是当前版本的新成绩
批量诊断规模	1,000 到 50,000 条记录，约 1.20 到 88.10 ms	独立文档批处理，不含模型推理，不是大型连通图修复
来源评分检查	180 对的模型评分与参考有效性相关	模型检查的辅助证据，不是新的人类评价
45 个 TNEWS 标题抽取	类别准确率 0.556；Neo4j 对照 0.533，差异不显著	小型辅助抽取检查，不是有金标准三元组的 KG 修复比较

一次模型响应过滤前后只算一次调用；11,700 次缓存回放不是 11,700 次 API 请求。模型修复如果需要先建图，应把初始建图成本也算上。同样调用一次，也可能使用不同数量的输入 tokens。

15. 用这张表记住论文结论

对应论文： 5.14 Discussion、5.15 的 tab:research_answers, 以及第 6 章 Conclusion。

问题	目前的答案
完整流程能改善一些文档字段图吗？	能，有受控与实际抽取的参考匹配结果
中文主任务必须用复杂模型吗？	没有证明；字段复制已达 100%
诊断或学习路由稳定带来额外增益吗？	尚未证明
过滤能拦截部分不合格候选吗？	能，但也出现过误删，不保证语义正确
证据索引在新收据上有帮助吗？	有正向结果，但没有可靠胜过所有简单上下文
结果已推广到合同吗？	没有可靠优势
真人评价完成了吗？	原定中文两项完成；不等于所有任务都已人工验证

论文目前说明的是：**修复效果与来源格式、字段含义、候选质量和检查方式密切相关**。查看下一步工作请读 [PROGRESS.md](#)；这里的负结果也是正式结论的一部分，不是待删除的失败记录。