

阅读目录

Paper1 数学导读：对照论文一步步看	2
先找到你正在读的论文位置	2
1. 输入和输出：修一张文档信息表	2
2. 三个检查：主体对不对、字段对不对、值能否找到	3
3. 模型生成：根据原文提出一份完整答案	3
4. 候选筛选：一个字段最多留一个值	3
5. 证据索引：给模型标出值得再看的原文行	4
6. Algorithm 1：把前面五件事串起来	4
7. 顺序变体的 profile：用四个分数概括当前图	5
8. 神经路由：建议要不要修、优先看哪类问题	5
9. 顺序选择：每次试改，再选择值得做的那一个	5
10. 自动评分：改对多少和整张图全对不同	6
11. 人工一致性与统计：判断这个提升是否可信	6
读完后应记住什么	7

Paper1 数学导读：对照论文一步步看

更新：2026-10-10。本文按当前论文顺序解释，不需要先学过图论或机器学习。本轮同步论文实验组织与收益归因，不改方法、公式、冻结协议或实验数值。

如果只想先理解方法，可以先读每节的解释和例子，暂时跳过公式；需要核对时再看符号。

全文用一个例子：收据写着“公司：甲公司；小计：100；实付：120”。系统要得到“这张收据—实付金额—120”这样的记录。这里的知识图谱，可以先理解为一张用三列存信息的表。

先找到你正在读的论文位置

章节号按当前 main.tex 实际引用的源码排列；Overleaf 若调整了顺序，以英文小节名为准。下面的“本导读第几节”不是论文公式编号。

本导读	论文对应位置	你会看懂什么
1	第 3 章开头, Task and Method	输入和输出是什么
2	3.1 Input Cleanup and Error Report	程序先检查哪些问题
3	3.2 Generating a Graph from Source Text	模型负责什么
4	3.3 Checking the Generated Triples	哪些候选能留下, 数量命题证明了什么
5	3.4 Field Meanings and Source Lines	怎样提示模型去原文找字段
6	4.1 Repair Steps, Algorithm 1	主流程怎样连起来
7—9	4.4 Choosing Edits One at a Time; 4.5 Shared Features for Training and Use	单独评估的神经路由和顺序修改怎样工作
10—11	5.1 Test Setup; 5.10 Human Review of Errors and Edits	怎样算分, 怎样理解人工结果

先分清两个流程。主实验的“98% 修复率”来自“一次模型生成+过滤”。神经路由和多轮选择是另一条单独评估的路径，不能用前者的成绩证明后者有效。

1. 输入和输出：修一张文档信息表

对应论文：第 3 章开头，overview.tex，定位 sec:framework。

符号	简单含义	例子
X	原文	收据上的全部文字
G	待修复的三列记录, 可包含重复项	“收据—实付—100”
$t = (h, r, o)$	一条记录: 主体、字段、值	(收据, 实付, 120)
h_0	这篇文档的固定编号	这张收据的编号
$\mathcal{R}_X$	允许填写的字段	公司、地址、日期、实付
G^*	评分时使用的参考答案	模型推理时不能读取
$\hat{G}$	修复后的输出	最终交出的信息表

这里每个字段最多保留一个值。“允许填写日期”不等于“每篇文档都必须有日期”。这个设置也不直接适用于“作者”这种可能有多个值的字段。

2. 三个检查：主体对不对、字段对不对、值能否找到

对应论文：3.1, [overview.tex](#), 公式标签 [eq:diagnostic_predicates](#)、[eq:diagnostic_context](#)。

程序先去掉完全重复的记录，处理字段图中明确写反的边，去掉非法主体或字段。接着用三个开关检查候选：

$$\begin{aligned} H(t) &= \mathbf{1}[h = h_0], & R(t) &= \mathbf{1}[r \in \mathcal{R}_X], \\ S(t; X) &= \mathbf{1}[o \neq \emptyset \wedge o \text{ occurs in } X]. \end{aligned}$$

$\mathbf{1}[\dots]$ 的意思是：方括号里的条件成立就记 1，否则记 0。 $\wedge$ 表示“并且”。

- H ：这条记录是否属于指定文档？
- R ：字段是否在允许名单内？
- S ：值是否非空，而且能在原文里找到？

例如“实付—100”可能三个检查都通过，因为 100 确实在收据里，但它是小计。因此，**通过这三个检查不等于字段语义正确**。

诊断报告只是把发现的问题列出来：

$$D = (n_{\text{dup}}, I_H, I_R, I_S, \mathcal{R}(G_s)).$$

G_s 是预处理后的图； n_{dup} 是重复数， I_H, I_R, I_S 是检查失败的位置，最后一项是已经出现的字段。报告在预处理之后生成，有些问题已被删除，对应列表自然为空。

3. 模型生成：根据原文提出一份完整答案

对应论文：3.2, [overview.tex](#), [eq:proposal_generation](#)。

$$C = L_\theta(X, h_0, \mathcal{R}_X, G_s, D).$$

把它读成一句话：**将原文、文档编号、字段名单、现有图和可选诊断交给模型，得到候选记录列表 C 。** L_θ 表示现成语言模型，不表示本论文重新训练了该模型。

模型要返回完整图，因此旧图里正确但没有被重新输出的记录，也可能丢失。该流程不是“只改错的地方，其余自动保留”。无法解析的输出按相应实验协议保留为失败，不从分母中删除。

4. 候选筛选：一个字段最多留一个值

对应论文：3.3, [overview.tex](#), [eq:eligible_candidates](#)、[eq:admissible_subsets](#)、[eq:selection_size](#)。

先去重，再留下通过三个检查的候选：

$$C_X = \{t \in \text{uniq}(C) : H(t)R(t)S(t; X) = 1\}.$$

这里三个 0/1 值相乘，只有全部为 1 才通过。再要求每个字段最多出现一次：

$$\mathcal{F}(C_X) = \left\{ A \subseteq C_X : \sum_{t \in A} \mathbf{1}[r_t = r] \leq 1, \forall r \in \mathcal{R}_X \right\}.$$

读法是：“ $\mathcal{F}$ 收集所有合法的候选子集；每个字段的计数不能超过 1。”实际算法按模型输出顺序扫描，保留每个字段的第一个合格候选。

论文的数量命题：

$$|\widehat{G}| = \max_{A \in \mathcal{F}(C_X)} |A| = |\{r : \exists t \in C_X, r_t = r\}|.$$

竖线 $|\cdot|$ 表示“有多少个”。假设合格候选涉及公司、日期、实付三个字段：每个字段最多取一个，所以最多保留三条；算法恰好各取一条，便达到三条。

这证明的是“保留数量最多”。如果实付的 100 和 120 都通过检查，选第一个仍可能选错。该命题没有证明语义最正确、修改最少或 F1 最高。若以后加入“总额必须等于各项金额之和”，字段之间会相互影响，原来的简单证明就不够了。

5. 证据索引：给模型标出值得再看的原文行

对应论文：3.4, [overview.tex](#), sec:framework:field_evidence。下面的窗口式是对文字步骤的展开，不是新增论文定理。

先告诉模型“实付金额”指最终应付总额，再在原文中寻找 total 等位置。例如找到第 10 行，就同时提示它查看第 9—12 行。

$$A_r = \{i : \text{line } i \text{ matches field } r\}, \quad E_r = \bigcup_{i \in A_r} \{i-1, i, i+1, i+2\}.$$

A_r 是字段 r 的锚点行， E_r 是锚点和邻近行；超出文档范围的行号去掉。所有比较方法仍能看到完整原文，索引只是额外提示，不是用参考答案挑行。

收据后续实验还统一了空白处理。 $N(s)$ 把连续空格、换行压成一个空格，并去掉首尾空白：

$$S_{ws}(t; X) = \mathbf{1}[|N(o)| > 0 \wedge N(o) \text{ occurs in } N(X)].$$

例如 甲公司\n上海 和 甲公司上海 可以匹配。这只减少排版差异，不会判断“甲公司”究竟是销售方还是购买方。早期主过滤器和顺序选择器使用的空白处理不同，各版本结果按原规则保留。

6. Algorithm 1：把前面五件事串起来

对应论文：4.1, [implementation.tex](#), alg:abstract。

1. 整理输入图，得到 G_s 。
2. 生成诊断报告。
3. 调用一次模型，解析完整候选图。
4. 依次检查重复、主体、字段、原文和单值限制。
5. 返回保留的记录，并记下拒绝原因。

复杂度是在估计“数据变多后需要做多少检查”：

$$T_{\text{preprocess}} = O(n), \quad T_{\text{gate}} = O(k(1 + c_X)).$$

n 是输入记录数， k 是候选数， c_X 是一次原文查找的成本。 $O(n)$ 可理解为“检查量大致随记录数增长”。这不包含模型推理时间；原文查找也不是永远固定耗时。

7. 顺序变体的 profile：用四个分数概括当前图

对应论文：4.4—4.5, `implementation.tex`、`math_revision.tex`，以及 Figures 1、3。下面的分量式补充正文中的文字定义。

分数	简单问题	计算方式（分母非空时）
Q_{inc}	有多少节点连着边？	$100(1 - I/n)$
Q_{uniq}	记录是否重复或高度相似？	$100c/m$
Q_{rule}	有多少记录未被规则标为违规？	$100(1 - B/m)$
Q_{src}	有多少值能在原文找到？	$100(1 - U/m)$

n 为节点数， m 为记录数， I 为孤立节点数， B 为被规则标记的不同记录数， U 为来源不匹配数。 c 是把相似记录连起来后得到的组数；实现用字符相似度判断，不需要下载嵌入模型。

四项平均得到 Q_p 。例如 5 个节点中 1 个孤立，第一项为 80 分。

不要把“节点都连着边”理解成“字段都填全了”。一张图只留下公司名，它的节点仍可能都连接正常。这正是额外检查明确来源字段是否缺失的原因。

图密度 ρ 表示实际连接占可能连接的比例；实现只计算不同节点对的连接，避免重复记录把密度推到 1 以上。空图和缺来源等边界采用明确的程序约定，分数不是“事实正确概率”。

8. 神经路由：建议要不要修、优先看哪类问题

对应论文：4.4—4.5。网络结构和训练损失属于实现补充，正文没有逐项展开这些矩阵。

输入是四个分数和四个图统计量：

$$x = [Q_{\text{inc}}, Q_{\text{uniq}}, Q_{\text{rule}}, Q_{\text{src}}, n, m, \rho, n_{\text{viol}}].$$

网络从 8 个数，经过 32、16 个中间单元，给出两个输出：修复概率 p_{repair} ，以及三类问题的优先程度 π 。 n_{viol} 是发现的违规数。

训练时，一方面要求“是否有缺陷”判断正确，另一方面要求“主要属于哪类问题”判断正确：

$$\mathcal{L} = \frac{1}{N} \sum_i \text{BCE}(p_i, y_i) + \frac{\sum_i m_i (-\log \pi_{i, c_i})}{\sum_i m_i + \epsilon}.$$

y_i 是是否有缺陷的标签； c_i 是问题类别； m_i 表示是否有可用类别标签； ϵ 防止除零。两项损失都在做同一件事：预测越偏离训练标签，扣分越多。

这是用已知标签训练的**监督路由器**。它不是 Paper2 那种靠连续行动奖励训练的 RL 网络。当前特征已统一为只使用公开输入，但“缺陷分类正确”仍不等于“最终编辑选择正确”。

9. 顺序选择：每次试改，再选择值得做的那一个

对应论文：4.4 的流程图和 4.5 的效用公式，`math_revision.tex`。

对候选操作 a ，先复制当前图，试做得到 G_a ，再计算：

$$U(a) = \frac{Q_p(G_a) - Q_p(G)}{100} + 0.20 \frac{\max(0, h(G) - h(G_a))}{\max(1, h(G))} - 0.35c(a) + 0.05 \log(\max(\pi_{s(a)}, 0.05) + 10^{-6}) + 0.02z(a).$$

从左到右就是五笔账：质量提高多少、违规减少多少、操作多贵、路由器多偏好这类操作、候选有多可信。 h 是违规数， c 是设定的操作成本， $s(a)$ 是类别， z 是提议置信度。

添加、删除、改类型的成本分别为 0.06、0.30、0.16；这不是美元费用。候选还要通过各分数下界、允许回退幅度、密度和不删空检查。然后选 U 最大且 $U > 0$ 的一项执行，重新评分，最多 12 轮。

一个容易理解的反例：正确补上一个缺失字段，但四个分数几乎不变；再减去成本后，系统可能觉得“不值得做”。所以效用变好和参考 F1 变好不是同一回事。

论文另检查了把均匀先验的负常数去掉：

$$U_{\text{relative}}(a) = U(a) - 0.05 \log(1/3 + 10^{-6}).$$

这像把所有候选同时加上相同分数：排名不变，但原来略低于零的候选可能变成可接受。它是敏感性对照，不是事后选出的新默认方案。

当前正文 5.4 报告选择器摘要，完整 13 配置和先验敏感性回放移至附录 A.2。默认顺序选择在受控输入接受 0 次编辑；自然输入学习先验 F1 87.99%，低于均匀先验 88.33%。保留这条神经变体和三张方法图用于单独评价，不能以主流程 98% 的结果归因于它。

该流程需要对许多记录两两比较。 T 轮、每轮最多 K 个候选、每图 m 条记录时，主要检查量约 $O(TKm^2)$ ；不能套用 Algorithm 1 的近似线性成本。

10. 自动评分：改对多少和整张图全对不同

对应论文：5.1 的 Metrics and statistics，以及各任务的评分说明，[experiments.tex](#)。

中文任务保留重复次数。设候选记录 t 在输出、参考中分别出现 y_t, g_t 次：

$$TP = \sum_t \min(y_t, g_t), \quad F1 = \frac{2TP}{|\hat{G}| + |G^*|}.$$

例如参考有 4 条，输出有 5 条，其中 4 条匹配，F1 为 8/9，约 88.9%。若只看命中参考的比例会得到 100%，却忽略多输出的一条。

- **缺陷修复率：**人工注入的缺陷有多少被恢复；主实验分母是 450 个缺陷。
- **整图精确匹配：**一篇文档的输出全部吻合参考才算通过。
- **参考差异减少率：**原差异数为 $d_0 > 0$ ，修复后为 d_1 ，计算 $1 - d_1/d_0$ ；差异增多时可以为负。

收据和合同另有规范化规则。忽略一些空白后更相似，不等于人工确认语义相同。

11. 人工一致性与统计：判断这个提升是否可信

对应论文：5.10 人工评价与 5.1 统计方法，[experiments.tex](#)。

两个人判断同一批项目，Cohen's κ 用来衡量“超过偶然一致程度的一致性”：

$$\kappa = \frac{p_o - p_e}{1 - p_e}.$$

p_o 是实际一致比例； p_e 是按两人各类标签比例计算的偶然一致水平。E 任务操作可接受性的原始一致率为 65%， κ 为 0.128；第三人裁决不会把这项原始一致性变高。

最终 E 接受率是 134/199，约 67.3%，另有 1 项不确定。它来自五种配置的合并操作样本，不能写成完整方法的人工准确率。历史 Diagnosis + Gate 的样本是 25/41；这些不平衡配置样本未建立人工方法优势。

配对 bootstrap 可以理解为：反复抽取整篇文档，比较同一批文档上的两种方法。如果差值区间跨过 0，就暂时不能判断哪种更好。Holm 校正是在同时比较很多项时提高判定要求，防止碰巧挑出“显著”结果。论文给出的边际 95% 区间不作多重比较调整；应按相应检验族的校正 p 值判断显著性。不显著不能证明等效，均值相同也不能证明等效。

收益归因必须遵循实际对照：整体 pipeline 对比同时改变提示和过滤，不能用它独立证明诊断有效；同一个响应过滤前后才能直接观察过滤的贡献。收据冻结对照 Index-Simple 为 +4.76 点，但后续 Full-Random 不显著、Full 与 Anchors-only 均值相同，所以不能将全部收益归于完整索引或精准检索。合同索引修复从 46.76% 降至 44.84%，与重抽取差值 +0.72 点的区间 [-4.80, 6.48] 又跨零：这项合同测试中，修复分数低于初始抽取，修复与重抽取的差值区间跨零。

读完后应记住什么

主算法的数学保证是检查条件和字段数量约束；模型负责提出值。证据索引帮助定位文本，顺序变体根据可计算分数选操作。**这些分数、引用和约束本身都不等于语义正确性的证明，效果仍要看对照实验。**

下一步按论文顺序读 [实验导读](#)。当前工作状态见 [PROGRESS.md](#)；需要追溯旧公式修复时再看 [历史数学审查](#)。