

阅读目录

Paper2 数学导读：对照论文理解规则、奖励和强化学习	2
先找到论文里的对应位置	2
1. 图质量：四种常见结构错误还有多少	2
2. 规则质量：检查规则是否好用	3
3. 策略的“观察”和“动作”	3
4. 奖励：一次操作到底值不值得做	4
5. Double DQN：从反复尝试中学习选动作	4
6. Algorithms 1、2：两种方式提出规则	5
7. 规则执行：提出一句话之后，还得能匹配到记录	5
8. DocRED 新环境：发现旧问题不该被当成制造新问题	6
9. 规则准入：先核验，再允许策略获取	6
10. 实验的几个数学量该怎么读	7
读完后应记住什么	7

Paper2 数学导读：对照论文理解规则、奖励和强化学习

更新：2026-10-08。按当前论文的章节顺序解释。本文只改说明方式，没有修改论文算法或实验。

如果只想先理解方法，可以先读每节的解释和例子，暂时跳过公式；需要核对时再看符号。

可以把系统想成一个整理资料的人：手里有一张可能出错的信息表，也有一些检查规则。他每一步要决定：先找新规则，还是先修已有问题？Paper2 用强化学习研究这个选择。

先找到论文里的对应位置

TKDE 模板用 III、IV 表示第三、第四章；III-B 表示第三章第二小节。云端若改了顺序，以英文标题为准。

本导读	论文位置	解释的问题
1—2	III-B Quality Assessment Model	怎样评价图和规则
3	III-C / Environment and Policy Observation	策略看到什么，可以做什么
4—5	III-C / Reward and Double DQN	如何给行动打分，怎样训练
6	III-D LLM-Based Dual-Strategy Rule Generation, Algorithms 1、2	两种规则生成算法
7	III-E Offline Generated-Rule Bridge	文字规则怎样变成可执行检查
8	III-E 的 response-level 段落；附录 C-A Source-Evidence Development Test	新文档环境为什么使用另一套奖励
9	III-E 的 admission 段落；附录 D-A Context-Bound Admission and Coverage	规则经过核验后才能进入执行器
10	IV-B / Matched Policies and Measures；IV-D；附录 D、E	F1、过程分数、穷举和统计怎么读

先区分：现有 RL 主实验使用固定规则库；DocRED 新环境使用实际生成候选，但新环境的正式 RL 训练还没完成。下面不会把这两套结果当成一套。

1. 图质量：四种常见结构错误还有多少

对应论文：III-B 的 Graph Quality, [methodology.tex](#), eq:kg_quality。

错误	普通例子	错误比例
孤立节点	表里留下一个名字，但和任何记录都不相连	I_r
重复边	同一条记录写了两遍	D_r
非法关系	字段名不在允许名单里	V_r
悬空边	记录指向一个不存在的实体编号	L_r

“好”的比例就是 1 减去错误比例。四种比例加权求和：

$$Q_G = 0.20(1 - I_r) + 0.20(1 - D_r) + 0.30(1 - V_r) + 0.30(1 - L_r).$$

例如只有重复问题，重复率为 10%，其余错误为零，那么 $Q_G = 0.98$ 。这表示结构分数高，不表示 98% 的事实经过真人确认。

孤立比例按节点数计算，其余按边的出现次数计算；分母至少取 1。执行器还禁止把原本非空的图删空，避免通过“全部删除”刷高结构分。

2. 规则质量：检查规则是否好用

对应论文：III-B 的 Rule Quality, [methodology.tex](#), eq:qr_online。

把规则用于一份固定的 180 案例检查清单，统计：

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}.$$

TP 是正确报错， FP 是把正常项误报成错误， FN 是漏掉的错误。例如报出 10 个问题，其中 8 个真有问题，precision 就是 80%。

Coverage 是四类缺陷中，有多少类已经有对应检查模块。最终：

$$Q_R = 0.35 \text{ Precision} + 0.35 \text{ Recall} + 0.30 \text{ Coverage}.$$

空规则库按零分处理。这些检查表现来自受控实验预设的校准清单，不是每一步让真人重做评价，也不是对任意新生成规则的正确率保证。

图质量和规则质量合起来，展示时使用：

$$\bar{Q} = \frac{Q_G + 0.4Q_R}{1.4}.$$

除以 1.4 是为了把尺度放回 0—1。这个综合分与参考 F1 是两个指标。固定规则库里的最佳 Q_R 约 0.9409，因此即使图完全无结构缺陷，综合分最高也只有约 0.9831，而非 1。这是该规则库的限制。

3. 策略的“观察”和“动作”

对应论文：III-C 的 Environment and Policy Observation, [methodology.tex](#)。

策略不会直接看到所有内部资料，而是看到 14 个数：

$$o_t = [S_1, S_2, S_3, S_4, P, R, C, \tilde{n}_I, \tilde{n}_D, \tilde{n}_V, \tilde{n}_L, \tilde{b}, \rho_{\text{valid}}, \rho_{\text{noisy}}].$$

前四个是图分数， P, R, C 是规则的 precision、recall、coverage；接着是四种缺陷相对初始数量的比例、剩余步数比例，以及两类模块的激活比例。

这里 o_t 是第 t 步的简要观察。它像只看报表摘要：两张不同的图可能有相同的 14 个数，所以不能认定它包含了作出最优决策所需的全部信息。

八种动作分为三组：

动作	作用
去孤立、去重、恢复非法关系、清理悬空边	修改图
获取 deletion 模块、获取 augmentation 模块、各取一个	增加固定规则库中的检查能力
prune	移除低精度模块

动作掩码就是一张“现在允许做什么”的清单：没有启用去重检查器，就先不允许执行相关修复。通常基线也获得同一清单，以保证比较公平。

主实验中恢复关系用到了环境私存的损坏前记录，策略读不到这些答案；这让受控环境有可信的恢复操作，不等于真实错误也已经有同样可靠的修法。

4. 奖励：一次操作到底值不值得做

对应论文：III-C 的 Reward and Double DQN, eq:reward_def、eq:safety_modes。

$$r_t = \Delta Q_G + 0.4\Delta Q_R - 0.004C_{\text{call}} - 2 \times 10^{-5}C_{\text{edit}} - P_t.$$

从左到右读成：图变好了多少+规则变好了多少-获取成本-编辑成本-新错误惩罚。 Δ 表示“操作后减操作前”。

C_{call} 在主 RL 实验里只是模拟成本单位，训练没有发 HTTP 请求。 C_{edit} 记录图和规则的改动次数。不能把它们直接读成真实费用。

为什么必须数“新产生的错误”

$$N_{\text{new}} = |\mathcal{V}(G_{t+1}) \setminus_m \mathcal{V}(G_t)|.$$

$\mathcal{V}$ 是带身份的错误列表； $\setminus_m$ 表示按身份和重复次数取差。删掉一条悬空边后，可能留下一个孤立节点：错误总数没变，但新错误确实产生了。只比较总数会漏掉它。

三种惩罚在比较什么

$$P_t^{\text{count}} = 0.01 \sum_k n_{k,t}, \quad P_t^{\text{rate}} = \sum_k w_k \frac{n_{k,t}}{D_{k,0}}, \quad P_t^{\text{zero}} = 0.$$

$n_{k,t}$ 是第 k 类新错误数， w_k 是图分数中的权重， $D_{k,0}$ 是初始节点数或边数，至少为 1。

- count：每出现一个新结构错误，扣固定分。
- rate：结合原图大小扣分；大图中的一个重复项占比更小。
- zero：不加这项惩罚，作为对照。

分母固定为初始规模，不能靠删小图来改变扣分标准。旧 count 惩罚曾让模型不愿恢复正确关系，因为恢复过程可能暂时造成重复。rate 缓解了这个问题，但没有证明“所有安全问题都解决了”。

为什么系统还在意“早点修好”

训练考虑未来奖励，但越远的奖励权重越小，折扣因子 $\gamma = 0.95$ 。令 $J_t = Q_G(G_t) + 0.4Q_R(R_t)$ ，论文展开为：

$$\sum_{t=0}^{T-1} \gamma^t (J_{t+1} - J_t) = -J_0 + \gamma^{T-1} J_T + (1 - \gamma) \sum_{t=1}^{T-1} \gamma^{t-1} J_t.$$

不必逐项背下来。它的含义是：不仅看最后好不好，也奖励中间阶段早点变好。只有 $\gamma = 1$ 时才只剩起点与终点之差。

5. Double DQN：从反复尝试中学习选动作

对应论文：III-C 的 Reward and Double DQN, methodology.tex。

网络 $Q_\theta(o, a)$ 预测：“现在做动作 a ，以后大概能拿到多少总奖励？”它不是图质量 Q_G ，也不是动作概率。网络结构为 $14 \rightarrow 32 \rightarrow 16 \rightarrow 8$ ，最后八个数分别评价八个动作。

Double DQN 用两个网络分工：在线网络挑选下一步，更新较慢的目标网络给这个选择估值。

$$a^* = \arg \max_{a' \in \mathcal{A}_{t+1}} Q_{\theta}(o_{t+1}, a'),$$

$$y_t = \begin{cases} r_t, & \text{episode ends or no feasible action,} \\ r_t + \gamma Q_{\theta^-}(o_{t+1}, a^*), & \text{otherwise.} \end{cases}$$

$\arg \max$ 表示“挑分数最高的”； $\mathcal{A}_{t+1}$ 是下一步允许的动作； θ^- 表示目标网络。比如当前得到 0.1 分，下一步预计还有 0.2 分，则目标值是 $0.1 + 0.95 \times 0.2 = 0.29$ 。

训练让当前预测接近这个目标：

$$\mathcal{L} = \mathbb{E}[\text{Huber}(Q_{\theta}(o_t, a_t) - y_t)].$$

$\mathbb{E}$ 可理解为取一批经验的平均。Huber 损失对小误差像平方扣分，对大误差改为较缓的线性扣分，避免个别大误差主导更新。

算法步骤：重置图 $\rightarrow$ 选动作 $\rightarrow$ 执行并拿到奖励 $\rightarrow$ 保存这一步经验 $\rightarrow$ 从旧经验中抽样训练 $\rightarrow$ 定期复制目标网络 $\rightarrow$ 开始下一轮。每个模型训练 250 回合，最多 18 步/回合，目标网络每 100 步更新。

训练初期多尝试随机动作，后期更多采用自己的预测。实际探索率按 260 回合衰减，因此第 250 回合结束时约为 0.0902，还没有降到设定下限 0.05。

6. Algorithms 1、2：两种方式提出规则

对应论文：III-D, [methodology.tex](#), alg:deletion_completion、alg:augmentation_expansion；完整提示在附录 A。

算法	怎样做	容易误解的地方
Algorithm 1: Deletion Completion	从原文删掉短片段，把原文、删改版和被删片段一起交给模型，提出规则	模型仍看到原文，不是盲猜缺失内容
Algorithm 2: Augmentation Expansion	让模型在一次响应中提出补充子句和规则候选	假设补充句不能当成真实来源证据；不是每补一句就额外调用一次

两种候选集合记为 R_D, R_A ：

$$|R_D \cup R_A| = |R_D| + |R_A| - |R_D \cap R_A|.$$

例如第一种提出 10 条、第二种 12 条，其中 4 条重复，合起来有 18 条。**合起来更多，可能只是因为调用了两次。**要判断是否划算，还要在相同调用次数下比较，并检查这些候选能否真正执行。

7. 规则执行：提出一句话之后，还得能匹配到记录

对应论文：III-D 的 Rule Materialization；III-E Offline Generated-Rule Bridge, sec:rule_bridge_method。

一个类型规则可以写为：主体类型、关系、对象类型。例如“人物—任职于—组织”。匹配条件是：

$$\text{match}(r, x) = \mathbf{1}[(\text{type}(h_x), p_x, \text{type}(o_x)) = r].$$

x 是要检查的记录， p_x 是它的关系。程序只在类型和关系能对上时使用这条规则，不自动猜类型或别名。

- allowed：这个类型组合被允许，不表示具体事实一定正确。

- forbidden: 这个组合被禁止, 可以触发检查。
- 同时允许与禁止: 有冲突, 先不删。
- 没有允许规则: 不能自动理解为禁止。

桥接流程是: 解析规则 → 获取指定规则包 → 找到匹配与冲突 → 删除无冲突的禁止项 → 重新检查。仅能执行的桥接接口还不是一个已经训练好的新 RL 策略。

8. DocRED 新环境: 发现旧问题不该被当成制造新问题

对应论文: III-E 的 Response-level development environment; [docred_source_pilot.tex](#), 附录 C-A。以下是实现奖励的详细展开。

新环境每次处理两篇文档, 四个动作是: 获取 deletion 响应、获取 augmentation 响应、修复、停止。最多获取四包、做十步, 和前面的八动作环境不同。

记录还可以得到具体来源的 supported (支持) 或 contradicted (矛盾) 判断。类型许可不等于事实支持; 明确来源支持与删除依据冲突时, 程序弃权。

令 T_A, T_F 分别表示类型允许/禁止, S, C 分别表示来源支持/矛盾:

$$\begin{aligned}\text{Conflict} &= (T_A \wedge T_F) \vee (S \wedge C) \vee (S \wedge T_F), \\ \text{Violation} &= \neg \text{Conflict} \wedge [C \vee (T_F \wedge \neg T_A \wedge \neg S)].\end{aligned}$$

$\vee$ 是“或者”, $\neg$ 是“不是”。这两行主要是在说: **有冲突先不删; 没有冲突时, 明确矛盾或未被支持抵消的类型禁止可以触发删除。**

新奖励比较修改前后的图时, 固定使用同一套更新后的规则:

$$\begin{aligned}r_t &= 0.5[\Phi(g_{t+1}; R_{t+1}) - \Phi(g_t; R_{t+1})] \\ &\quad + 0.5[C(R_{t+1}) - C(R_t)] - 0.004a_t - 0.00002d_t - \frac{|V_{\text{edit},t}|}{N}.\end{aligned}$$

这里 N 是初始记录数 (至少为 1); $\Phi = 1 - \text{违规数}/N$; $C(R)$ 是原始记录被规则无冲突覆盖的比例; a_t, d_t 是获取和删除数量; V_{edit} 只数修改新制造的违规。

想象刚拿到一把更好的尺子, 发现桌子原来就歪了。这个问题不是尺子造成的。对应地, 新增规则发现旧错误, 不该被罚成“引入新错误”。

仍有一个问题: 如果尺子本身错了, 系统可能删掉正确记录并得到正奖励。当前删除操作不会让剩余记录出现新的局部违规, 新违规惩罚可能一直为零; 把零前面的系数调大不能纠正坏规则。

9. 规则准入: 先核验, 再允许策略获取

对应论文: III-E 的 Context-bound rule admission; 附录 D-A, [appendix.tex](#), app:rule_admission。本节公式是对文字机制的简写, 自动核验效果尚未完成评估。

每个判断都绑定候选、原文、初始图、关系词表和生成响应。输入变了, 旧批准就不能直接搬过来。

对一个类型候选, 先找本对文档中所有匹配记录, 再逐个判断。聚合规则很简单: 任何一项拒绝就拒绝; 每项都批准才批准; 没有匹配或证据不足则不确定。

$$a(r) = \begin{cases} \text{reject}, & \text{any matching record is rejected,} \\ \text{approve}, & \text{nonempty matches are all approved,} \\ \text{uncertain}, & \text{otherwise.} \end{cases}$$

批准只是“可以使用”，还要等策略真正获取所属响应包才激活：

$$R_t = \{r : \text{grounded}(r) = 1, a(r) = \text{approve}, p(r) \in A_t\}.$$

$p(r)$ 是规则所属包， A_t 是已经获取的包集合。核验器不能把没有获取的规则提前送给策略。

schema 与模型联合时，明确拒绝优先；没有拒绝时，任一有效批准可准入。本轮没有可靠的 schema 硬映射，因此 schema 全部是不确定。模型自动判断也不等于独立人工标签。

“引用能找到”只证明出处存在。原文没有说某件事，不能推出它说了这件事是假的。当前输入图只做删除；如果以后新增或改写记录，需要重新核验相关范围。

10. 实验的几个数学量该怎么读

对应论文：IV-B 的 Matched Policies and Measures、Inference；IV-D；附录 D、E。

F1： F_T 是输出事实集合， F^* 是参考集合：

$$F1 = \frac{2|F_T \cap F^*|}{|F_T| + |F^*|}.$$

它同时考虑漏掉和多出的事实。关系恢复率更严格：原坏边必须还在，而且关系名修对；直接删除坏边不算恢复。

过程 AUC：

$$\text{AUC}_{18} = \frac{1}{18} \sum_{t=0}^{17} \frac{\bar{Q}_t + \bar{Q}_{t+1}}{2}.$$

可理解为 18 步里的平均过程质量；提前结束后用最后分数补齐。它不是分类任务的 ROC-AUC，也不是上面的 F1。

Oracle：把当前有限预算内所有可行动作顺序都试一遍，再用参考答案挑最高分：

$$F_i^{\text{safe}} = \max_{\tau: \text{Preservation}_i(\tau) \geq 0.99} F_i(\tau).$$

i 表示文档对， τ 表示一条操作顺序。它帮助判断“即便选得最好还有多少提升空间”，但用了答案，不能当作实际策略。

统计单位：RL 主比较先对每个种子的 30 个场景取平均，再比较 10 个种子；DocRED 用 10 个文档对。不能把所有重复回放都当独立样本。平均保留率先逐对算再平均，所以不一定等于把所有正确条目直接合并后的比例。

读完后应记住什么

Paper2 的 RL 是真实训练的；奖励和掩码会影响行为。但固定规则库上的学习结果，不能自动证明真实生成规则已经可靠。当前最需要验证的是：好规则能否带来有用且互补的修复，随后再判断学习调度是否值得。

对应数据和结论见 实验导读，当前状态见 PROGRESS.md。自动核验的细节留在 冻结协议，需要时再查。